

Pravilo razvrstavanja - Ako je $d_i(\vec{x}) > d_j(\vec{x})$ te $j \neq i$ tada uzorak \vec{x} pripada razredu w_i

$$d(\vec{x}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} = \vec{w}^T \vec{x} + w_{n+1}$$

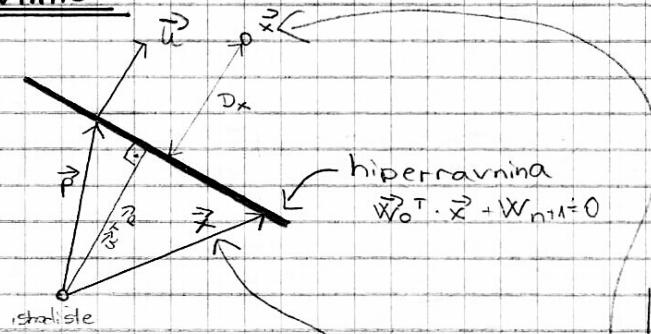
\downarrow težinski koeficijenti \downarrow formirajuće

DVA RAZREDA

- | | | | |
|-----|------------------|------|-------------------|
| ako | $d(\vec{x}) > 0$ | onda | $\vec{x} \in w_1$ |
| | $d(\vec{x}) < 0$ | | $\vec{x} \in w_2$ |
| | $d(\vec{x}) = 0$ | | nedefinirano |

$$d(\vec{x}) = \vec{w}_0^T \vec{x} + w_{n+1} = 0$$

Jednadžba hiperravnine



$$\vec{w}_0^T \vec{x} + w_{n+1} = 0$$

$$\vec{w}_0^T (\vec{x} - \vec{p}) = 0$$

$$\vec{w}_0^T \vec{x} = -w_{n+1} \cdot \frac{1}{\|\vec{w}_0\|}$$

$$\vec{w}_0^T \vec{x} - \vec{w}_0^T \vec{p} = 0$$

$$\frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|} = \frac{-w_{n+1}}{\|\vec{w}_0\|}$$

$$\vec{u}^T \vec{x} = \vec{u}^T \vec{p}$$

$$\vec{u}^T \vec{x} = \frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|}$$

$$\boxed{\vec{u}^T \vec{p} = \frac{w_{n+1}}{\|\vec{w}_0\|}} = \frac{|w_{n+1}|}{\|\vec{w}_0\|} = D_x$$

$$\vec{u}^T = \frac{\vec{w}_0^T}{\|\vec{w}_0\|}$$

udaljenost
hiperravnine
od središta

$$\boxed{\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}}$$

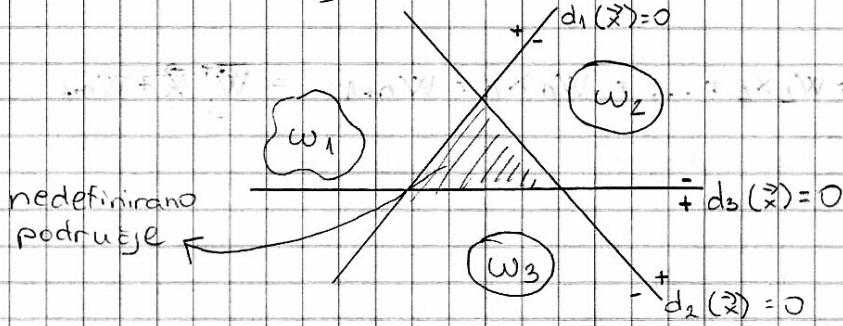
$$\boxed{D_x = |\vec{u}^T \vec{p} - \vec{u}^T(\vec{x})|}$$

orientacija
hiperravnine

udaljenost točke
 \vec{x} od hiperravnine

Separabilnost vrć razreda

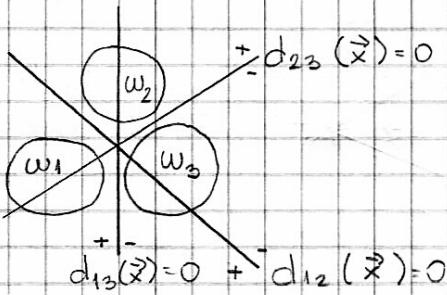
- ① Svaki je razred uzoraka separabilan od ostalih razreda jednom decizijском ravninom



Broj linearnih f-jai
c

$$d_i(\vec{x}) = \vec{w}_i^T \vec{x} = \begin{cases} > 0 & \text{ako } \vec{x} \in w_i \\ < 0 & \text{ako } \vec{x} \notin w_i \end{cases}$$

- ② Svaki razred uzoraka je separabilan sa svakim pojedinim drugim razredom i to jednom decizijском ravninom



Broj linearnih f-jai:
 $\frac{C(C-1)}{2}$

Granica između $w_i : w_j$ zadana je s

$$d_{ij}(\vec{x}) = w_{ij1}x_1 + w_{ij2}x_2 + \dots + w_{ijn}x_n + w_{ijn+1} = 0$$

$d_{ij}(\vec{x}) > 0$ za svaki $j \neq i$
 \vec{x} pripada w_i

- ③ Postoji C decizijskih funkcija sa svojstvom da \vec{x} pripada razredu w_i ako

$$d_i(\vec{x}) > d_j(\vec{x}) \quad \text{za sve } j \neq i$$

Možemo definisati

$$d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (\vec{w}_i - \vec{w}_j)^T \vec{x} = \vec{w}_{ij}^T \vec{x}$$

ako je $d_i(\vec{x}) > d_j(\vec{x})$ za sve $j \neq i$ onda je $d_{ij}(\vec{x}) > 0$ za sve $j \neq i$ tj.

ako su razredi separabili za ③ onda su automatski separabili i za ②

$$d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (w_{i1} - w_{j1})x_1 + (w_{i2} - w_{j2})x_2 + \dots + (w_{in} - w_{jn})x_n + (w_{in+1} - w_{jn+1}) = 0$$

$$\Rightarrow (\vec{w}_i - \vec{w}_j)^T \vec{x} + (w_{in+1} - w_{jn+1}) = 0$$

Kazdrojni vektor

Velikor \vec{w} koji zadovoljava sustav linearnih nejednaciba

$$[\vec{x}] \cdot \vec{w} > 3$$

gdje je

$$\begin{matrix} \vec{x}_{11}, \vec{x}_{12}, \dots \\ \vec{x}_{21}, \vec{x}_{22}, \dots \end{matrix} \in w_1 \quad \begin{matrix} \vec{x}_{11}, \vec{x}_{12}, \dots \\ \vec{x}_{21}, \vec{x}_{22}, \dots \end{matrix} \in w_2$$

dimenzionalnost vektora
povećava se za jedan
(dodaje se 1 na kraj)

$$[\vec{x}] = \begin{bmatrix} \vec{x}_{11} \\ \vec{x}_{12} \\ \vdots \\ \vec{x}_{21} \\ \vec{x}_{22} \\ \vdots \end{bmatrix} \quad \left. \begin{array}{l} \text{uzorci iz } w_2 \\ \text{pomnoženi su} \\ \text{sa } -1 \end{array} \right\}$$

Uzorak je pravilno razvrstan ako za sve \vec{x} iz w_1 i w_2 vrijedi

$$\vec{w}^T \vec{x} > 0$$

gdje su uzorci iz w_2 pomnoženi s -1

Tražimo funkciju koja dostiže minimum kada je ispunjen uvjet

$$\vec{w}^T \vec{x} > 0$$

Gradientni postupak

Korak po korak povećavamo argument \vec{w} u smjeru negativnog gradijenta funkcije $J(\vec{w}, \vec{x})$ dok ne postignemo njen minimum

$$\vec{w}(k+1) = \vec{w}(k) - c \left\{ \frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} \right\}$$

$$\vec{w} = \vec{w}(k)$$

a)

Uzimamo funkciju:
$$J(\vec{w}, \vec{x}) = \frac{1}{2} (\|\vec{w}^T \vec{x}\| - \vec{w}^T \vec{x})$$

$$(|x|) = \operatorname{sgn}(x)$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2} \left[\vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}) - \vec{x} \right]$$

$$\operatorname{sgn}(x) = \begin{cases} 1 & \text{ako } x > 0 \\ -1 & \text{ako } x \leq 0 \end{cases}$$

$$\vec{w}(k+1) = \vec{w}(k) - c \cdot \frac{\partial J}{\partial \vec{w}} = \vec{w}(k) + \frac{c}{2} \left[\vec{x}(k) - \vec{x}(k) \operatorname{sgn}(\vec{w}^T(k) \vec{x}(k)) \right]$$

$$\vec{w}(k+1) = \vec{w}(k) + \frac{c}{2} \cdot \begin{cases} 0 & \text{ako } \vec{w}^T(k) \vec{x}(k) > 0 \\ 2 \vec{x}(k) & \text{ako } \vec{w}^T(k) \vec{x}(k) \leq 0 \end{cases}$$

$$\vec{w}(k+1) = \vec{w}(k) + c \cdot \begin{cases} 0 & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) > 0 \\ \vec{x}(k) & \text{ako } \vec{w}^T(k) \cdot \vec{x}(k) \leq 0 \end{cases}$$

b)

Uzimamo funkciju:

$$J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}|^2 - |\vec{w}^T \vec{x}| \cdot |\vec{w}^T \vec{x}|)$$

$$\begin{aligned}\frac{\partial J}{\partial \vec{w}} &= \frac{1}{4\vec{x}^T \vec{x}} \left[2 \cdot |\vec{w}^T \vec{x}| \cdot \text{sgn}(\vec{w}^T \vec{x}) \cdot \vec{x} - \text{sgn}(\vec{w}^T \vec{x}) \cdot \vec{x} \cdot \vec{w}^T \vec{x} - |\vec{w}^T \vec{x}| \cdot \vec{x} \right] \\ &= \frac{1}{4\vec{x}^T \vec{x}} \left[2 |\vec{w}^T \vec{x}| \cdot \vec{x} \cdot \text{sgn}(\vec{w}^T \vec{x}) - |\vec{w}^T \vec{x}| \cdot \vec{x} - |\vec{w}^T \vec{x}| \cdot \vec{x} \right] \\ &= \frac{1}{4\vec{x}^T \vec{x}} \left[2 |\vec{w}^T \vec{x}| \cdot \vec{x} \cdot \text{sgn}(\vec{w}^T \vec{x}) - 2 |\vec{w}^T \vec{x}| \cdot \vec{x} \right] \\ &= \frac{1}{2\vec{x}^T \vec{x}} \left[|\vec{w}^T \vec{x}| \cdot \vec{x} (\text{sgn}(\vec{w}^T \vec{x}) - 1) \right] \\ &= \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \left[\vec{x} (\text{sgn}(\vec{w}^T \vec{x}) - 1) \right] = \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \cdot \begin{cases} 0 \text{ ako } \vec{w}^T \vec{x} > 0 \\ -2\vec{x} \text{ ako } \vec{w}^T \vec{x} \leq 0 \end{cases}\end{aligned}$$

$$\vec{w}(k+1) = \vec{w}(k) - \lambda \frac{\partial J}{\partial \vec{w}} = \vec{w}(k) - \lambda \cdot \frac{|\vec{w}^T \vec{x}|}{2\vec{x}^T \vec{x}} \cdot \begin{cases} 0 \text{ ako } \vec{w}^T \vec{x} > 0 \\ -2\vec{x} \text{ ako } \vec{w}^T \vec{x} \leq 0 \end{cases} =$$

$$\vec{w}(k+1) = \vec{w}(k) + \lambda \frac{|\vec{w}^T(k) \cdot \vec{x}(k)|}{\vec{x}^T(k) \cdot \vec{x}(k)} \cdot \begin{cases} \vec{x} & \text{ako } \vec{w}^T(k) \vec{x}(k) > 0 \\ \vec{x}(k) & \text{ako } \vec{w}^T(k) \vec{x}(k) \leq 0 \end{cases}$$

• za $0 < \lambda < 2 \Rightarrow$ postupak učenja konvergira• za $\lambda > 1 \Rightarrow$ uzorak se pravilno razvrstava nakon svake korekcije \vec{w}

Varijacije algoritma perceptron

a) $C = \text{konst.} > 0 \rightarrow$ ALGORITAM SA STALJIM PRIRASTOMb) C izabran tako da je dovoljno velik da jamči da će uzorak biti ispravno klasificiran nakon ugatjanja težinskih faktora \vec{w} - ako je $\vec{w}^T(k) \cdot \vec{x}(k) \leq 0$ izabire se C tako da vrijedi

ALGORITAM

s

APSOULTNOM
KOREKCIJOM

$$\vec{w}^T(k+1) \vec{x}(k) = [\vec{w}(k) + C \vec{x}(k)]^T \vec{x}(k) > 0$$

$$\vec{w}^T(k) \vec{x}(k) + C \vec{x}^T(k) \vec{x}(k) > 0$$

$$C > \frac{|\vec{w}^T(k) \vec{x}(k)|}{\vec{x}^T(k) \vec{x}(k)}$$

C je najmanji cijeli broj veći od

c) C je izabran tako da vrijedi

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k+1)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)| \quad (1)$$

izraz $\vec{x}(k+1) = \vec{x}(k) + c\vec{x}(k)$ tj. $\vec{w}^T(k+1) = \vec{w}^T(k) + c\vec{x}^T(k)$ uvrstimo u (1)

ALGORITAM

s

DJELOMIČNOM
KOREKCIJOM

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k)\vec{x}(k) - c\vec{x}^T(k)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

$$|c\vec{x}^T(k)\vec{x}(k)| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

$$c |\underbrace{\vec{x}^T(k)\vec{x}(k)}_{\text{kadrirajuje je pozitivno}}| = \eta |\vec{w}^T(k)\vec{x}(k)|$$

$$c = \eta \frac{|\vec{w}^T(k)\vec{x}(k)|}{\vec{x}^T(k)\vec{x}(k)}$$

PERCEPTRON - klasifikator uzorka u dva razreda - ako su razredi linearno separabilni

Perceptron za $M > 2$

M = broj razreda

PRAVILO - uzorak se svrstava u razred w_i akko

$$R_i > R_j \text{ za sve } i \neq j$$

$$\text{gdje je } R = \vec{w}^T \cdot \vec{x}$$

Algoritam perceptrona

1) Ako $\vec{x}(k) \in \omega_1$ i $\vec{w}^T(k)\vec{x}(k) \leq 0$

zamjeni $\vec{w}(k)$ sa $\vec{w}(k+1) = \vec{w}(k) + c\vec{x}(k)$.

2) Ako $\vec{x}(k) \in \omega_2$ i $\vec{w}^T(k)\vec{x}(k) > 0$

zamjeni $\vec{w}(k)$ sa $\vec{w}(k+1) = \vec{w}(k) - c\vec{x}(k)$

3) Inače $\vec{w}(k+1) = \vec{w}(k)$

$c \rightarrow$ korekcijski faktor, mora biti pozitivan

$\vec{w}(1) \rightarrow$ početna vrijednost vektora težinskih koeficijenata - proizvoljno izabrana

RJEŠENJE - dobiva se kada se posavi iteracija bez pogresaka tj. iteracija u kojoj za sve uzorke vrijedi 3)

Ho-Kashyap algoritam (LMSE - Last Mean Square Error)

- Traži se vektor \vec{w} tako da vrijedi

$$[\mathbf{x}] \vec{w} = \vec{b}$$

\vec{b} - vektor kojemu su sve komponente pozitivne

Kriterijska funkcija:

$$J(\vec{w}, \vec{x}, \vec{b}) = \frac{1}{2} \sum_{j=1}^N (\vec{w}^\top \vec{x}_j - b_j)^2 = \frac{1}{2} \| [\mathbf{x}] \vec{w} - \vec{b} \|^2$$

veličina vektora $[\mathbf{x}] \vec{w} - \vec{b}$

Gradijenti:

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2} \cdot [\mathbf{x}]^\top \cdot 2([\mathbf{x}] \vec{w} - \vec{b}) = [\mathbf{x}]^\top ([\mathbf{x}] \vec{w} - \vec{b})$$

$$\frac{\partial J}{\partial \vec{b}} = \frac{1}{2} \cdot (-1) \cdot 2([\mathbf{x}] \vec{w} - \vec{b}) = -([\mathbf{x}] \vec{w} - \vec{b})$$

- Posto se umjesto uvjeta $[\mathbf{x}] \vec{w} > \vec{b}$ koristi $[\mathbf{x}] \vec{w} = \vec{b}$, to znači da \vec{w} nije ograničen; možemo uzeti $\frac{\partial J}{\partial \vec{w}} = \vec{0}$

$$\frac{\partial J}{\partial \vec{w}} = \vec{0}$$

$$[\mathbf{x}]^\top ([\mathbf{x}] \vec{w} - \vec{b}) = \vec{0}$$

$$[\mathbf{x}]^\top [\mathbf{x}] \vec{w} - [\mathbf{x}]^\top \vec{b} = \vec{0}$$

$$[\mathbf{x}]^\top [\mathbf{x}] \vec{w} = [\mathbf{x}]^\top \vec{b} / \cdot ([\mathbf{x}]^\top [\mathbf{x}])^{-1}$$

$$\vec{w} = ([\mathbf{x}]^\top [\mathbf{x}])^{-1} [\mathbf{x}]^\top \vec{b}$$

$$[\mathbf{x}]^{\#} = ([\mathbf{x}]^\top [\mathbf{x}])^{-1} [\mathbf{x}]^\top \rightarrow \text{generalizirani inverz od } [\mathbf{x}]$$

$$\vec{w} = [\mathbf{x}]^{\#} \vec{b} \quad (1)$$

- Vektor \vec{b} se mijenja tako da unjeti vrijedi $b_i > 0$ za $i = 0, 1, 2, \dots, N$

$$\vec{b}(k+1) = \vec{b}(k) + \gamma \vec{b}(k) \quad (2)$$

$$\gamma b_i(k) = \begin{cases} 2c ([\mathbf{x}] \vec{w}(k) - b(k))_i & \text{ako } ([\mathbf{x}] \vec{w}(k) - b(k))_i > 0 \\ 0 & \text{ako } ([\mathbf{x}] \vec{w}(k) - b(k))_i \leq 0 \end{cases}$$

$$\vec{e}(k) = [\mathbf{x}] \vec{w}(k) - \vec{b}(k) \Rightarrow \gamma \vec{b}(k) = c (\vec{e}(k) + |\vec{e}(k)|)$$

(2) se uvrštava u (1)

$$\begin{aligned}\vec{w}(k+1) &= [x]^{\#} \vec{b}(k+1) \\ &= [x]^{\#} (\vec{b}(k) + \delta \vec{b}(k)) \\ &= \underbrace{[x]^{\#} \vec{b}(k)}_{\vec{w}(k)} + [x]^{\#} \delta \vec{b}(k) \\ &= \vec{w}(k) + [x]^{\#} \cdot c (\vec{e}(k) + |\vec{e}(k)|)\end{aligned}$$

$$\vec{w}(k+1) = \vec{w}(k) + c [x]^{\#} (\vec{e}(k) + |\vec{e}(k)|)$$

$$\vec{b}(k+1) = \vec{b}(k) + c (\vec{e}(k) + |\vec{e}(k)|)$$

Pravilo - ako su u bilo kojoj iteraciji sve komponente vektora

$\vec{e}(k) < 0$ razredi nisu linearne separabilni

- kada je $\vec{e}(k) = \vec{0}$ znači da vrijedi $[x]^{\#} \vec{w}(k) = \vec{b}(k)$
pa je $\vec{w}(k)$ RJEŠENJE.

Poopćeni algoritam perceptronu za M razreda

- istodobno se određuje M težinskih koeficijenata: $\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M$
- računa se M decizijskih funkcija

$$d_j(\vec{x}(k)) = \vec{w}_j^T(k) \vec{x}(k) \quad \text{za } j=1, 2, \dots, M$$

Pravilo: Ako

$$d_i(\vec{x}(k)) > d_j(\vec{x}(k)) \quad \text{za } j=1, 2, \dots, M$$

$$\text{ONDA } \vec{w}_j(k+1) = \vec{w}_j(k) \quad \text{za } j=1, 2, \dots, M$$

Ako

$$d_i(\vec{x}(k)) \leq d_e(\vec{x}(k))$$

ONDA

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c \vec{x}(k)$$

$$\vec{w}_e(k+1) = \vec{w}_e(k) - c \vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k) \quad \text{za } j=1, 2, \dots, M, j \neq i, j \neq e$$

- Postupak konvergira u koničnom broju ponavljanja ako su razredi linearne separabilni

FISHEROVA LINEARNA DISKRIMINANTA

- d-dimenzionalan vektor značajki \vec{x} reducira se na jednu dimenziju

$$\mathbb{R}^d \rightarrow \mathbb{R}^1$$

- ZADATAK - naći orijentaciju pravca na koji će projiciraju

d-dimenzionalni uzorci, ali tako da su projicirani uzoriči separabilni

$$n = \text{broj uzoraka} = n_1 + n_2 \quad \begin{matrix} \rightarrow \text{broj uzoraka razreda } w_1 \\ \rightarrow \text{broj uzoraka razreda } w_2 \end{matrix}$$

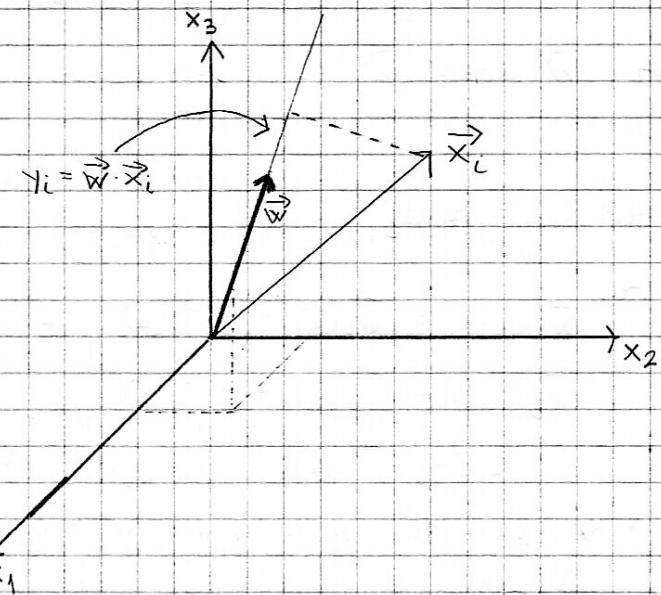
$$\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n \text{ - d-dimenzionalni uzorci}$$

$$y_i = \vec{w}^T \vec{x}_i \quad i=1,2,\dots,n$$

\hookrightarrow linearna kombinacija komponenti \vec{x}

$$\begin{matrix} D_1, D_2 \\ \downarrow \\ \text{d-dimenzionalno} \end{matrix} \longrightarrow \begin{matrix} y_1, y_2 \\ \downarrow \\ \text{jednodimenzionalno} \end{matrix}$$

ako $\|\vec{w}\| = 1 \rightarrow$ svaki y_i je projekcija odgovarajućeg \vec{x}_i na pravac u smjeru \vec{w}



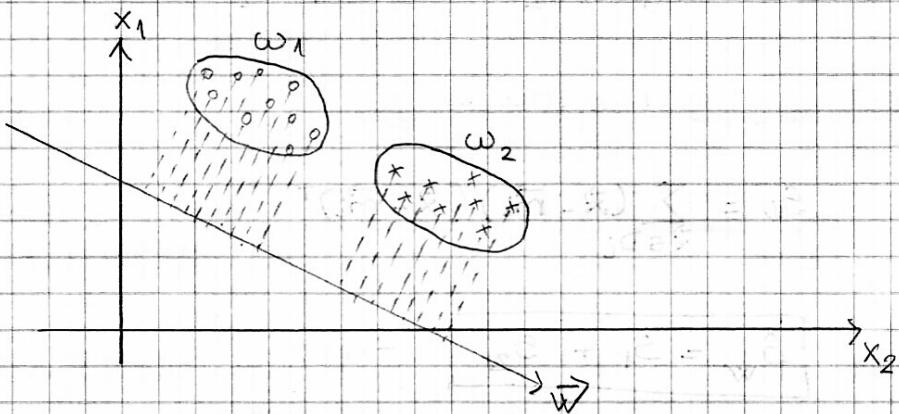
Cilj - naci najbolji smjer od \vec{w}

MJERA ODNOŠIVOSTI

izmedu projiciranih uzoraka je razlika srednjih vrijednosti projiciranih uzoraka

$$\vec{m}_i = \frac{1}{n_i} \sum_{x \in D_i} \vec{x} ; i=1,2 \rightarrow \text{srednja vrijednost uzoraka svakog razreda u } d\text{-dimenzionalnom prostoru}$$

$$\tilde{m}_i = \frac{1}{n_i} \sum_{y \in Y_i} y ; i=1,2 \rightarrow \text{srednja vrijednost projiciranih uzoraka}$$



$$\tilde{m}_i = \frac{1}{n_i} \sum_{y \in Y_i} y = \frac{1}{n_i} \sum_{x \in D_i} \vec{w}^T \vec{x} = \vec{w}^T \left[\frac{1}{n_i} \sum_{x \in D_i} \vec{x} \right] = \vec{w}^T \vec{m}_i$$

\tilde{m}_i je projekcija vektora \vec{m}_i

Razlika srednjih vrijednosti projiciranih uzoraka

$$|\tilde{m}_1 - \tilde{m}_2| = |\vec{w}^T \vec{m}_1 - \vec{w}^T \vec{m}_2| = |\vec{w}^T (\vec{m}_1 - \vec{m}_2)|$$

skaliranjem \vec{w} razliku činimo proizvoljno velikom

Kriterijska funkcija:

$$J(\vec{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\sigma_1^2 + \sigma_2^2} \rightarrow \text{razlika sr. vrijednosti}$$

\rightarrow varijanca uzorka unutar razreda

- Za dobro odvajanje projiciranih uzoraka udaljenost izmedu srednjih vrijednosti projiciranih točaka mора biti relativno velika u odnosu na standardnu devijaciju svakog razreda

Linearna funkcija $\vec{w}^T \vec{x}$ za koju je kriterijska funkcija $J(\vec{w})$

MAKSIMALNA roditi najboljem razdvajaju izmedu projiciranih skupova

- Umjesto varijanci \hat{s}_i^2 raspršenost unutar razreda definiramo

kao

$$\hat{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{m}_i)^2$$

$$\frac{1}{n} (\hat{s}_1^2 + \hat{s}_2^2) \rightarrow \text{procjena varijance podataka}$$

mjera raspršenosti
projiciranih podataka
unutar razreda

$$J(\vec{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\sigma_1^2 + \sigma_2^2} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\hat{s}_1^2 + \hat{s}_2^2}$$

Raspršenost unutar razreda w_i :

$$S_i = \sum_{x \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T \rightarrow \text{matrica raspršenosti unutar razreda } w_i$$

matrica

$$S_w = S_1 + S_2 \rightarrow \text{matrica raspršenosti unutar razreda}$$

$$\begin{aligned} \hat{s}_i^2 &= \sum_{y \in Y_i} (y - \tilde{m}_i)^2 = \left\{ \begin{array}{l} y = \vec{w}^\top \vec{x} \\ \tilde{m}_i = \vec{w}^\top \vec{m}_i \end{array} \right\} \\ &= \sum_{x \in D_i} (\vec{w}^\top \vec{x} - \vec{w}^\top \vec{m}_i)^2 \\ &= \sum_{x \in D_i} (\vec{w}^\top \vec{x} - \vec{w}^\top \vec{m}_i)(\vec{w}^\top \vec{x} - \vec{w}^\top \vec{m}_i)^T \\ &= \sum_{x \in D_i} \vec{w}^\top (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^\top \vec{w} \\ &= \vec{w}^\top \cdot \left[\sum_{x \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^\top \right] \cdot \vec{w} \\ &= \vec{w}^\top S_i \vec{w} \end{aligned}$$

$$\hat{s}_i^2 = \vec{w}^\top S_i \vec{w}$$

$$\hat{s}_1^2 + \hat{s}_2^2 = \vec{w}^\top S_1 \vec{w} + \vec{w}^\top S_2 \vec{w} = \vec{w}^\top (S_1 + S_2) \vec{w} = \vec{w}^\top S_w \vec{w}$$

$$\hat{s}_1^2 + \hat{s}_2^2 = \vec{w}^\top S_w \vec{w}$$

$$\begin{aligned}
 (\hat{\vec{m}}_1 - \hat{\vec{m}}_2)^2 &= (\vec{w}^\top \vec{m}_1 - \vec{w}^\top \vec{m}_2)^2 \\
 &= (\vec{w}^\top \vec{m}_1 - \vec{w}^\top \vec{m}_2)(\vec{w}^\top \vec{m}_1 - \vec{w}^\top \vec{m}_2)^\top \\
 &= (\vec{w}^\top \vec{m}_1 - \vec{w}^\top \vec{m}_2)(\vec{m}_1^\top \vec{w} - \vec{m}_2^\top \vec{w}) \\
 &= \vec{w}^\top (\vec{m}_1 - \vec{m}_2) \underbrace{(\vec{m}_1 - \vec{m}_2)^\top}_{S_B} \vec{w} \\
 &= \vec{w}^\top S_B \vec{w}
 \end{aligned}$$

$$S_B = (\vec{m}_1 - \vec{m}_2)(\vec{m}_1 - \vec{m}_2)^\top$$

$$(\vec{m}_1 - \vec{m}_2)^2 = \vec{w}^\top S_B \vec{w}$$

$$J(\vec{w}) = \frac{\vec{w}^\top S_B \vec{w}}{\vec{w}^\top S_w \vec{w}}$$

$$\left(\frac{a}{b}\right)^2 = \frac{ba' - ab'}{b^2}$$

Traži se maksimum funkcije $J(\vec{w})$

$$\frac{\partial J}{\partial \vec{w}} = 0$$

$$\begin{aligned}
 \frac{\partial J(\vec{w})}{\partial \vec{w}} &= \frac{(\vec{w}^\top S_w \vec{w})(\vec{w}^\top S_B \vec{w})' - (\vec{w}^\top S_B \vec{w})(\vec{w}^\top S_w \vec{w})'}{(\vec{w}^\top S_w \vec{w})^2} \\
 &= \frac{(\vec{w}^\top S_w \vec{w}) \cdot 2S_B \vec{w} - (\vec{w}^\top S_B \vec{w}) \cdot 2S_w \vec{w}}{(\vec{w}^\top S_w \vec{w})(\vec{w}^\top S_w \vec{w})^\top} = 0
 \end{aligned}$$

$$(\vec{w}^\top S_w \vec{w}) \cdot 2S_B \vec{w} - (\vec{w}^\top S_B \vec{w}) \cdot 2S_w \vec{w} = 0 \quad | : 2$$

$$(\vec{w}^\top S_w \vec{w}) \cdot S_B \vec{w} = (\vec{w}^\top S_B \vec{w}) \cdot S_w \vec{w} \quad | \cdot (\vec{w}^\top S_w \vec{w})^{-1}$$

$$S_B \vec{w} = \underbrace{(\vec{w}^\top S_B \vec{w})}_{\text{skalar}} \underbrace{(\vec{w}^\top S_w \vec{w})^{-1} S_w \vec{w}}$$

$$\eta = (\vec{w}^\top S_B \vec{w}) (\vec{w}^\top S_w \vec{w})^{-1}$$

$$S_B \hat{\vec{w}} = \eta S_w \hat{\vec{w}} \rightarrow \text{generalizirani problem s ugovorenim vektorom}$$

Ako S_w^{-1} postoji onda je smjer $\hat{\vec{w}}$ -a

$$\hat{\vec{w}} = (S_w^{-1} S_B) \vec{w}$$

Pošto je $S_B \cdot \vec{w}$ uvijek usmjeren ka $(\vec{m}_1 - \vec{m}_2)$, a faktor skaliranja za \vec{w} ne zanima nego samo smjer, onda pišemo

$$\hat{\vec{w}} = S_w^{-1} (\vec{m}_1 - \vec{m}_2) \rightarrow \hat{\vec{w}} \text{ maksimizira omjer rasprešenja između razreda i rasprešenja unutar razreda}$$

Višestruka FLD → generalizirana FLD

C - broj razreda

Postoji $(c-1)$ diskriminantnih funkcija

Cilj: Projekcija d-dimenzionalnog prostora u $(c-1)$ -dimenzionalni
 $d \gg c$

$$S_W = \sum_{i=1}^c S_i \quad \rightarrow \text{generalizirana matrica raspršenosti uнутар разреда}$$

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T$$

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{x} \in D_i} \vec{x} \quad | \cdot n_i$$

$$n_i \vec{m}_i = \sum_{\vec{x} \in D_i} \vec{x}$$

$$\vec{m} = \frac{1}{n} \sum_{\vec{x}} \vec{x} = \frac{1}{n} \sum_{i=1}^c \sum_{\vec{x} \in D_i} \vec{x} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

$$\vec{m} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

$$\begin{aligned} S_T &= \sum_{\vec{x}} (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})^T \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} [(\vec{x} - \vec{m}_i) + (\vec{m}_i - \vec{m})] [(\vec{x} - \vec{m}_i)^T + (\vec{m}_i - \vec{m})^T] \\ &= \sum_{i=1}^c \sum_{\vec{x} \in D_i} [(\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T + (\vec{x} - \vec{m}_i)(\vec{m}_i - \vec{m})^T + (\vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i)^T + (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T] \end{aligned}$$

$$\begin{aligned} &= \underbrace{\sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T}_{S_W} + \underbrace{\sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T}_{S_B} \\ &= S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T \sum_{\vec{x} \in D_i} 1 \end{aligned}$$

$$S_T = S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

Drugi član je

$$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

→ generalizirana matica raspršenosti između razreda

$$S_T = S_W + S_B$$

Projekcija iz d-dimenz. prostora u (c-1)-dimenz. uz (c-1) diskriminantnih funkcija:

$$y_i = \vec{w}_i^T \vec{x} \quad ; \quad i=1, 2, \dots, c-1$$

\vec{y} → vektor čije su komponente y_i

W → matica dimenzija $d \times (c-1)$
→ stupci su joj vektori \vec{w}_i

$$\vec{y} = W^T \vec{x}$$

Uzorci $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$ projiciraju se u $\vec{y}_1, \vec{y}_2, \dots, \vec{y}_n$ čiji vektori srednjih vrijednosti i matica raspršenosti iznose:

$$\tilde{m}_i = \frac{1}{n_i} \sum_{\vec{y} \in y_i} \vec{y} \quad \Rightarrow \quad n_i \tilde{m}_i = \sum_{\vec{y} \in y_i} \vec{y}$$

$$\tilde{m} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{m}_i$$

$$\tilde{m} = \frac{1}{n} \sum_{\vec{y}} \vec{y} = \frac{1}{n} \sum_{i=1}^c \sum_{\vec{y} \in y_i} \vec{y} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{m}_i$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in y_i} (\vec{y} - \tilde{m}_i)(\vec{y} - \tilde{m}_i)^T$$

$$= \sum_{i=1}^c \sum_{\vec{x} \in D_i} (W^T \vec{x} - W^T \tilde{m}_i)(W^T \vec{x} - W^T \tilde{m}_i)^T$$

$$= \left(\sum_{i=1}^c \sum_{\vec{x} \in D_i} W^T (\vec{x} - \tilde{m}_i)(\vec{x} - \tilde{m}_i)^T \right) W$$

$$= W^T S_W W$$

$$\tilde{S}_W = W^T S_W W$$

$$\begin{aligned}
 \tilde{S}_B &= \sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} (\tilde{\vec{m}}_i - \tilde{\vec{m}})(\tilde{\vec{m}}_i - \tilde{\vec{m}})^T \\
 &= \sum_{i=1}^c (\tilde{\vec{m}}_i - \tilde{\vec{m}})(\tilde{\vec{m}}_i - \tilde{\vec{m}})^T \sum_{\vec{y} \in \mathcal{Y}_i} 1 \\
 &= \sum_{i=1}^c n_i (\tilde{\vec{m}}_i - \tilde{\vec{m}})(\tilde{\vec{m}}_i - \tilde{\vec{m}})^T \\
 &= \sum_{i=1}^c n_i (\vec{w}^T \tilde{\vec{m}}_i - \vec{w}^T \tilde{\vec{m}})(\vec{w}^T \tilde{\vec{m}}_i - \vec{w}^T \tilde{\vec{m}})^T \\
 &= \sum_{i=1}^c n_i \cdot \vec{w}^T (\tilde{\vec{m}}_i - \tilde{\vec{m}})(\tilde{\vec{m}}_i - \tilde{\vec{m}})^T \cdot \vec{w} \\
 &= \sum_{i=1}^c \vec{w}^T \cdot n_i (\tilde{\vec{m}}_i - \tilde{\vec{m}})(\tilde{\vec{m}}_i - \tilde{\vec{m}})^T \cdot \vec{w} \\
 &= \vec{w}^T S_B \vec{w}
 \end{aligned}$$

$$\boxed{\tilde{S}_B = \vec{w}^T S_B \vec{w}}$$

Cilj: Naći matricu \vec{w} koja maksimizira omjer $\tilde{S}_B / \tilde{S}_W$

- jednostarna skalarna mjeru raspršenosti je DETERMINANTA

$$J(\vec{w}) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|\vec{w}^T S_B \vec{w}|}{|\vec{w}^T S_W \vec{w}|}$$

Stupci optimalne matrice \vec{w} su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i$$

Traže se svojstvene vrijednosti kao konjeni karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

Zatim se traže svojstveni vektori rješavanjem

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

METODE ISPITIVANJA

1) Holdout metoda

Skup uzoraka s poznatom klasifikacijom dijeli se na:

- Skup uzoraka za učenje = S_u
- Skup uzoraka za ispitivanje = S_i

NEDOSTACI - smanjene skupova za učenje i ispitivanje
- kako pravilno razdijeliti skupove?

2) Leave - One - Out metoda

- Učenje se obavlja na $N-1$ uzoraka a ispitivanje na onom preostalom
- Ovisno je li preostali uzorak točno ili netočno klasificiran povećava se brojilo točnosti ili pogreške
- Postupak se ponavlja N puta tako da je struki put za ispitivanje koristen drugi uzorak

NEDOSTATAK - velika računska složenost

3) Resubstitution metoda (metoda ponarne zamjene)

- isti skup se koristi prvo za učenje pa za ispitivanje
- OPTIMISTIČKA procjena vjerojatnosti klasifikatora

ANALIZA DANIŠTA

ANALIZA DANIŠTA

SVM - SUPPORT VECTOR MACHINES

(strojevi s potpornim vektorima)

Cilj: Konstrukcija decizijske hiperravnine ali tako da margin odvajanja između pozitivne i negativne skupine uzoraka bude **MAKSIMALNA**

Skup uzoraka za učenje: \rightarrow broj primjera

$$\{(\vec{x}_i, d_i)\}_{i=1}^N$$

↓ ↓
 ulazni vektor željeni odgovor
 uzorka za i -ti primjer klasifikatora

za $w_1 \rightarrow d_i = +1$

$w_2 \rightarrow d_i = -1$

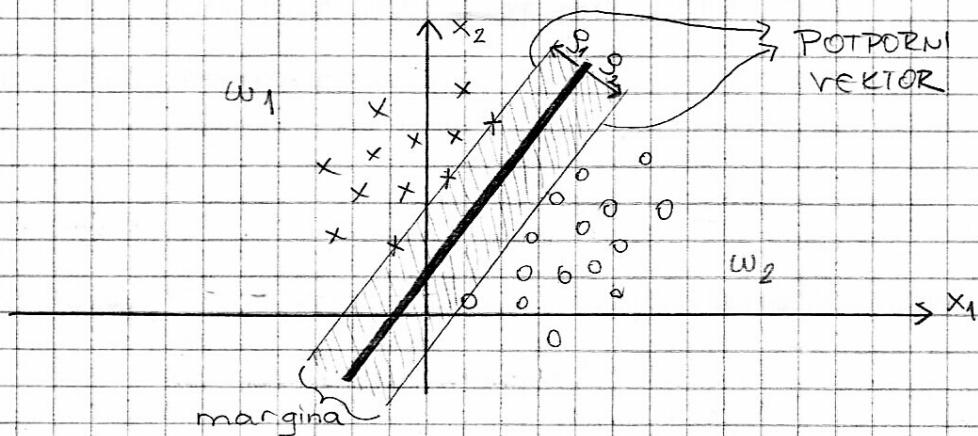
Jednadžba decizijske ravnine:

$$\vec{w}^T \vec{x} + b = 0$$

↓ ↓ ↓
 vektor težinskih ulazni pomaknuće
 koeficijenata vektor (w₀)

za: $d_i = +1$ vrijedi $\vec{w}^T \vec{x} + b > 0$

$d_i = -1$ vrijedi $\vec{w}^T \vec{x} + b < 0$



MARGINA ODVAJANJA \Rightarrow udaljenost između hiperravnine i najblže točke u n-dimenzionalnom prostoru

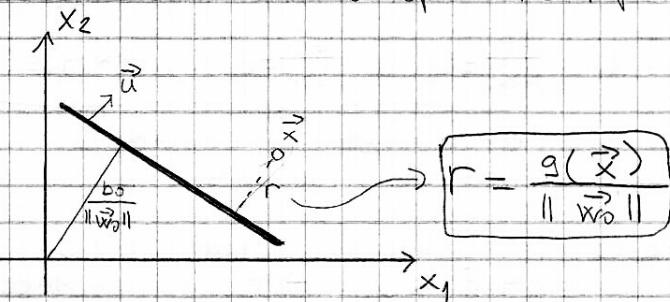
OPTIMALNA RAVNINA - hiperravnina za koju je margina odvajanja maksimalna

\vec{w}_0, b_0 - optimalne vrijednosti \vec{w} i b

$\vec{w}_0^T \vec{x} + b_0 = 0 \rightarrow$ optimalna hiperpravina

$$g(\vec{x}) = \vec{w}_0^T \vec{x} + b_0 \rightarrow \text{decizijska funkcija}$$

- daje mjeru udaljenosti \vec{x} -a od optimalne hiperpravine



Par (\vec{w}_0, b_0) mora zadovoljiti (ako su uzorci lin. odvojivi)

$$\vec{w}_0^T \vec{x}_i + b_0 \geq 1 \quad \text{za } d_i = +1$$

$$\vec{w}_0^T \vec{x}_i + b_0 \leq -1 \quad \text{za } d_i = -1$$

POTPORNI VEKTORI - uzorci iz skupa za učenje za koje vrijedi

$$\left. \begin{array}{l} \vec{x}^{(s)} \\ \vdots \end{array} \right\} \quad \begin{array}{ll} \vec{w}_0^T \vec{x} + b_0 = 1 & \text{za } d_i = +1 \\ \vec{w}_0^T \vec{x} + b_0 = -1 & \text{za } d_i = -1 \end{array}$$

$$\Rightarrow g(\vec{x}^{(s)}) = \vec{w}_0^T \vec{x}^{(s)} + b_0 = \pm 1 \quad \text{za } d_i = \pm 1$$

$$r = \frac{|g(\vec{x}^{(s)})|}{\|\vec{w}_0\|} = \frac{\pm 1}{\|\vec{w}_0\|} = \begin{cases} 1/\|\vec{w}_0\| & \text{za } d^{(s)} = +1 \\ -1/\|\vec{w}_0\| & \text{za } d^{(s)} = -1 \end{cases}$$

Optimalna vrijednost margine odvajanja

$$\rho = 2r = \frac{2}{\|\vec{w}_0\|}$$

minimiziranjem norme od \vec{w}_0 maksimizira se margina odvajanja

Cilj: Pronaći optimalne vrijednosti koeficijenata \vec{w} i pomaknuće b tako da je zadovoljeno ograničenje

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad i = 1, 2, \dots, N$$

a da pri tomu vektor \vec{w} minimizira KRITERIJSKU FUNKCIJU

$$J(\vec{w}) = \frac{1}{2} \underbrace{\vec{w}^T \vec{w}}_{\vec{w}^T \vec{w} = \|\vec{w}\|^2}$$

Problem optimizacije rješava se Lagrangeovim multiplikatorima:

Određivanje ekstrema funkcije $f(x,y)$ uz uvjet $\varphi(x,y)=0$

$$F = f(x,y) + \lambda \cdot \varphi(x,y)$$

↳ Lagrangeov multiplikator

$$\frac{\partial F}{\partial x} = 0 \quad \frac{\partial F}{\partial y} = 0 \quad \varphi(x,y) = 0$$

ovim sustavom jednadžbi
određuju se x, y i λ

AKO

$$\begin{aligned} d^2 F < 0 &\rightarrow f(x,y) \text{ ima MAKSIMUM} \\ d^2 F > 0 &\rightarrow f(x,y) \text{ ima MINIMUM} \end{aligned}$$

$$d^2 F = \frac{\partial^2 F}{\partial x^2} dx^2 + 2 \frac{\partial^2 F}{\partial x \partial y} dx dy + \frac{\partial^2 F}{\partial y^2} dy^2$$

ODREĐIVANJE OPTIMALNE HIPERPLAVNICE

$$J(\vec{w}) = \frac{1}{2} \vec{w}^T \vec{w}$$

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad ; \quad i=1, 2, \dots, N$$

$$\varphi(\vec{w}, b) = \sum_{i=1}^N (d_i(\vec{w}^T \vec{x}_i + b) - 1)$$

$$J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i [d_i(\vec{w}^T \vec{x}_i + b) - 1] \quad (*)$$

$$\frac{\partial J}{\partial \vec{w}}, \frac{\partial J}{\partial b}, \varphi(\vec{w}, b) = 0$$

$$\begin{aligned} \lambda_i d_i (\vec{w}^T \vec{x}_i + b) - \lambda_i \\ = \lambda_i d_i \vec{w}^T \vec{x}_i + \lambda_i d_i b - \lambda_i \end{aligned}$$

$$1) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \frac{1}{2} \cdot 2 \vec{w} - \sum_{i=1}^N \lambda_i d_i \vec{x}_i = \vec{w} - \sum_{i=1}^N \lambda_i d_i \vec{x}_i = 0$$

$$\boxed{\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i}$$

$$\frac{\partial J(\vec{w}, b, \lambda)}{\partial b} = - \sum_{i=1}^N \lambda_i d_i = 0$$

$$\boxed{\sum_{i=1}^N \lambda_i d_i = 0}$$

**

vrijednosti za koje $J(\vec{w})$ dostize minimum

$$\pi_i [d_i(\vec{w}^T \vec{x}_i + b) - 1] = 0$$

$$\boxed{\pi_i [d_i(\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i = 1, 2, \dots, N}$$

$$\boxed{\pi_i > 0}$$

$$J(\vec{w}, b, \pi) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - \sum_{i=1}^N \pi_i d_i b + \sum_{i=1}^N \pi_i$$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \pi_i d_i \underbrace{\vec{w}^T \vec{x}_i}_{\vec{w} = \sum_{j=1}^N \pi_j d_j \vec{x}_j} - b \sum_{i=1}^N \pi_i d_i + \sum_{i=1}^N \pi_i$$

* * se uvrstava

da bi se dobito
min $J(\vec{w}, \pi)$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \sum_{j=1}^N \pi_i d_i \pi_j d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \boxed{\vec{w}^T \cdot \vec{w} = \left[\sum_{i=1}^N \pi_i d_i \vec{x}_i^T \right] \cdot \left[\sum_{j=1}^N \pi_j d_j \vec{x}_j \right] = \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j}$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \pi_i$$

$$= \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$\boxed{Q(\pi) = J(\vec{w}, b, \pi) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j} = \min_{\vec{w}} J(\vec{w}, \pi)$$

Lagrangeov dualni problem

Optimizacijski zadatak - minimizacija $J(\vec{w})$ uz uvjet $\pi_i(\vec{w}) \geq 0$

Lagrangeova funkcija

$$J(\vec{w}, \pi) = J(\vec{w}) - \sum_{i=1}^N \pi_i \varphi_i(\vec{w})$$

ima maksimum kada je

$$\pi_i = 0 \quad ; \quad i = 1, 2, \dots, N$$

$$\text{ili } \varphi_i(\vec{w}) = 0 \quad ; \quad i = 1, 2, \dots, N$$

$$\text{tj. } \max_n (J(\vec{w}, \pi)) = J(\vec{w})$$

Pa se originalni problem može prikazati kao

$$\min_{\vec{w}} J(\vec{w}) = \min_{\vec{w}} \max_{\pi} J(\vec{w}, \pi) = \max_{\pi} \min_{\vec{w}} J(\vec{w}, \pi)$$

Zadatak se svodi na $\max_{\pi} Q(\pi)$

SVM za M > 2 razreda

- Za svaki od razreda traži se optimalna decizjska funkcija $g_i(\vec{x})$ -

tako da vrijedi $g_i(\vec{x}) > g_j(\vec{x}) \quad \forall j \neq i$

ako je $\vec{x} \in w_i$

ZADATAK - Naći deciziju funkciju $g_i(\vec{x}) = 0$ koja je optimalna hiperplanina koja odvaja razred w_i od svih ostalih:

$$g_i(\vec{x}) > 0 \quad \text{za } \vec{x} \in w_i$$

$$g_i(\vec{x}) < 0 \quad \text{inac}$$

KLASIFIKACIJSKO PRAVILO

Dodijeli \vec{x} u w_i ako

$$i = \arg \max_k \{ g_k(\vec{x}) \}$$

SVM za linearne neodvajive razrede

Cilj: Pronalazak optimalne hiperplane koja minimizira vjerojatnost klasičačke pogreške

Meka merna razdvajanja - merna kod koje za uzorak

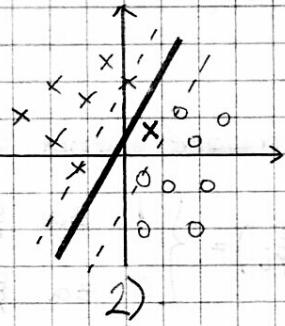
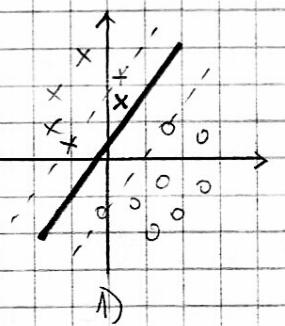
(\vec{x}_i, d_i) NE VRIJEDI

$$d_i \cdot (\vec{w}^\top \vec{x}_i + b) \geq +1$$

Povreda uvjeta $d_i \cdot (\vec{w}^\top \vec{x}_i + b) > +1$ u dva slučaja:

1) uzorak (\vec{x}_i, d_i) pada unutar područja odvajanja ali s prave strane dečijske hiperplane

2) uzorak (\vec{x}_i, d_i) pada unutar područja odvajanja na krivu stranu dečijske hiperplane



Kategorije uzoraka za učenje

1) Uzorci koji padaju izvan marge i ispravno su klasificirani. Za njih vrijedi:

$$d_i \cdot (\vec{w}^\top \vec{x}_i + b) \geq 1 \quad \xi_i = 0$$

2) Uzorci koji padaju unutar marge ali su pravilno razvrstani. Za njih vrijedi:

$$0 < d_i \cdot (\vec{w}^\top \vec{x}_i + b) < 1 \quad 0 < \xi_i \leq 1$$

3) Uzorci koji su pogrešno razvrstani (mogu biti i unutar i izvan marge). Za njih vrijedi:

$$d_i \cdot (\vec{w}^\top \vec{x}_i + b) < 0 \quad \xi_i > 1$$

Jedinstveni oblik: $d_i \cdot (\vec{w}^\top \vec{x}_i + b) \geq 1 - \xi_i$

$\xi_i \rightarrow$ Labava varijabla

- mjeri odstupanja vektora od idealnog uvjeta separabilnosti uzorka

Potporni vektori zadovoljavaju:

$$d_i (\vec{w}^\top \vec{x}_i + b) \geq 1 - \xi_i$$

čak i za slučaj $\xi_i > 0$

Cilj: - Naći dečijsku funkciju za koju je pogreška klasifikacije minimalna tj.

- učiniti marginu što je moguće većom ali uz uvjet da je broj uzoraka sa

$$\xi_i > 0$$

što je moguće manji

$\xi \rightarrow$ vektor s komponentama ξ_i

$$I(\xi_i) = \begin{cases} 1 & \text{za } \xi_i > 0 \\ 0 & \text{za } \xi_i = 0 \end{cases} \rightarrow \begin{array}{l} \text{loš slučaj} \\ \text{dobar slučaj} \end{array}$$

Funkcija koštanjja

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \|\vec{w}\|^2 + C \underbrace{\sum_{i=1}^N I(\xi_i)}_{\text{broj loših slučajeva}}$$

C - pozitivna konstanta kojom se upravlja relativan međumutjeci

$$\frac{1}{2} \|\vec{w}\|^2 + \sum_{i=1}^N I(\xi_i)$$

Optimizacija je teška jer je $I(\xi_i)$ diskontinuirana funkcija pa se koristi nova funkcija "bliska" funkciji koštanjja:

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i$$

Primarni problem za neseparabilne razrede

Za zadani skup uzoraka $\{\vec{x}_i, d_i\}_{i=1}^N$ pronaći optimalne vrijednosti vektora \vec{w} tako da su zadovoljena ograničenja

$$d_i(\vec{w}^\top \vec{x}_i + b) \geq 1 - \xi_i \quad ; \quad i=1, 2, \dots, N$$

$$\text{uz } \xi_i \geq 0$$

te da labave varijable ξ_i minimiziraju funkciju koštaja

$$J(\vec{w}, b, \vec{\xi}) = \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i$$

Uporaba Lagrangeovih množilnika

$$\mathcal{L}(\cdot) = J(\vec{w}, b, \vec{\xi}) - \pi_i \varphi_i(\cdot)$$

$$\begin{aligned} \mathcal{L}(\vec{w}, b, \vec{\xi}, \vec{\pi}) &= \frac{1}{2} \vec{w}^\top \vec{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \pi_i [d_i(\vec{w}^\top \vec{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^N \mu_i \xi_i \\ &= \pi_i [\vec{d}_i \vec{w}^\top \vec{x}_i + d_i b - 1 + \xi_i] \\ &= \pi_i d_i \vec{w}^\top \vec{x}_i + \pi_i d_i b - \pi_i + \pi_i \xi_i \end{aligned}$$

$$\text{Trazimo } \frac{\partial \mathcal{L}}{\partial \vec{w}}, \frac{\partial \mathcal{L}}{\partial b}, \frac{\partial \mathcal{L}}{\partial \vec{\xi}}$$

$$\frac{\partial \mathcal{L}}{\partial \vec{w}} = \frac{1}{2} \cdot 2 \vec{w} - \sum_{i=1}^N \pi_i d_i \vec{x}_i = \vec{w} - \sum_{i=1}^N \pi_i d_i \vec{x}_i = 0$$

$$\boxed{\vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i} \quad i=1, 2, \dots, N$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \pi_i d_i = 0$$

$$\boxed{\sum_{i=1}^N \pi_i d_i = 0} \quad i=1, 2, \dots, N$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C \cdot 1 - \pi_i = \mu_i = C - \pi_i - \mu_i = 0$$

$$\boxed{C - \pi_i - \mu_i = 0} \quad i=1, 2, \dots, N$$

$$\boxed{\pi_i [d_i (\vec{w}^\top \vec{x}_i + b) - 1 + \xi_i] = 0} \quad i=1, 2, \dots, N$$

$$\boxed{\mu_i \xi_i = 0} \quad i=1, 2, \dots, N$$

$$\boxed{\mu_i > 0} \quad \boxed{\pi_i > 0}$$

Novi zadatak:

Maksimizacija

$$\downarrow (\vec{w}, b, \vec{\xi}, \pi_i, \mu_i) = \frac{1}{2} \vec{w}^T \vec{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \pi_i [d_i (\vec{w}^T \vec{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^N \mu_i \xi_i$$

$$= \pi_i [d_i \vec{w}^T \vec{x}_i + d_i b - 1 + \xi_i] = 0$$

$$= \pi_i d_i \vec{w}^T \vec{x}_i + \pi_i d_i b - \pi_i + \pi_i \xi_i$$

uz uvjete

$$1) \quad \vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i$$

$$4) \quad \sum_{i=1}^N \pi_i d_i = 0$$

$$2) \quad C - \mu_i - \pi_i = 0$$

$$5) \quad \mu_i \xi_i = 0$$

$$3) \quad \pi_i \geq 0, \mu_i \geq 0$$

$$\vec{w}^T \vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i^T \cdot \sum_{j=1}^N \pi_j d_j \vec{x}_j^T = \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$\downarrow (\vec{w}, b, \vec{\xi}, \pi_i, \mu_i) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N (\mu_i + \pi_i) \xi_i - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i - \sum_{i=1}^N \pi_i d_i b + \sum_{i=1}^N \pi_i - \sum_{i=1}^N \pi_i \xi_i$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j + \sum_{i=1}^N \mu_i \xi_i + \sum_{i=1}^N \pi_i \xi_i - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i + b \sum_{i=1}^N \pi_i d_i + \sum_{i=1}^N \pi_i - \sum_{i=1}^N \pi_i \xi_i$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j - \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i + \sum_{i=1}^N \pi_i$$

$$= \sum_{i=1}^N \pi_i d_i \vec{w}^T \vec{x}_i = \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$= \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j = Q(\pi)$$

Novi zadatak (Lagrangeov dualni problem)

Traži se maksimum funkcije

$$Q(\pi) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^T \vec{x}_j$$

tj. traži se

$$\max_{\vec{\pi}} Q(\vec{\pi}) = \max_{\vec{\pi}} \left(\sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i d_i \pi_j d_j \vec{x}_i^T \vec{x}_j \right)$$

Labave varijable ξ_i i njihovi množiljatori μ_i ne ulaze izravno u problem nego su prisutni kroz uvjet

$$0 \leq \pi_i \leq C \quad \text{kod lin. sep. je } \pi_i \geq 0$$

Skalarna produktna jezgra za SVM

C4: Pronalažak optimalne hiperravnine za linearno neseparabilne razrede uporabom SVM-a.

KORACI:

- 1) Nelinearno preslikavanje ulaznog vektora u prostor značajki većih dimenzija
- 2) Konstrukcija optimalne hiperravnine za odvajanje vektora značajki dobivenih u 1)

m_0 - dimenzija ulaznog prostora

m_1 - dimenzija prostora značajki većih dimenzija

\vec{x} - vektor iz ulaznog prostora

$\{\varphi_j(\vec{x})\}_{j=1}^{m_1}$ - skup nelinearnih transformacija iz ulaznog prostora u prostor značajki

$$\sum_{j=1}^{m_1} w_j \varphi_j(\vec{x}) + b = 0 \rightarrow \text{DECIZIJSKA RAVNINA}$$

$$\downarrow$$

$$\sum_{j=0}^{m_1} w_j \varphi_j(\vec{x}) = 0 \rightarrow w_0 = b$$

$$\vec{\varphi}(\vec{x}) = [\varphi_0(\vec{x}), \varphi_1(\vec{x}), \dots, \varphi_{m_1}(\vec{x})]^T \rightarrow \text{elika inducirana u prostoru značajki zbog ulaznog vektora } \vec{x}$$

$$\boxed{\vec{w}^T \vec{\varphi}(\vec{x}) = 0}$$

*

U prostoru značajki postoji linearna separabilnost za koju je SVM dao:

$$\vec{w} = \sum_{i=1}^N \pi_i d_i \vec{x}_i \Rightarrow \boxed{\vec{w} = \sum_{i=1}^N \pi_i d_i \vec{\varphi}(\vec{x}_i)}$$

\vec{w} se uvrištava u *:

$$\vec{w}^T \vec{\varphi}(\vec{x}) = \sum_{i=1}^N \pi_i d_i \underbrace{\vec{\varphi}^T(\vec{x}_i) \cdot \vec{\varphi}(\vec{x})}_{} = 0$$

skalarni produkt
dvaju vektora iz prostora
značajki koji su
inducirani ulaznim
vektorima \vec{x}_i , \vec{x} .

$$\boxed{K(\vec{x}, \vec{x}_i) = \vec{\varphi}^T(\vec{x}) \cdot \vec{\varphi}(\vec{x}_i)} \rightarrow \text{Skalarna produktna jezgra}$$

$$K(\vec{x}, \vec{x}_i) = \sum_{j=0}^{m_1} \varphi_j(\vec{x}) \cdot \varphi_j(\vec{x}_i) \quad \text{za } i=1, 2, \dots, N$$

Optimalna hiperpovršina u prostoru znacajki je stoga zadana s:

$$\sum_{i=1}^N \pi_i d_i K(\vec{x}_i, \vec{x}_i) = 0$$

u izvornom prostoru je nelinearna ali u prostoru znacajki linearna

Premda SVM-u imamo

$$J(\vec{\pi}) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j \vec{x}_i^\top \vec{x}_j$$

pa ista formula u prostoru znacajki iznosi

$$J(\vec{\pi}) = \sum_{i=1}^N \pi_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \pi_i \pi_j d_i d_j K(\vec{x}_i, \vec{x}_j)$$

uz ograničenja

$$\sum_{i=1}^N \pi_i d_i = 0 \quad 0 \leq \pi_i \leq C \quad \text{za } i=1, 2, \dots, N$$

pozitivni parametar

optimalni vektor $\vec{w}_0 = \sum_{i=1}^N \pi_{0,i} d_i \varphi(\vec{x}_i)$

prva komponenta vektora \vec{w}_0 predstavlja optimalno pohraknuće bo

POOPĆENE LINEARNE DECIZIJSKE FUNKCIJE

Poopćeni oblik linearne decizijske funkcije

$$d(\vec{x}) = \sum_{i=1}^{k+1} w_i f_i(\vec{x})$$

$$d(\vec{x}) = w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_k f_k(\vec{x}) + w_{k+1}$$

$$f_{k+1} = 1$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

- linearna funkcija u k-dimenzijском prostoru

$$d(\vec{x}) = \vec{w}^\top \vec{x}^*$$

- "virtualno" linearna

$$\vec{w} = (w_1, w_2, \dots, w_k, w_{k+1})^\top$$

Obavlja se transformacija iz n-dimenzijskog prostora u k-dimenzijski.

Zadatak: Odabrat: $\{f_i(\vec{x})\}_{i=1}^k$ - u obliku polinoma

2 stupnja

$$d(\vec{x}) = \sum_{j=1}^n w_{jj} x_j^2 + \sum_{j=1}^{n-1} \sum_{k=j+1}^n w_{jk} x_j x_k + \sum_{j=1}^n w_j x_j + w_{n+1}$$

$$k = \frac{(n+1)(n+2)}{2}$$

$$n=2 \quad r=3$$

$$\vec{x} = \begin{bmatrix} 2 \\ 4 \end{bmatrix} \rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

r-tog stupnja

$$k = \frac{(n+r)!}{r! n!}$$

$$\begin{array}{l} 1 1 1 \rightarrow x_1^3 \\ 1 1 2 \rightarrow x_1^2 x_2 \\ 1 2 2 \rightarrow x_1 x_2^2 \\ 2 2 2 \rightarrow x_2^3 \end{array}$$

$$\begin{array}{l} 1 1 - x_1^2 \\ 1 2 - x_1 x_2 \\ 2 2 - x_2^2 \end{array}$$

$$\begin{array}{l} 1 - x_1 \\ 2 - x_2 \end{array}$$

$$\vec{x}^* = \begin{bmatrix} x_1^3 \\ x_1^2 x_2 \\ x_1 x_2^2 \\ x_2^3 \\ x_1^2 \\ x_1 x_2 \\ x_2^2 \\ x_1 \\ x_2 \end{bmatrix}$$

BAYESOVA DECIJJSKA TEORIJA

$P(w_i)$ - a' priori vjerojatnost

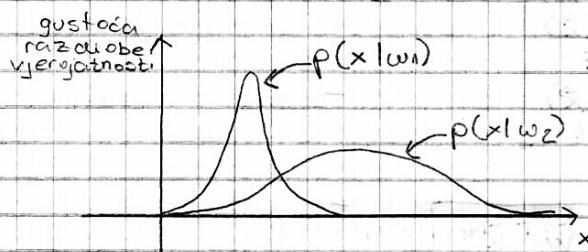
$p(x|w_j)$ - gustoća razdiobe vjerojatnosti

Funkcija gustoće razdiobe vjerojatnosti - funkcija $f(x)$ sa svojstvima:

$$1) f(x) \geq 0, \forall x$$

$$2) \int_{-\infty}^{+\infty} f(x) dx = 1$$

$$3) \int_{x_1}^{x_2} f(x) dx = P\{x_1 < x < x_2\}$$



$$P(w_j|x) = \frac{p(x|w_j) \cdot P(w_j)}{\tilde{p}(x)} \rightarrow \text{BAYESOVO PRAVILA}$$

a' posteriori vjerojatnost

$$\tilde{p}(x) = \sum_{j=1}^N p(x|w_j) P(w_j)$$

Ako $P(w_1|x) > P(w_2|x)$ odabiremo w_1
 Inace w_2

\Rightarrow Bayesovo
decizjsko pravilo

Prepoznavanje

- 1) Upotreba više od jedne znacijke
- 2) Više od dva stanja prirode
- 3) Uvođenje akcije umjesto samo odluke o stanju prirode
- 4) Funkcija gubitka $\pi(x_i|w_j)$

$\pi(x_i|w_j)$ - gubitak nastao poduzimanjem akcije x_i kada je stanje prirode w_j

$$R(x_i|\bar{x}) = \sum_{j=1}^c \pi(x_i|w_j) P(w_j|\bar{x})$$

Očekivani gubitak - nastaje kada poduzmemo akciju x_i a stanje prirode je w_j

Bayesovo decizjsko pravilo

Da bi minimizirali ukupan rizik izračunavamo uvjetni rizik

$$R(x_i | \vec{x}) = \sum_{j=1}^c \pi(x_i | w_j) P(w_j | \vec{x})$$

$\exists i = 1, 2, \dots, a$; tada izabiremo akciju x_i za koju je $R(x_i | \vec{x})$ MINIMUM

M=2

$$\begin{aligned} R(x_1 | \vec{x}) &= \pi(x_1 | w_1) P(w_1 | \vec{x}) + \pi(x_1 | w_2) P(w_2 | \vec{x}) \\ &= \{\pi(x_1 | w_1) = \pi_{11}; \pi(x_1 | w_2) = \pi_{12}\} \\ &= \pi_{11} P(w_1 | \vec{x}) + \pi_{12} P(w_2 | \vec{x}) \end{aligned}$$

$$\begin{aligned} R(x_2 | \vec{x}) &= \pi(x_2 | w_1) P(w_1 | \vec{x}) + \pi(x_2 | w_2) P(w_2 | \vec{x}) \\ &= \pi_{21} P(w_1 | \vec{x}) + \pi_{22} P(w_2 | \vec{x}) \end{aligned}$$

PRAVILO : Odluci se za w_1 . Ako

$$R(x_1 | \vec{x}) < R(x_2 | \vec{x})$$

$$\pi_{11} P(w_1 | \vec{x}) + \pi_{12} P(w_2 | \vec{x}) < \pi_{21} P(w_1 | \vec{x}) + \pi_{22} P(w_2 | \vec{x})$$

$$\pi_{11} P(w_1 | \vec{x}) - \pi_{21} P(w_1 | \vec{x}) < \pi_{22} P(w_2 | \vec{x}) - \pi_{12} P(w_2 | \vec{x})$$

$$(\pi_{11} - \pi_{21}) P(w_1 | \vec{x}) < (\pi_{22} - \pi_{12}) P(w_2 | \vec{x})$$

$$\pi_{11} < \pi_{21}$$

$$\pi_{22} < \pi_{12}$$

$$\pi_{11} - \pi_{21} < 0 \quad | \cdot (-1)$$

$$\pi_{21} - \pi_{11} > 0$$

$$\pi_{22} - \pi_{12} < 0 \quad | \cdot (-1)$$

$$\pi_{12} - \pi_{22} > 0$$

$$\Rightarrow (\pi_{22} - \pi_{12}) P(w_2 | \vec{x}) > (\pi_{11} - \pi_{21}) P(w_1 | \vec{x})$$

$$\frac{(\pi_{22} - \pi_{12}) P(\vec{x} | w_2) P(w_2)}{P(\vec{x})} > \frac{(\pi_{11} - \pi_{21}) P(\vec{x} | w_1) P(w_1)}{P(\vec{x})}$$

$$(\pi_{22} - \pi_{12}) P(\vec{x} | w_2) P(w_2) > (\pi_{11} - \pi_{21}) P(\vec{x} | w_1) P(w_1) \quad | \cdot (-1)$$

$$(\pi_{12} - \pi_{22}) P(\vec{x} | w_2) P(w_2) < (\pi_{21} - \pi_{11}) P(\vec{x} | w_1) P(w_1)$$

$$\boxed{\frac{P(\vec{x} | w_1)}{P(\vec{x} | w_2)} > \frac{(\pi_{12} - \pi_{22}) P(w_2)}{(\pi_{21} - \pi_{11}) P(w_1)}} \rightarrow \text{Omjer vjerojatnosti}$$

ako vrijedi odlučujemo se za w_1

frag rezavisan od \vec{x}

FUNKCIJA GUBITKA - simetrična ili nula-jedan funkcija

$$\pi(x_i | w_j) = \begin{cases} 0 & i=j \\ 1 & i \neq j \end{cases}$$

$$\begin{aligned} R(x_i | \vec{x}) &= \sum_{j=1}^c \pi(x_i | w_j) P(w_j | \vec{x}) \\ &= \sum_{j \neq i} P(w_j | \vec{x}) \\ &= 1 - P(w_i | \vec{x}) \end{aligned}$$

M = C

$g_i(\vec{x})$, $i=1, 2, \dots, c$ → skup diskriminarnih funkcija

Klasifikator razvrstava \vec{x} u w_i ako

$$g_i(\vec{x}) > g_j(\vec{x}) \text{ za sve } j \neq i$$

$$g_i(\vec{x}) = -R(x_i | \vec{x}) \rightarrow \text{za opći slučaj s rizikom}$$

$$g_i(\vec{x}) = P(w_i | \vec{x}) \rightarrow \text{za slučaj minimalne progreske}$$

$$\begin{aligned} g_i(\vec{x}) &= P(w_i | \vec{x}) = \frac{P(\vec{x} | w_i) P(w_i)}{P(\vec{x})} \\ &= P(\vec{x} | w_i) P(w_i) \\ &= \ln P(\vec{x} | w_i) + \ln P(w_i) \end{aligned}$$

$$P(w_i | \vec{x}) - P(w_j | \vec{x}) = 0$$

Decizionska ploha koja u višedimenzionalnom prostoru značajki dijeli područja R_i i R_j

- s jedne strane plohe razlikuje pozitivna a s druge negativna

Klasificiraj \vec{x} u w_i ako $g_i(\vec{x}) > g_j(\vec{x}) \forall j \neq i$

Bayesova klasifikacija za normalne distribucije

$$P(\vec{x} | w_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)\right)$$

$$\vec{\mu}_i = E[\vec{x}] \quad \begin{matrix} \text{(ocekivanje)} \\ \rightarrow \text{srednja vrijednost razreda } w_i \end{matrix}$$

$$\Sigma_i = E[(\vec{x} - \vec{\mu}_i)(\vec{x} - \vec{\mu}_i)^T] \rightarrow \text{kovarijacijska matrica}$$

$\mathcal{N}(\vec{\mu}, \Sigma) \rightarrow \text{Gaussova distribucija}$

$$\begin{aligned} g_i(\vec{x}) &\stackrel{\text{def}}{=} \ln P(w_i | \vec{x}) \\ &= \ln(P(w_i)) + \ln P(\vec{x} | w_i) \\ &= \ln P(w_i) + \ln \rho(\vec{x} | w_i) \\ &= \ln \left[\frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \right] + \ln \left[e^{-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)} \right] + \ln P(w_i) \\ &= \ln 1 - \ln \left[(2\pi)^{d/2} |\Sigma_i|^{1/2} \right] - \frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i) + \ln P(w_i) \\ &= -\ln(2\pi)^{d/2} - \ln |\Sigma_i|^{1/2} - \frac{1}{2} (\vec{x}^T \Sigma_i^{-1} \vec{x} - \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i) + \ln P(w_i) \\ &= -\underbrace{\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i|}_{C_i} - \frac{1}{2} (\vec{x}^T \Sigma_i^{-1} \vec{x} - \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} - \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i + \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i) + \ln P(w_i) \\ &= C_i - \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \ln P(w_i) \end{aligned}$$

$$g_i(\vec{x}) = C_i - \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \ln P(w_i)$$

Pojednostavljenja

- 1) Kovarijacijska matrica ista za sve razrede
- 2) Kovarijacijska matrica je dijagonalna s jednakim elementima

Kovarijacijska matrica ista za sve razrede

$$\Sigma_i = \Sigma$$

$\vec{x}^T \Sigma \vec{x} \rightarrow$ jednak za sve diskriminantne funkcije
 c_i
 \Rightarrow Mogu se ispuštiti

$$g_i(\vec{x}) = \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i + \ln P(\omega_i)$$

$$g_i(\vec{x}) = -\left(\Sigma^{-1} \vec{\mu}_i\right)^T \vec{x} + \left(\ln P(\omega_i) - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i\right)$$

$$\vec{w}_i = \Sigma^{-1} \vec{\mu}_i \quad \vec{w}_{i0} = \ln P(\omega_i) - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i$$

$$g_i(\vec{x}) = \vec{w}_i^T \vec{x} + w_{i0}$$

Kovarijacijska matrica dijagonalna s jednakim elementima

$$\Sigma = \sigma^2 I$$

- značajke koje oblikuju vektor značajki su međusobno nekorelirane i imaju jednaku varijancu

$$E[(x_i - \mu_i)(x_j - \mu_j)] = \sigma^2 \delta_{ij}$$

$$\begin{aligned} g_i(\vec{x}) &= \vec{w}_i^T \vec{x} + w_{i0} \\ &= \Sigma^{-1} \vec{\mu}_i^T \vec{x} + w_{i0} \\ &= \frac{1}{\sigma^2} \vec{\mu}_i^T \vec{x} + w_{i0} \end{aligned}$$

jer je

$$\Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma^2} & & & \\ & \ddots & & \\ & & \frac{1}{\sigma^2} & \\ & & & \ddots \end{bmatrix}$$

$$g_i(\vec{x}) = \frac{1}{\sigma^2} \vec{\mu}_i^T \vec{x} + w_{i0}$$

Decizijaska hiperravnina

$$g_{ij}(\vec{x}) = g_i(\vec{x}) - g_j(\vec{x}) = \vec{w}^T (\vec{x} - \vec{x}_0) = 0$$

$$\vec{w} = \vec{\mu}_i - \vec{\mu}_j$$

$$\vec{x}_0 = \frac{1}{2} (\vec{\mu}_i + \vec{\mu}_j) - \sigma^2 \ln \left(\frac{P(w_i)}{P(w_j)} \right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

AKO $P(w_i) = P(w_j)$ ONDA hiperravnina prolazi kroz točku \vec{x}_0 tj. prolazi srednjom vrijednosti od $\vec{\mu}_i$ i $\vec{\mu}_j$

$$g_{ij}(\vec{x}) = 0 \Rightarrow \vec{w}^T (\vec{x} - \vec{x}_0) = (\underbrace{\vec{\mu}_i - \vec{\mu}_j}_{})^T (\vec{x} - \vec{x}_0) = 0$$

ortogonalan na decizijsku hiperravninu

AKO $P(w_i) < P(w_j)$ ONDA je hiperravnina bliza $\vec{\mu}_i$

AKO je σ^2 mala vrijednost u odnosu na $\|\vec{\mu}_i - \vec{\mu}_j\|$ položaj hiperravnine je neosjetljiv na vrijednost $P(w_i)$, $P(w_j)$

Kovarijacijska matrica nije dijagonalna

$$\vec{x}_0 = \frac{1}{2} (\vec{\mu}_i + \vec{\mu}_j) - \ln \left(\frac{P(w_i)}{P(w_j)} \right) \frac{\vec{\mu}_j - \vec{\mu}_i}{\|\vec{\mu}_i - \vec{\mu}_j\|^2} \quad \text{---}$$

$$\|\vec{x}\| = \sqrt{\vec{x}^T \Sigma^{-1} \vec{x}} \quad \rightarrow \text{norma od } \vec{x}$$

Hiperravnina je ortogonalna na $\Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j)$

Klasifikator na temelju minimalne udaljenosti

Imamo izraz

$$g_i(\vec{x}) = -\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) + \ln p(w_i) + c_i \quad \xrightarrow{\text{zanećaju se}}$$

Pretpostavka \rightarrow svi su razredi jednakog vrijednosti i imaju istu kovarijantnu matricu

Sljедi:

$$g_i(\vec{x}) = -\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i)$$

SLUČAJ $\Sigma = \sigma^2 I$

Maksimum $g_i(\vec{x})$ podrazumijeva MINIMUM od

$$d_e = \|\vec{x} - \vec{\mu}_i\|$$

$\xrightarrow{\text{euklidска udaljenost}}$

- vektor značajki klasificira se u razred u skladu s minimalnom vrijednosti euklidске udaljenosti.

SLUČAJ Σ nije dijagonalna matica

Maksimum $g_i(\vec{x})$ postiže se kad je Σ^{-1} norma minimalna

$$d_m = \left((\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) \right)^{\frac{1}{2}}$$

$\xrightarrow{\text{Mahalanobisova udaljenost}}$

KARHUNEN-LOÈVA TRANSFORMACIJA (PCA)

I. PRISTUP

KL transformacija kao postupak minimizacije srednje kvadratne pogreške približnog zapisa uzorka

$\{\vec{e}_j\}$ → skup orthonormiranih vektora

Uzorak \vec{x} može se zapisati kao

$$\vec{x} = \sum_{j=1}^r c_j \vec{e}_j$$

c_j | $j=1, 2, \dots, r$ → koeficijenti reda

Ako uzorak \vec{x} aproksimiramo pomoću $n < r$ članova reda dobivamo srednju kvadratnu pogrešku

$$\bar{\varepsilon}^2 = E \left\{ \left| \vec{x} - \sum_{j=1}^n c_j \vec{e}_j \right|^2 \right\}$$

E - operator matematičkog očekivanja

$$\begin{aligned} \bar{\varepsilon}^2 &= E \left\{ \left| \vec{x} - \sum_{j=1}^n c_j \vec{e}_j \right|^2 \right\} \\ &= E \left\{ \left| \sum_{j=1}^r c_j \vec{e}_j + \sum_{j=r+1}^n c_j \vec{e}_j \right|^2 \right\} \end{aligned}$$

-uzimamo u obzir ortogonalnost jediničnih vektori:

$$\vec{e}_j^\top \vec{e}_i = \begin{cases} 1, & \text{ako } j=i \\ 0, & \text{ako } j \neq i \end{cases} \quad *$$

Stoga $\bar{\varepsilon}^2 = E \left\{ \left| \sum_{j=n+1}^r c_j \vec{e}_j \right|^2 \right\}$

$$= E \left\{ \sum_{j=n+1}^r c_j^2 \right\} \Rightarrow \bar{\varepsilon}^2 = E \left\{ \sum_{j=n+1}^r c_j^2 \right\}$$

$$\vec{x} - \sum_{j=1}^r c_j \vec{e}_j \perp \vec{e}_j^\top$$

$$\vec{e}_j^\top \vec{x} = \vec{e}_j^\top \vec{e}_j c_j \rightarrow \text{urnštavamo } *$$

$$\vec{e}_j^\top \vec{x} = 1 \cdot c_j$$

$$\boxed{\vec{c}_j = \vec{e}_j^\top \vec{x}}$$

Izraz $C_j = \vec{e}_j^T \vec{x}$ uvrštavamo u $\bar{\epsilon}^2$

$$\bar{\epsilon}^2 = E \left\{ \sum_{j=n+1}^r C_j^2 \right\}$$

$$= E \left\{ \sum_{j=n+1}^r \vec{e}_j^T \vec{x} \vec{e}_j \vec{x}^T \right\} \quad \vec{e}_j \text{ je deterministički pa možemo zamijeniti redoslijed}$$

$$= E \left\{ \sum_{j=n+1}^r \vec{e}_j^T \vec{x} \vec{x}^T \vec{e}_j \right\}$$

$$= \sum_{j=n+1}^r \vec{e}_j^T E \{ \vec{x} \vec{x}^T \} \vec{e}_j$$

$$R = E \{ \vec{x} \vec{x}^T \} \rightarrow \text{korelačka matrica uzorka}$$

$$\boxed{\bar{\epsilon}^2 = \sum_{j=n+1}^r \vec{e}_j^T R \vec{e}_j}$$

Tražimo da srednja kvadratna pogreška bude minimalna tj.

tražimo ortonormalne vektore \vec{e}_j (koordinatni sustav) koji minimiziraju pogrešku

Lagrangeova funkcija:

$$\mathcal{L}(\vec{e}_j) = \sum_{j=n+1}^r \vec{e}_j^T R \vec{e}_j - \sum_{j=n+1}^r \lambda_j (\vec{e}_j^T \vec{e}_j - 1)$$

$$\frac{\partial \mathcal{L}}{\partial \vec{e}_j} = \sum_{j=n+1}^r 2 \vec{e}_j^T R - \sum_{j=n+1}^r \lambda_j \cdot 2 \vec{e}_j$$

$$= \sum_{j=n+1}^r 2 \vec{e}_j^T (R - \lambda_j I) = 0 \quad | : 2$$

$$\Rightarrow (R - \lambda_j I) \vec{e}_j = 0$$

$$R \vec{e}_j = \lambda_j I \vec{e}_j$$

$$\boxed{R \vec{e}_j = \lambda_j \vec{e}_j}$$

KL koordinatne osi: \rightarrow svjestreni vektor korelačke matrice $R = E \{ \vec{x} \vec{x}^T \}$

\hookrightarrow ortonormalni su \rightarrow koeficijenti KL reda su međusobno nekorelirani

$R = E \{ \vec{z} \vec{z}^T \}$ - dijagonalna matrica
 - elementi jednaki svojstvenim vrijednostima
 korelacijske matrice $R = E \{ \vec{x} \vec{x}^T \}$

$$\begin{aligned}\vec{\Sigma}^2 &= \sum_{j=n+1}^r \vec{e}_j^T R \vec{e}_j \\ &= \{ R \vec{e}_j = \lambda_j \vec{e}_j \} \quad \vec{e}_j^T \vec{e}_j = 1 \\ &= \sum_{j=n+1}^r \vec{e}_j^T \lambda_j \vec{e}_j = \sum_{j=n+1}^r \lambda_j\end{aligned}$$

$\vec{\Sigma}^2 = \sum_{j=n+1}^r \lambda_j$

$$A = \begin{bmatrix} \vec{e}_1^T \\ \vec{e}_2^T \\ \vdots \\ \vec{e}_n^T \end{bmatrix} \rightarrow \text{Transformacijska matrica}$$

- sastoji se od prvih n vektora koordinatnih osi \vec{e}_j^T uredenih po padajućem redoslijedu svojstvenih vrijednosti matrice

$\vec{y} = A \cdot \vec{x}$

\rightarrow Vektor uzorka

Raspoznavanje uzorka - umjesto korelacijske matrice R koristi se kovarijacijska matrica K

$$K \vec{e}_j = \lambda_j \vec{e}_j$$

$$K = E \{ (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T \}$$

$\vec{\Sigma}^2 = \sum_{j=n+1}^r E \{ c_j \} \vec{e}_j$

II. PRISTUP

KL transformacija kojom se maksimizira varijanca

- aproksimacija vektora \vec{x} gradi se iz nkr komponenti koje imaju najveću varijancu

- srednja kvadratna pogreška između \vec{x} i aproksimiranog \vec{x}' jednaka je sumi varijanci komponenti koje su eliminirane iz \vec{x}

PRETPOSTAVKA - slučajni vektor \vec{x} ima srednju vrijednost ϕ :

$$E\{\vec{x}\} = \vec{\phi}$$

↳ operator matematičkog očekivanja

- \vec{x} nema srednju vrijednost $\vec{\phi}$? → srednju vrijednost oduzimamo od \vec{x} prije daljnog postupka

\vec{x} - vektor značajki dimenzije r

\vec{e} - jedinični vektor dimenzije r

- Projiciramo \vec{x} na \vec{e}

$$A = \vec{x}^T \vec{e} = \vec{e}^T \vec{x}$$

Ograničenje: $\|\vec{e}\| = (\vec{e}^T \vec{e})^{1/2} = 1$

$$E[A] = E[\vec{e}^T \vec{x}] = \vec{e}^T E[\vec{x}] = 0$$

A → projekcija - slučajna varijabla sa srednjom vrijednosti i varijancom u kojima se zrcali statistika slučajnog vektora \vec{x}

Varijanca od A:

$$\begin{aligned}\sigma^2 &= E[A^2] = E[\vec{e}^T \vec{x} \cdot \vec{e} \vec{x}^T] \\ &= E[(\vec{e}^T \vec{x})(\vec{x}^T \vec{e})] \\ &= \vec{e}^T E[\vec{x} \vec{x}^T] \vec{e} \\ &= \vec{e}^T R \vec{e}\end{aligned}$$

$R^T = R \Rightarrow$ simetrična je

$$\sigma^2 = \vec{e}^T R \vec{e}$$

$$R = E[\vec{x} \vec{x}^T]$$

→ korelacijska matrica
slučajnog vektora \vec{x}

$$\boxed{\Psi(\vec{e}) = \sigma^2 = \vec{e}^T R \vec{e}}$$

CIV - pronaći jedinične vektore \vec{e} užduž kojih $\Psi(\vec{e})$ ima lokalne minimume ili maksimume (ekstreme)

OPTIMIZACIJA - Tražimo max vrijednost uz ograničenje euklidske norme vektora:

$$\boxed{\vec{e}^T \cdot \vec{e} = 1}$$

$$L(\vec{e}) = \vec{e}^T R \vec{e} - \lambda (\vec{e}^T \vec{e} - 1)$$

$$\frac{\partial L}{\partial \vec{e}} = 2 \vec{e}^T R - \lambda \cdot 2 \vec{e} = 2 R \cdot \vec{e} - 2 \lambda \cdot \vec{e} = 0 \quad | : 2$$

$$R \vec{e} - \lambda \vec{e} = 0$$

$$(R - \lambda I) \vec{e} = 0$$

$$\boxed{\downarrow \\ R \vec{e} = \lambda \vec{e}}$$

KLASIFIKACIJA UZORAKA POMOĆU FUNKCIIA UDALJENOSTI

- Djelotvorna metoda kada razredi pokazuju svoštvo GRUPIRANJA

Klasifikacija pomoću najmanje udaljenosti

MJERA UDALJENOSTI - funkcija koja zadovljava uvjete:

$$1) D(\vec{x}_k, \vec{x}_e) = 0 \quad \text{ako } \vec{x}_k = \vec{x}_e$$

$$\begin{aligned} D(\vec{x}_k, \vec{x}_e) &= \phi \\ D(\vec{x}_k, \vec{x}_e) &> 0 \end{aligned} \quad \left. \right\} \text{ako } \vec{x}_k \neq \vec{x}_e$$

$$2) D(\vec{x}_k, \vec{x}_e) = D(\vec{x}_e, \vec{x}_k)$$

$$3) D(\vec{x}_k, \vec{x}_e) \leq D(\vec{x}_k, \vec{x}_j) + D(\vec{x}_j, \vec{x}_e)$$

Euklidска udaljenost

$$D = \|\vec{x}_k - \vec{x}_e\| = \sqrt{\sum_{i=1}^n (x_{ki} - x_{ei})^2}$$

- invarijantna na translaciju i rotaciju

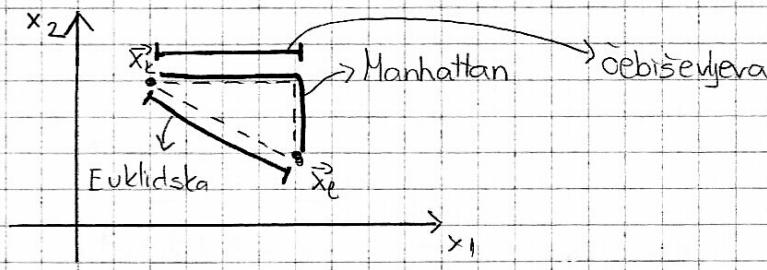
Minkovski udaljenost

$$D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n |x_{kj} - x_{ej}|^s \right)^{\frac{1}{s}}$$

$$\underline{s=1} \quad D(\vec{x}_k, \vec{x}_e) = \sum_{j=1}^n |x_{kj} - x_{ej}| \rightarrow \text{Manhattan ili city-block udaljenost}$$

$$\underline{s=2} \quad D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n |x_{kj} - x_{ej}|^2 \right)^{\frac{1}{2}} \rightarrow \text{Euklidска udaljenost}$$

$$\underline{s=\infty} \quad D(\vec{x}_k, \vec{x}_e) = \max \{ |x_{kj} - x_{ej}| \} \rightarrow \text{Čebiševska udaljenost}$$



Težinska udaljenost Minouskog

$$D(\vec{x}_k, \vec{x}_e) = \left(\sum_{j=1}^n w_j |x_{kj} - x_{ej}|^s \right)^{\frac{1}{s}}$$

$w_j \rightarrow$ težina pojedine značajke

$$w_j > 1$$

Mahalanobisova udaljenost

$$D(\vec{x}_k, \vec{x}_e) = (\vec{x}_k - \vec{x}_e)^T C^{-1} (\vec{x}_k - \vec{x}_e)$$

$C \rightarrow$ kovarijacijska matrica dobivena iz skupa za učenje