

1.3. ŠEST POSTULATA RU

Postulat 1: U cilju prikupljanja informacija

o PU moraju biti raspoloživi reprezentativni uzorci iz M razreda.

Postulat 2: Jednostavan uzorak ima značajke koje karakteriziraju njegovu pripadnost određenom razredu.

Postulat 3: Značajke uzoraka koji pripadaju jednom razredu uzoraka zauzimaju kompaktno područje u prostoru značajki. Područja okupirana značajkama različitih razreda su odvojena.

Postulat 4: Složeni (kompleksni) uzorak sastoji se iz jednostavnijih građevnih komponenti ili segmenata objekata koji se nalaze u izvjesnim odnosima. Uzorak se može sastaviti iz tih komponenti.


S. Ribarić, Prepoznavanje uzoraka

Postulat 5: Složeni uzorak koji pripada
određenom području uporabe ima
određenu strukturu. To implicira
da bilo kakvo uređenje jednostavnih
građevnih elemenata neće dati
uzorak $f_k(\vec{x})$.


Postulat 6: Dva uzorka su si slična
ako je pogodno definirana mjera
udaljenosti u prostoru značajki
mala.

2. MODEL SUSTAVA ZA RASPOZNAVANJE UZORAKA

2.1 FORMALNI MODEL




m - mjerenje



2.2. ZNAČAJKE, VEKTOR ZNAČAJKI I KLASIFIKATOR

Osnovne faze/stupnjevi u postupku oblikovanja sustava RU



značajke - promatramo ih kao slučajne
varijable : x_i

vektor značajki - slučajni vektori \vec{X}

$$\vec{X} = [x_1, x_2, \dots, x_n]^T$$

- značajke koje predstavljaju razlike između razreda uzoraka nazivaju se INTERSET značajke

INTRASET značajke su zajedničke SVIM razredima iz PU (područja uporabe) i ne nose diskriminacijsku informaciju - TAKVE ZNAČAJKE MOGU SE ZANEMARITI

Izbor značajki - izlučiti i izabrati INTERSET značajke

- U većini slučajeva određivanje potpunog skupa diskriminacijskih značajki je iznimno teško ili čak nemoguće;
- Neke diskriminacijske značajke mogu se naći na temelju raspoloživih rezultata mjerenja (senziranja);
- Redukcija dimenzionalnosti vektora značajki uporabom transformacija uz minimalni gubitak informacije;
- Vektor značajki predčen kao točka u n -dimenzionalnom prostoru značajki;
- Obično definiramo i neku vrstu metrike u takvom prostoru značajki;
- Klasifikacija (razvrstavanje) uzorka temelji se na decizijskim funkcijama; PROBLEM: određivanje optimalne decizijske procedure;

- Problem klasifikacije može se promatrati kao razvrstavanje nepoznatog uzorka u potprostor prostora značajki na temelju decizijskih granica koje definiraju te potprostore!

- Decizijske granice određene su decizijskim funkcijama:

$$d_1(\vec{x}), d_2(\vec{x}), \dots, d_M(\vec{x})$$

d_i je funkcija koja ima za argument VEKTOR a vraća SKALAR / VAŽNO!

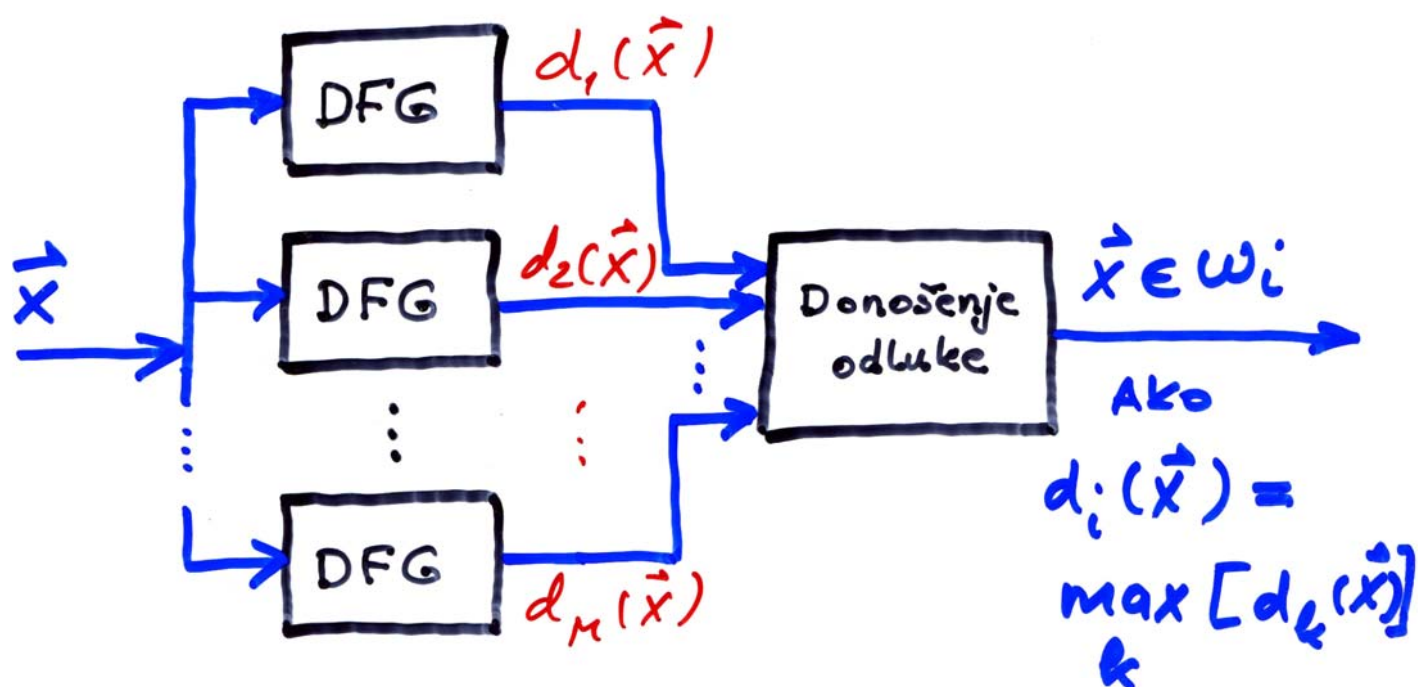
- Pravilo razvrstavanja:

Ako $d_i(\vec{x}) > d_j(\vec{x})$ za

$i, j = 1, 2, \dots, M$ te $j \neq i$

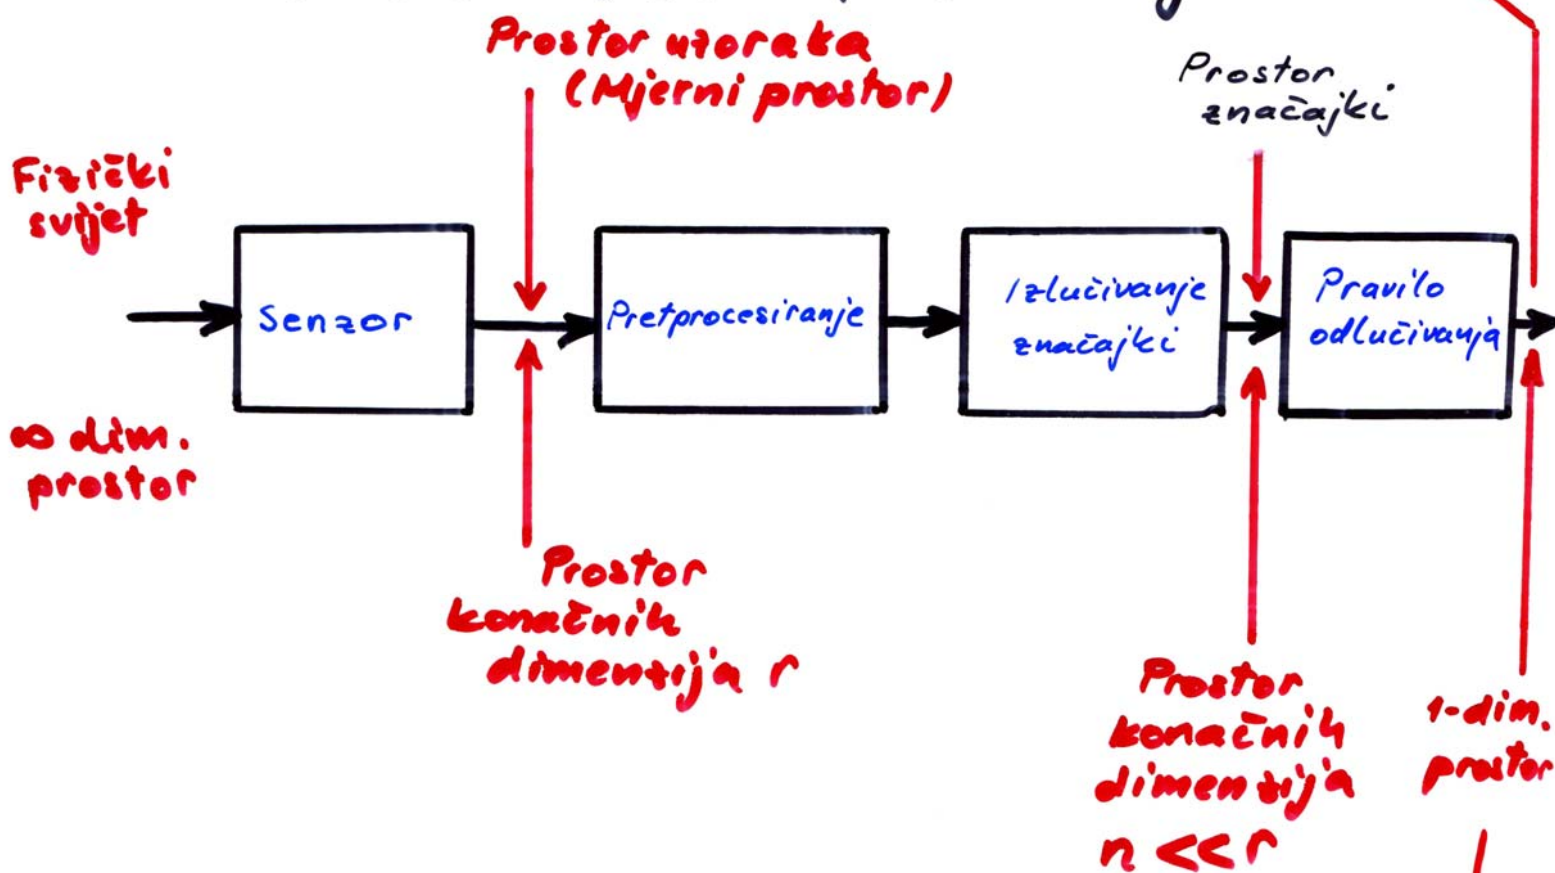
tada nepoznati uzorak \vec{x} pripada razredu W_i .

Blok-dijagram klasifikatora



DFG - Generator decizijske funkcije (engl. Decision function generator)

Model sustava za raspoznavanje



- Vanjski, fizički svijet sadrži praktički ∞ mnogo značajki
 ↓
 "analogni" svijet
 • senzor ili pretvarač pretvara analogni svijet u zapis koji sadrži r (brojčanih) vrijednosti
- Pretprocesiranje : izlučivanje šuma, poboljšanje mjernog podatka
- Prostor značajki : $n \ll r$

$$\vec{x} = (x_1, x_2, x_3, \dots, x_n)^T$$
- Prostor odlučivanja - jednodim. prostor R^1

PRIMER

$$DB = \{O_k; k=1, 2, \dots\}$$

O_i - signal EKG-a pacijenta

PU - automatska dijagnoza signala EKG-a u testu opterećenja

Uzorak

$$f_k(x) \rightarrow \vec{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

Razred objekata:

Normalni EKG

Granični EKG

Nonnormalni EKG

Razred uzoraka

C_1 / ω_1 - Nonnormalni EKG

C_2 / ω_2 - Granični EKG

C_3 / ω_3 - Normalni EKG

Skup uzoraka za učenje ili

vježbanje $U_M = (S_M, \Omega)$

Tip uzorka - jednostavni uzorak

PRIMJER (nastavak)


2.8.

Sustav za automatsku dijagnozu EKG-a

/Lesterova dijagnostička metoda/

EKG u
fazu
opterećenja

- Vanjski, fizički svijet



- Uzorkovanje ($f = 800\text{Hz}$) (A/D konverzija)



- Pretprocesiranje : - Eliminacija ekstrasistule


- Detekcija stabilnih točaka
(maksimalna i minimalna derivacija)

Utvrdjivanje
broja otkucaja
u minuti

- Filtriranje usrednjavanjem
/eliminacija šuma za faktor
 \sqrt{n} ; gdje je n broj
analiziranih perioda

- Izlučivanje


značajki u skladu s Lesterovom dijagnostičkom
metodom

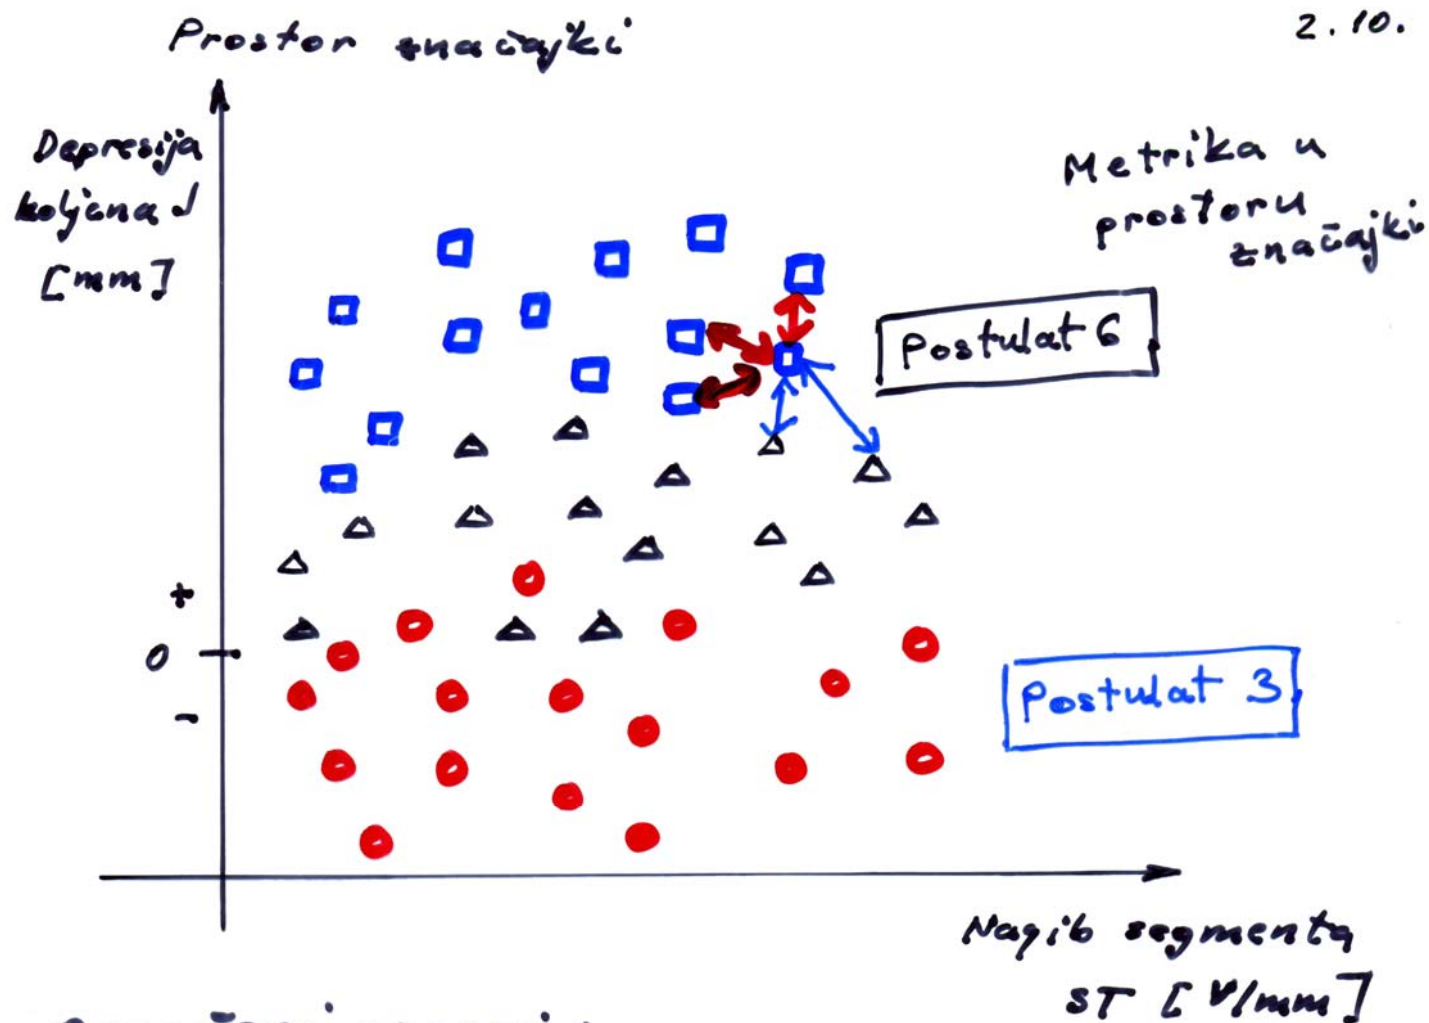


Problem: - Koljeno J ima različite oblike

- segment ST se nalazi između kraja (završetka) vala S i početka vala T i dužina segmenta ST zavisi od frekvencije signala EKG-a (broja otkucaja srca u minuti)

Primjeri kliničkih oblika koljena J i nagiba segmenta ST





- Označeni uzorci:

- uzorci iz skupa za učenje

- - Nenormalan EKG
- △ - Granični slučaj
- - Normalan EKG

u skladu s
postulatom 1

$\Omega = \{ \overset{\omega_1}{\text{Nenormalan EKG}}, \overset{\omega_2}{\text{Granični slučaj}}, \overset{\omega_3}{\text{Normalan EKG}} \}$

$\Omega = \{ \omega_1, \omega_2, \omega_3 \}; M=3$


Postulat 2

vektor značajki $\vec{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$

x_1 - nagib segmenta ST
 x_2 - depresija koljena J


-decizijske funkcije

2.11.



Razvrstavanje (klasifikacija) nepoznatog uzorka (■)

$$\hat{\vec{x}} = \begin{bmatrix} x_1' \\ x_2' \end{bmatrix}$$



LINEARNE FUNKCIJE ODLUČIVANJA

(engl. Linear discriminant functions)


\vec{X} - vektor značajki

$$\vec{X} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$\circ \in \omega_1$

$\times \in \omega_2$

$M=2$



Funkcija odlučivanja kao linearna kombinacija komponenti vektora \vec{X} :

$$d(\vec{X}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1}$$

gd.

$n=2$ funkcija odlučivanja \rightarrow jednačina pravca

$n=3$ jednačina ravnine

$n > 3$ hiperravnina

w_i - težinski koeficijenti; $i = 1, 2, \dots, n$

w_{n+1} - pomaknuće, utežnosni prag

(engl. bias, threshold weight)

SLUČAJ: DVA RAZREDA (ω_1 i ω_2)

$$M=2$$

$$d(\vec{x}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} = 0$$

$$M=2; \quad \omega_1 \text{ i } \omega_2$$

Decizijsko pravilo:

ako $d(\vec{x}) > 0$ onda $\vec{x} \in \omega_1$

$d(\vec{x}) < 0$ onda $\vec{x} \in \omega_2$


ako je $d(\vec{x}) = 0$


nedefinirano

$d(\vec{x})$ zapišimo u vektorskom obliku:

$$d(\vec{x}) = \vec{w}_0^T \vec{x} + w_{n+1} = 0$$

Geometrijska interpretacija funkcije odlučivanja:





Jednadžba hiperravnine:

$$\vec{u}^T (\vec{x} - \vec{p}) = 0$$

$$\vec{w}_0^T \vec{x} + w_{n+1} = 0 \quad / \quad \|\vec{w}_0\|$$

$$\frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|} = - \frac{w_{n+1}}{\|\vec{w}_0\|}$$

$$\|\vec{w}_0\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

usporedimo!

$$\vec{u}^T \vec{x} = \vec{u}^T \vec{p}$$

$$\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|} \quad ; \quad \vec{u}^T \vec{p} = - \frac{w_{n+1}}{\|\vec{w}_0\|}$$

$$\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}$$

→ pokazuje orijentaciju
hiperravnine;

ako je neka komponenta od \vec{u}
jednaka 0 onda je
hiperravnina paralelna s
odgovarajućom koordinatnom
osi

Apsolutna vrijednost $\vec{u}^T \cdot \vec{p}$:

$|\vec{u}^T \cdot \vec{p}|$ predstavlja udaljenost
hiperravnine od ishodišta.

$$D_u = \frac{|w_{n+1}|}{\|\vec{w}_0\|}$$

Posljedice:


- Budući da je $\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}$ ispitivanjem
vektora težinskih koeficijenata \vec{w}_0
može se utvrditi da li je hiperravnina
paralelna s bilo kojom koordinatnom
osi.
- Ako je $w_{n+1} = 0$ onda hiperravnina
prolazi kroz ishodište koordinatnog
sustava
- Udaljenost točke \vec{X} od hiperravnine
je $D_x = \left| \vec{u}^T \cdot \vec{p} - \vec{u}^T \cdot \vec{X} \right|$
 $= \left| \frac{\vec{w}_0^T \cdot \vec{p}}{\|\vec{w}_0\|} - \frac{w_{n+1} \vec{X}}{\|\vec{w}_0\|} \right|$

SLUČAJ: VIŠE RAZREDA $M > 2$

- više pristupa rješavanju problema linearnog klasifikatora za $M > 2$

$$M = c \quad c > 2$$

Primjer: problem se može reducirati na c problema klasifikacije u dva razreda u kojem se i -ti problem rješava linearnom funkcijom odlučivanja koja odvaja uzorke razreda ω_i od svih ostalih koji ne pripadaju razredu ω_i .




Slika za 1. slučaj

1. Slučaj: Granica između ω_i ; $i=1, 2, \dots, c$
i preostalih razreda

$$d_i(\vec{X}) = W_{i,1}X_1 + W_{i,2}X_2 + \dots + W_{i,n}X_n + W_{i,n+1} = 0$$


$$d_i(\vec{X}) = \vec{W}_i^T \vec{X} + W_{i,n+1}$$

1. slučaj: Svaki je razred uzoraka separabilan od ostalih razreda jednom
decizijskom
ravninom



$$d_i(\hat{x}) = \vec{w}_i^T \vec{x} = \begin{cases} > 0 & \text{if } \hat{x} \in \omega_i \\ < 0 & \text{if } \hat{x} \notin \omega_i \end{cases}$$

2. slučaj: Svaki razred uzoraka je separabilan sa svakim pojedinim (drugim) razreda i to
jednom decizijskom
ravninom.



/ razredi su po
parovima
separabilni:
 $M(M-1)/2$
decizijskih
ravniina

3. slučaj: Postoji M decizijskih funkcija

$$d_k(\vec{x}) = \vec{w}_k^T \vec{x}, \quad k=1, 2, \dots, M \quad \text{sa svojstvom}$$

da \vec{x} pripada razredu ω_i ako

$$d_i(\vec{x}) > d_j(\vec{x}) \quad \text{za sve } j \neq i$$


To je poseban slučaj **2. slučaja** zato što možemo definirati sledeće:

$$\begin{aligned} d_{ij}(\vec{x}) &= d_i(\vec{x}) - d_j(\vec{x}) \\ &= (\vec{w}_i - \vec{w}_j)^T \vec{x} \end{aligned}$$

$$= \vec{w}_{ij}^T \vec{x}; \quad \vec{w}_{ij} = \vec{w}_i - \vec{w}_j$$

ako je $d_i(\vec{x}) > d_j(\vec{x})$ za sve $j \neq i$, tada je $d_{ij}(\vec{x}) > 0$ za sve $j \neq i$, što znači:

ako su razredi separabilni za 3. slučaj onda su automatski separabilni i za 2. slučaj.



2. slučaj :

Upotrijebi $\frac{c(c-1)}{2}$ linearnih funkcija
odlučivanja tako da sa svakom funkcijom
odvojiš par razreda

Granica između W_i i W_j je zadana s :

$$d_{ij}(\vec{X}) = W_{ij,1} X_1 + W_{ij,2} X_2 + \dots + W_{ij,n} X_n + W_{ij,n+1} = 0$$

3. slučaj :

$$\begin{aligned} d_{ij}(\vec{X}) &= d_i(\vec{X}) - d_j(\vec{X}) = \\ &= (W_{i,1} - W_{j,1}) X_1 + (W_{i,2} - W_{j,2}) X_2 + \dots + \\ &\quad (W_{i,n} - W_{j,n}) X_n + (W_{i,n+1} - W_{j,n+1}) = 0 \end{aligned}$$

$$d_i(\vec{X}) = \vec{W}_i^T \cdot \vec{X} + W_{i,n+1}$$

ako je $d_i(\vec{X}) > d_j(\vec{X})$; $j=1,2,\dots; j \neq i$

onda $\vec{X} \in W_i$

klasifikator \rightarrow Linearni stroj (engl. linear machine)

$$(\vec{W}_i - \vec{W}_j)^T \vec{X} + (W_{i,n+1} - W_{j,n+1}) = 0$$

ODREĐIVANJE FUNKCIJE ODLUČIVANJA → UČENJE ILI VJEŽBANJE

Problem oblikovanja linearnog klasifikatora:
odrediti koeficijente linearne funkcije odlučivanja:

$$\vec{W} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} \quad \begin{matrix} i \\ \swarrow \\ ? \end{matrix} \quad w_{n+1}$$

$$d(\vec{x}) = \vec{W}^T \vec{x} + w_{n+1}$$

"Automatizirati" postupak određivanja koeficijenata linearne funkcije odlučivanja:
iterativni postupak **učenja**
koeficijenata linearne funkcije odlučivanja uporabom uzoraka iz skupa za učenje (engl. training set).

N uzoraka: $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$

razvrstani u dva razreda ω_1 i ω_2

Vektori uzoraka \vec{x}_i $i=1, 2, \dots, N$

su "označeni" vektori tj. oni sa poznatom pripadnošću razredu

(ω_1 ili ω_2). **UPOTRIJEBIT**
ĆEMO IH ZA UČENJE $d(\vec{x})$!

Povećat ćemo dimenzionalnost vektora \vec{X} za jedan ^{ef8}

$$\vec{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix}$$

radi elegantnijeg zapisa:

$$d(\vec{X}) = \vec{W}^T \vec{X}$$

Uspijemo li odrediti takav vektor težinskih koeficijenata \vec{W} tako da pomoću funkcije $d(\vec{X})$ pravilno razvrstamo sve uzorke (iz skupa za učenje), kažemo da su ω_1 i ω_2 LINEARNO RAZDVOJIVI.

$$M=2$$

Uzorak \vec{X} je pravilno razvrstan

ako za sve \vec{X} iz ω_1

vrijedi $\vec{W}^T \vec{X} > 0$ i ako

za sve \vec{X} iz ω_2

vrijedi

$$\vec{W}^T \vec{X} < 0$$

Jedinstven uvjet: $\vec{W}^T \vec{X} > 0$

ako uzorke iz ω_2 pomnožimo

s -1 !

Redefiniran problem:

ef 9.

Tražimo vektor koeficijenata \vec{w} linearne funkcije odlučivanja tako da vrijedi

$$\vec{w}^T \vec{x} > 0 \quad \text{za sve uzorke}$$

\vec{x} iz skupa uzoraka za učenje.

/ PAŽI: uzorci $\vec{x} \in \omega_2$ su pomnoženi

s -1 /

odnosno

$$[X] \vec{w} > \vec{0} \quad \text{za sve uzorke } \vec{x}$$

$$[X] = \begin{bmatrix} \vec{x}_1^T \\ \vec{x}_2^T \\ \vdots \\ \vec{x}_N^T \end{bmatrix}$$

$[X]$ je matrica svih uzoraka iz skupa za učenje, s tim da su uzorci iz ω_2 pomnoženi s -1 .

$$\vec{w} = (w_1, w_2, \dots, w_n, w_{n+1})^T$$

$\vec{0}$ - nulti vektor

PRIMJER 1:

$$\vec{x}_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}; \vec{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad \begin{array}{l} \vec{x}_1 \in \omega_1 \\ \vec{x}_2 \in \omega_1 \end{array}$$

$$\vec{x}_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}; \vec{x}_4 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \begin{array}{l} \vec{x}_3 \in \omega_2 \\ \vec{x}_4 \in \omega_2 \end{array}$$

- POVEĆAJMO DIMENZIONALNOST VEKTORA :

$$\vec{x}_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}; \vec{x}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}; \vec{x}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

$$\vec{x}_4 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

- POMNOŽIMO SVE UZORKE IZ RAZREDA ω_2 S -1

$$\vec{x}_3 = \begin{bmatrix} -1 \\ 0 \\ -1 \end{bmatrix}; \vec{x}_4 = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

- Oblikujemo matricu $[X]$

ef. 11

$$[X]_{4 \times 3} = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

$$[X] \vec{w} > \vec{0}$$

$$\begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}_{4 \times 3} \cdot \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}_{3 \times 1} > \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}_{4 \times 1}$$

vektor \vec{w} koji zadovoljava
sustav linearnih nejednadžbi

$$[x] \cdot \vec{w} > \vec{0}$$

nazivamo razdvojni vektor.

A) GRADIJENTNI POSTUPCI ODREĐIVANJA RAZDVOJNOG VEKTORA

$d(\vec{x})$ - funkcija vektorskog argumenta
 \uparrow
 vektor!

Općenito: $f(\vec{y})$

$$\vec{y} = (y_1, y_2, \dots, y_n)^T$$

Gradijent funkcije vektorskog argumenta:

$$\text{grad } f(\vec{y}) = \frac{df(\vec{y})}{d\vec{y}} = \begin{bmatrix} \frac{df}{dy_1} \\ \frac{df}{dy_2} \\ \vdots \\ \frac{df}{dy_n} \end{bmatrix}$$

• GRADIJENT SKALARNE
FUNKCIJE VEKTORSKOG
ARGUMENTA JE
VEKTOR.

- svaka komponenta gradijenta predstavlja
veličinu promjene funkcije u smjeru
komponente vektora

VRIJEDI:

- Povećanje argumenta u smjeru pozitivnog gradijenta funkcije f dovodi nas do maksimuma funkcije f
- povećanje argumenta u smjeru negativnog gradijenta dovodi nas do minimuma funkcije f

PRIMJER 2:Funkcija $J(w, 1) = (|w| - w)$

$$\frac{\partial J(w, 1)}{\partial w} = \text{sgn}(w) - 1$$

$$\text{sgn}(x) = \begin{cases} 1 & \text{za } x > 0 \\ -1 & \text{za } x \leq 0 \end{cases}$$

$$\frac{\partial J}{\partial w} = -2 \quad \text{ako je } w \leq 0$$

$$= 0 \quad \text{ako je } w > 0$$

$$w(k+1) > w(k)$$

↑ povećanje
argumenta u smjeru
negativne vrijednosti komp.
gradijenta \Rightarrow prema min.

