

Pooprćene (Linearne) decizijske funkcije

- Složenost granica:

Linearne \rightarrow vrlo nelinearne!

- vrlo nelinearne?

Rješenje:

Pooprćni oblik (linearne) decizijske funkcije:

$$d(\vec{x}) = w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_k f_k(\vec{x}) + w_{k+1}$$

$$= \sum_{i=1}^{k+1} w_i f_i(\vec{x})$$

$$\{f_i(\vec{x})\}, i = 1, 2, \dots, k$$

$$f_{k+1} = 1$$

Pazi: $f_i(\vec{x})$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$d(\vec{x})$ je linearna funkcija po \vec{x}^*

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$\vec{w} = (w_1, w_2, \dots, w_k, w_{k+1})^T$$

Decizijska funkcija $d(\vec{x})$ može se promatrati kao linearna funkcija u k -dimenzionalnom prostoru!

Transformacija:

$$\begin{array}{ccc} \vec{x} / & \longrightarrow & \vec{x}^* / \\ n\text{-dimenzija} & & k\text{-dimenzija} \end{array}$$

Vrijedi:

$$k > n$$

$d(\vec{x})$ se često naziva i "virtualno linearna"

Kako izabrati $\{f_i(\vec{x})\}_{i=1}^k$?

Mogućnost:

$\{f_i(\vec{x})\}$ $f_i(\vec{x})$ u obliku polinoma

- Najjednostavniji slučaj: linearna funkcija

$$\vec{x} = (x_1, x_2, \dots, x_n)^T$$

$$f_i(\vec{x}) = x_i$$

$$\vec{x} = \vec{x}^*$$

$$k=n$$

- Polinom drugog stupnja:

Npr. $n=2$ $\vec{x} = (x_1, x_2)^T$

$$d(\vec{x}) = W_{11}x_1^2 + W_{12}x_1x_2 + W_{22}x_2^2 + W_1x_1 + W_2x_2 + W_3$$

$$d(\vec{x}) = \vec{W}^T \vec{x}^*$$

$$\vec{x}^* = (x_1^2, x_1x_2, x_2^2, x_1, x_2, 1)^T$$

Opci slučaj kvadratnog oblika:

$$d(\vec{x}) = \underbrace{\sum_{j=1}^n W_{jj}x_j^2}_{n \text{ izraza}} + \underbrace{\sum_{j=1}^{n-1} \sum_{k=j+1}^n W_{jk}x_jx_k}_{\frac{n(n-1)}{2} \text{ izraza}} + \underbrace{\sum_{j=1}^n W_jx_j}_{n \text{ izraza}} + \underbrace{W_{n+1}}_{1 \text{ izraz}}$$

Kvadratnu decizijsku funkciju možemo promatrati kao linearnu ("linear by virtue") funkciju s

$$k = \frac{(n+1)(n+2)}{2} \text{ varijabli}$$

$$\{f_1(\vec{x}) \dots f_n(\vec{x})\} = \{x_1^2, x_2^2, \dots, x_n^2\}$$

$$\{f_{n+1}(\vec{x}), \dots, f_{2n}(\vec{x})\} = \{x_1, x_2, \dots, x_n\}$$

$$\{f_{2n+1}(\vec{x}), \dots, f_k(\vec{x})\} = \{x_1 x_2, x_1 x_3, \dots, x_{n-1} x_n\}$$

- Decizijske funkcije višeg reda
(polinomi stupnja $r > 2$) možemo promatrati kao linearne funkcije

$$\frac{(n+r)!}{r! n!} \text{ varijabli}$$

n - dimenzionalnost vektora \vec{x}

r - stupanj polinoma

Funkcije iz skupa $\{f_i(\vec{x})\}$ određene su

s :

$$f_i(\vec{x}) = x_{p_1}^{s_1} x_{p_2}^{s_2} \dots x_{p_r}^{s_r}$$

$$p_1, p_2, \dots, p_r = 1, 2, \dots, n$$

$$s_1, s_2, \dots, s_r = 0, 1$$

Decizijsku funkciju u obliku polinoma r -tog stupnja možemo zapisati u rekursivnom obliku:

$$d^r(\vec{x}) = \left(\sum_{p_1=1}^n \sum_{p_2=p_1}^n \dots \sum_{p_r=p_{r-1}}^n W_{p_1 p_2 \dots p_r} x_{p_1} x_{p_2} \dots x_{p_r} \right) + d^{r-1}(\vec{x}) \quad ; \quad d^0(\vec{x}) = W_{n+1}$$

Primjer:

za $r=2$; $n=2$:

$$d^2(\vec{x}) = \sum_{p_1=1}^2 \sum_{p_2=p_1}^2 W_{p_1 p_2} x_{p_1} x_{p_2} + d^1(\vec{x})$$

$$d^1(\vec{x}) = \sum_{p_1=1}^2 W_{p_1} x_{p_1} + d^0(\vec{x})$$

$$d^1(\vec{x}) = W_1 x_1 + W_2 x_2 + W_3$$

$$d^2(\vec{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + d'(\vec{x})$$

$$d^2(\vec{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$$

$$\vec{w}^T = \begin{bmatrix} w_{11} \\ w_{12} \\ w_{22} \\ w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

$$\vec{x}^* = [x_1^2, x_1x_2, x_2^2, x_1, x_2, 1]^T$$

Primjer: $r=3$; $n=2$

$$d^3(\vec{x}) = \left(\sum_{p_1=1}^2 \sum_{p_2=p_1}^2 \sum_{p_3=p_2}^2 w_{p_1 p_2 p_3} x_{p_1} x_{p_2} x_{p_3} \right)$$

$$+ d^2(\vec{x}) ;$$

$$d(\vec{x}) = w_{111}x_1^3 + w_{112}x_1^2x_2 + w_{122}x_1x_2^2 + w_{222}x_2^3 + d^2(\vec{x})$$

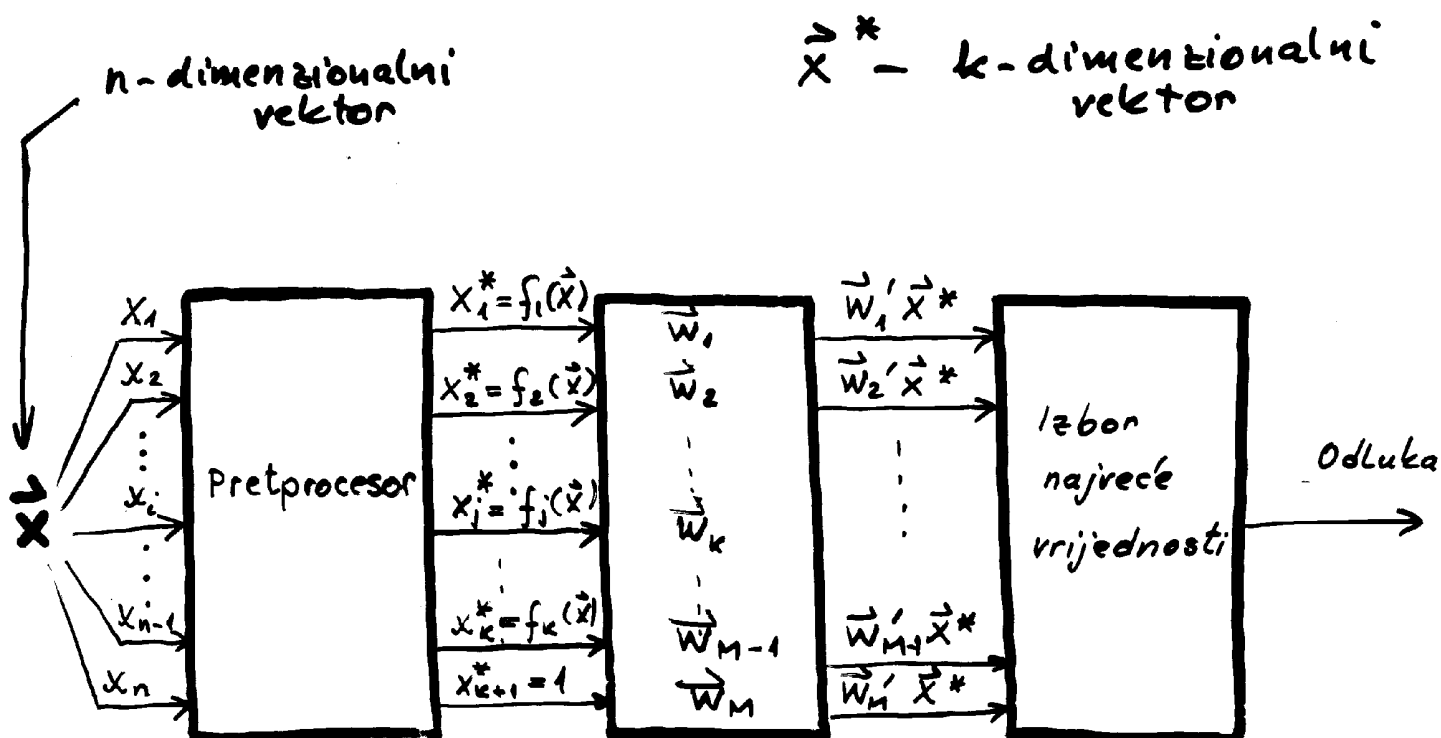
$$d(\vec{x}) = w_{111}x_1^3 + w_{112}x_1^2x_2 + w_{122}x_1x_2^2 + w_{222}x_2^3 + w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$$

Cijena koju plaćamo za
linearizaciju :

- broj koeficijenata (težijskih
faktora) za funkciju r -tog
stupnja i različite n :

$n \backslash r$	1	2	3	...	6	10
1	2	3	4		7	11
2	3	6	10		28	66
3	4	10	20		84	286
⋮						
9	10	55	220		5005	92378
10	11	66	286		8008	184756

Dimenzionalnost "lineariziranog
prostora" !




$k \gg n$
 Blok-shema sustava za raspoznavanje

PRIMJER

RS3.
Lpd 9

Zadan je skup uzoraka za učenje:

- $U_4^1 = \{(0,0)^T, (0,4)^T, (4,0)^T, (4,4)^T\}$
- $U_4^2 = \{(1,1)^T, (1,3)^T, (3,1)^T, (3,3)^T\}$
- $U_1^3 = \{(2,2)^T\}$



• $\in \omega_1$

• $\in \omega_2$

• $\in \omega_3$

← oznaka razreda

u ← broj uzoraka

Zadane uzorke ne možemo odijeliti linearnim dec. funkcijama!

Pokušajmo kvadratnim! $\Rightarrow r=2; n=2$

$K = \frac{(n+1)(n+2)}{2} = 6$ - dimenzionalni prostor

$n=2$

2-dim. \rightarrow 6-dim.

Preslikavanje 2- u 6-dimenz. prostor funkcijama

$$f_1 = x_1^2 \quad f_2 = x_1 x_2 \quad f_3 = x_2^2 \quad f_4 = x_1 \quad f_5 = x_2 \quad f_6 = 1$$

Preslikan skup za učenje je:

$$U_4^1 = \{(0,0,0,0,0,1)^T, (0,0,16,0,4,1)^T, (16,0,0,4,0,1)^T, (16,16,16,4,4,1)^T\}$$

$$U_4^2 = \{(1,1,1,1,1,1)^T, (1,3,9,1,3,1)^T, (9,3,1,3,1,1)^T, (9,9,9,3,3,1)^T\}$$

$$U_1^3 = \{(4,4,4,2,2,1)^T\}$$


$$\vec{X}^* = \begin{bmatrix} x_1^2 \\ x_1 \cdot x_2 \\ x_2^2 \\ x_1 \\ x_2 \\ 1 \end{bmatrix}$$

$$d(\vec{X}) = \vec{W}^T \cdot \vec{X}^*$$


$$\vec{W} = ?$$

Upotrijebimo poopćeni algoritam perceptrona ($M=3$).

Dva od mogućih rezultata (u zavisnosti od izbora početnih vrijednosti):



Decizijske se
granice
dobivaju
nakon nešto
više od
2000
koraka
poopćenog
algoritma
perceptrona



Popćeni algoritam perceptrona

RS 2

M razreda : $\omega_1, \omega_2, \dots, \omega_M$

Pretpostavimo da u k-tom koraku tijekom ućenja uzorak $\vec{x}(k)$ pripada razredu ω_i .

Raćunamo M decizijskih funkcija.

Ako je

$$d_i[\vec{x}(k)] > d_j[\vec{x}(k)] \quad j=1,2,\dots,M; \\ j \neq i$$

težinski vektor se ne ućada :

$$\vec{w}_j(k+1) = \vec{w}_j(k), \quad j=1,2,\dots,M$$

Pretpostavimo da je za neki ℓ

$$d_i[\vec{x}(k)] \leq d_\ell[\vec{x}(k)]$$

težinski vektori se sada ućadaju :

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c \vec{x}(k)$$

$$\vec{w}_\ell(k+1) = \vec{w}_\ell(k) - c \vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k); \quad j=1,2,\dots,M \\ j \neq i \\ j \neq \ell.$$

c - pozitivna konstanta

$\vec{w}_i(1)$ su proizvoljni poćetni vektori
 $i=1,2,\dots,M$.

Skalarno produktno jezgro (Inner-Product Kernel)

- Kako naći optimalnu hiperravninu za linearno neodvojive razrede uporabom SVM?


Odgovor:

Uporabom sljedećih koraka:

1. Nelinearnim preslikavanjem izvornog (ulaznog) vektora u prostor značajki većih dimenzija;
2. Konstrukcijom optimalne hiperravnine za odvajanje vektora značajki dobivenih u 1. koraku;

Opaska: Korak 1. temelji na Coverovom teoremu (1965. godina) \rightarrow višedimenzionalni prostor može biti transformiran u novi prostor značajki u kojem su uzorci linearno separabilni (s visokom vjerojatnošću) ako su zadovoljena dva uvjeta:

- a) transformacija mora biti
NELINEARNA;
- b) dimenzionalnost prostora
mora biti DOVOJNO VELIKA;



Ulaзни prostor
(izvorni
prostor značajki)

dimenzija: m_0

Prostor
značajki

dimenzija: m_1

$$m_0 < m_1$$

- Označimo s \vec{x} vektor iz ulaznog prostora; dimenzija vektora neka je m_0 .

- Označimo $\{\varphi_j(\vec{x})\}_{j=1}^{m_1}$ skup

nelinearnih transformacija iz ulaznog prostora u prostor značajki

- Pretpostavlja se da je $\varphi_j(\vec{x})$ definiran apriorno za sve j .

epd 13

- za tako zadani skup nelinearnih transformacija možemo definirati dečizijsku ravninu:

$$\sum_{j=1}^{m_1} w_j \varphi_j(\vec{x}) + b = 0,$$

gde je $\{w_j\}_{j=1}^{m_1}$ označava skup linearnih težina (težinskih koeficijenata) a b - pomaknuće.

Možemo zapisati:

$$\sum_{j=0}^{m_1} w_j \varphi_j(\vec{x}) = 0$$

gde je $\varphi_0(\vec{x}) = 1$ za sve \vec{x} tako da w_0 označava b .

Definirajmo vektor:

$$\vec{\varphi}(\vec{x}) = [\varphi_0(\vec{x}), \varphi_1(\vec{x}), \dots, \varphi_{m_1}(\vec{x})]^T$$

gde je $\varphi_0(\vec{x}) = 1$ za sve \vec{x} .

epd 14

vektor $\vec{\varphi}(\vec{x})$ predstavlja sliku
"induciranu" u prostoru značajki
zbog ulaznog vektora \vec{x} .

Vrijedi:

$$\vec{w}^T \vec{\varphi}(\vec{x}) = 0$$

u prostoru značajki zahtijevamo
"linearnu" separabilnost!

SVM nam je dao rezultat:

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i, \text{ odnosno}$$

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{\varphi}(\vec{x}_i),$$

gdje vektor $\vec{\varphi}(\vec{x}_i)$ odgovara
transformiranom ulaznom

vektoru \vec{x}_i u i -tom slučaju
(primjerku)

zpa 15

Uvrstimo $\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{\varphi}(\vec{x}_i)$

u $\vec{w}^T \vec{\varphi}(\vec{x}) = 0$!

Dobivamo:

$$\sum_{i=1}^N \lambda_i d_i \vec{\varphi}^T(\vec{x}_i) \cdot \vec{\varphi}(\vec{x}) = 0$$

$\vec{\varphi}^T(\vec{x}_i) \cdot \vec{\varphi}(\vec{x})$ predstavlja

skalarni produkt dvaju vektora
iz prostora značajki koji su
"inducirani" ulaznim vektorima
 \vec{x} i \vec{x}_i .

$$K(\vec{x}, \vec{x}_i) = \vec{\varphi}^T(\vec{x}) \vec{\varphi}(\vec{x}_i)$$

↗ skalarno produktno jezgro

$$K(\vec{x}, \vec{x}_i) = \sum_{j=0}^{m-1} \varphi_j(\vec{x}) \varphi_j(\vec{x}_i)$$

za $i = 1, 2, \dots, N$

Jezgro $K(\vec{x}, \vec{x}_i)$ je simetrična funkcija svojih argumenata

$$K(\vec{x}, \vec{x}_i) = K(\vec{x}_i, \vec{x}) \text{ za sve } i$$

Najvažnije :

Možemo koristiti jezgro $K(\vec{x}, \vec{x}_i)$ za konstrukciju optimalne hiperravnine u prostoru značajki :

Optimalna hiperravnina je definirana s :

$$\sum_{i=1}^N \lambda_i d_i K(\vec{x}, \vec{x}_i) = 0$$

Optimalni dizajn SVM

Jezgro $K(\vec{x}, \vec{x}_i)$ i njegova
ekspanzija $\sum_{j=0}^{m_i} \varphi_j(\vec{x}) \varphi_j(\vec{x}_i)$
nam omogućava konstrukciju
decizijske ravnine koja je
nelinearna u ulaznom (izvornom
prostoru) značajki, ali je
njena slika u (transformiranom)
prostoru značajki linearna.

Dualni oblik za optimizaciju
(SVM):

- zadani su skup uzoraka za učenje
 $\{\vec{x}_i, d_i\}_{i=1}^N$, naći Lagrangeove
multiplikatore $\{\lambda_i\}_{i=1}^N$ koji
maksimiziraju funkciju:

$$J(\hat{\lambda}) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \cdot K(\vec{x}_i, \vec{x}_j)$$

uz ograničenja:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) 0 \leq \lambda_i \leq C \quad \text{za } i=1, 2, \dots, N,$$

gdje je C user-specific
pozitivni parametar

Kad nađemo optimalne vrijednosti
Lagrangeovih multiplikatora

$\lambda_{0,i}$ dobivamo \vec{w}_0

$$\vec{w}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \varphi(\vec{x}_i)$$

Prva komponenta

vektora \vec{w}_0

— predstavlja pomaknuće
optimalno pomaknuće \vec{b}_0

Jezgro ?

Marcer-ov teorem (1908) :

Neka je $K(\vec{x}, \vec{x}')$ kontinuirano simetrično jezgro koje je definirano na zatvorenom intervalu $\vec{a} \leq \vec{x} \leq \vec{b}$, $\vec{a} \leq \vec{x}' \leq \vec{b}$.

Jezgro $K(\vec{x}, \vec{x}')$ može se razviti

kao:
$$K(\vec{x}, \vec{x}') = \sum_{i=1}^{\infty} \alpha_i \varphi_i(\vec{x}) \varphi_i(\vec{x}')$$

gdje je $\alpha_i > 0$ za sve i .

Taj razvoj je valjan ako vrijedi:

$$\int_b^a \int_b^a K(\vec{x}, \vec{x}') \varphi(\vec{x}) \varphi(\vec{x}') d\vec{x} d\vec{x}'$$

$$i \text{ za } \overset{\text{sve}}{\psi(\cdot)} \int_b^a \psi^2(\vec{x}) d\vec{x} < \infty;$$

za koje vrijedi :

$\varphi_i(\vec{x})$ - svojstvena funkcija (engl. eigenfunction);
 α_i - svojstvena vrijednost (engl. eigenvalue);

- funkcije $\varphi_i(\vec{x})$ se zovu
svojstvene funkcije

α_i - svojstvene vrijednosti

Jezgra:

$$K(\vec{x}, \vec{x}_i) \quad i=1, 2, \dots, N$$

- polinomske funkcije

$$(\vec{x}^T \vec{x}_i + 1)^p$$

- radialne bazne funkcije


$$\exp\left(-\frac{1}{2\sigma^2} \|\vec{x} - \vec{x}_i\|^2\right)$$

- dvorazinski perceptron

$$\tanh(\beta_0 \vec{x}^T \vec{x}_i + \beta_1)$$


Pozor: za jezgro dvorazinskog perceptrona
Mercerov teorem je zadovoljen za
samo neke vrijednosti β_0 i β_1 !

Arhitektura SVM



Primjer: XOR (Exclusive OR)

Ulazni vektor \vec{x}	Željeni odgovor d
$(-1, -1)$	-1
$(-1, +1)$	$+1$
$(+1, -1)$	$+1$
$(+1, +1)$	-1



$\bullet \in \omega_1$

$+ \in \omega_2$

$$\{([-1, -1]^T, d_1 = -1), ([-1, +1]^T, d_2 = +1),$$

$$([+1, -1]^T, d_3 = +1), ([+1, +1]^T, d_4 = -1)\}$$

Izaberimo jezgro $K(\vec{x}, \vec{x}_i) =$

$$(1 + \vec{x}^T \vec{x}_i)^2$$

$$\vec{x} = [x_1, x_2]^T$$

$$\vec{x}_i = [x_{i1}, x_{i2}]^T$$

$$K(\vec{x}, \vec{x}_i) = \vec{\varphi}^T(\vec{x}) \vec{\varphi}(\vec{x}_i)$$

Jezgro $K(\vec{x}, \vec{x}_i) :$

$$K(\vec{x}, \vec{x}_i) = 1 + x_1^2 x_{i1}^2 + 2 x_1 x_2 x_{i1} x_{i2} +$$

$$+ x_2^2 x_{i2}^2 + 2 x_1 x_{i1} + 2 x_2 x_{i2}$$

Slika ulaznog vektora \vec{x} u prostoru značajki je :

$$\vec{\varphi}(\vec{x}) = [1, x_1^2, \sqrt{2} x_1 x_2, x_2^2, \sqrt{2} x_1, \sqrt{2} x_2]^T$$

$$\vec{\varphi}(\vec{x}_i) = [1, x_{i1}^2, \sqrt{2}x_{i1}x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}]^T \quad i=1,2,3,4$$

$K(\vec{x}_i, \vec{x}_j)$ - javlja nam se u
izrazu za SVM

(vidi Epđ 17-18)

$$\underline{K} = \{ K(\vec{x}_i, \vec{x}_j) \}_{(i,j)=1}^N$$

$K(\vec{x}_i, \vec{x}_j)$ možemo promatrati kao
ij-ti element simetrične
matrice K

$$\vec{\varphi}(\vec{x}_1) = [1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}]^T$$

$$\vec{x}_1 = (-1, -1)$$

$$K(\vec{x}_1, \vec{x}_1) = \vec{\varphi}^T(\vec{x}_1) \cdot \varphi(\vec{x}_1)$$

$$K(\vec{x}_1, \vec{x}_1) = 9$$

Dualni oblik za optimizaciju (SVM):

$$\{\vec{x}_i, d_i\}_{i=1}^N$$

Treba naći Lagrangeove multiplikatore

$\{\lambda_i\}_{i=1}^N$ koji maksimiziraju funkciju

$$J(\vec{\lambda}) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j K(\vec{x}_i, \vec{x}_j)$$

uz ograničenja:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) 0 \leq \lambda_i \leq C \quad \text{za } i=1, 2, \dots, N$$

C - pozitivna konstanta

Mpr.

$$K(\vec{x}_1, \vec{x}_4)$$

$$\vec{\varphi}(\vec{x}_1) = [1, +1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}]^T$$

$$\vec{\varphi}(\vec{x}_4) = [1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}]^T$$

$$\vec{x}_4 = [1, 1]^T$$

$$\vec{\varphi}^T(\vec{x}_1) \cdot \varphi(\vec{x}_4) = 1$$

$$K = \begin{matrix} & \begin{matrix} j=1 & 2 & 3 & 4 \end{matrix} \\ \begin{matrix} i=1 \\ 2 \\ 3 \\ 4 \end{matrix} & \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 9 & 1 & 1 \\ 1 & 1 & 9 & 1 \\ 1 & 1 & 1 & 9 \end{bmatrix} \end{matrix}$$

Funkcija (za dualni problem):
(str. svm 17)

$$\begin{aligned} J(\vec{\lambda}) = & \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 - \\ & - \frac{1}{2} (9\lambda_1^2 - 2\lambda_1\lambda_2 - 2\lambda_1\lambda_3 + 2\lambda_1\lambda_4 \\ & + 9\lambda_2^2 + 2\lambda_2\lambda_3 - 2\lambda_2\lambda_4 + 9\lambda_3^2 - 2\lambda_3\lambda_4 \\ & + 9\lambda_4^2) \end{aligned}$$

Optimiziranje funkcije $J(\vec{\lambda})$

u odnosu na Lagrangeove multiplikatore daje skup jednačbi:

$$9\lambda_1 - \lambda_2 - \lambda_3 + \lambda_4 = 1$$

$$-\lambda_1 + 9\lambda_2 + \lambda_3 - \lambda_4 = 1$$

$$-\lambda_1 + \lambda_2 + 9\lambda_3 - \lambda_4 = 1$$

$$\lambda_1 - \lambda_2 - \lambda_3 + 9\lambda_4 = 1$$

Optimalne vrijednosti Lagrangeovih multiplikatora su

$$\lambda_{0,1} = \lambda_{0,2} = \lambda_{0,3} = \lambda_{0,4} = \frac{1}{8}$$

- sva četiri vektora u EXOR problemu su potporni vektori

$$J_0(\vec{\lambda}) = \frac{1}{4}$$

$$\frac{1}{2} \|\vec{w}_0\|^2 = \frac{1}{4} \quad \|\vec{w}_0\| = \frac{1}{\sqrt{2}}$$

Nadimo \vec{w}_0

$$\vec{w}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \varphi(\vec{x}_i)$$

$$\vec{w}_0 = \frac{1}{8} [-\varphi(\vec{x}_1) + \varphi(\vec{x}_2) + \varphi(\vec{x}_3) - \varphi(\vec{x}_4)]$$

$$\vec{w}_0 = \frac{1}{8} \left[- \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \end{bmatrix} \right]$$

$$\vec{w}_0 = \begin{bmatrix} 0 \\ 0 \\ -1/\sqrt{2} \\ 0 \\ 0 \\ 0 \end{bmatrix} \rightarrow \text{pomaknuće} \\ b = w_0 = 0$$

Optimalna hiperravnina je

$$\vec{w}_0^T \vec{\varphi}(\vec{x}) = 0$$

$$\left[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0 \right] \begin{bmatrix} 1 \\ x_1^2 \\ x_2^2 \\ \sqrt{2} x_1 x_2 \\ \sqrt{2} x_1 \\ \sqrt{2} x_2 \end{bmatrix} = 0$$

$$\boxed{-x_1 x_2 = 0}$$

za $x_1 = x_2 = -1$ i $x_1 \cdot x_2 = +1$

izlaz $y = -1$

za $x_1 = -1$ i $x_2 = +1$ te za

$x_1 = +1$ i $x_2 = -1$

