


SVM – Support Vector Machines

Strojevi s potpornim vektorima (Vapnik, 1992)

-Izvorno SVM je linearni stroj

- Osnovna zamisao SVM : konstrukcija hiperravnine kao decizijske plohe ali tako da je margina odvajanja između pozitivne „pozitivne“ i „negativne“ skupine uzoraka (za učenje) maksimalna.



Imamo skup uzoraka za učenje: $\{(\vec{x}_i, d_i)\}_{i=1}^N$, gdje je \vec{x}_i ; $i=1,2,\dots,N$ ulazni vektor uzoraka za i -ti primjer.

d_i - željeni odgovor klasifikatora

Označeni uzorci:

$w_1 \rightarrow d_i = +1$

$w_2 \rightarrow d_i = -1$

Pretpostavka: razredi w_1 i w_2 su linearno separatibilni.

Jednadžba decizijske ravnine:

$$\vec{w}^T \vec{x} + b = 0$$

\vec{x} - ulazni vektor

\vec{w} - vektor težinskih koeficijenata

b – pomaknuće (w_0)


Vrijedi :

$$\vec{w}^T \vec{x} + b \geq 0 \quad \text{za } d_i = +1$$

$$\vec{w}^T \vec{x} + b < 0 \quad \text{za } d_i = -1$$

Margina: Za zadani vektor težinskih koeficijenata \vec{w} i pomaknuće b udaljenost između hiperravnine i najbliže točke (uzorka) u n -dimenzionalnom prostoru naziva se MARGINA ODVAJANJA (engl. Margin of separation) i označit ćemo je s p .

Cilj: Naći posebnu hiperravninu za koju je margina odvajanja p maksimalna. Takva hiperravnina naziva se OPTIMALNA RAVNINA.




Optimalna hiperravnina: $\{\vec{w}_0, b_0\}$ – optimalne vrijednosti


$$\vec{w}_0^T \vec{x} + b_0 = 0$$

Decizijska funkcija :

$g(\vec{x}) = \vec{w}_0^T \vec{x} + b_0$ – daje mjeru udaljenosti \vec{x} -a od optimalne hiperravnine.



Primjer:



$$g(\vec{x}) = \vec{w}_0^T \vec{x} + b_0$$

$$g(\vec{x}) = \begin{bmatrix} -2 \\ 3 \end{bmatrix}^T \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - 4$$

$$\vec{x}_1 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

$$g(\vec{x}_1) = -2 \text{ - normirati } r(\vec{x}_1) = 0.54$$

$$\vec{x}_2 = \begin{bmatrix} 1.5 \\ 5 \end{bmatrix}$$

$$g(\vec{x}_2) = 8 \text{ - normirati } r(\vec{x}_2) = 2.65$$

$$\|\vec{w}_0\| = \sqrt{w_1^2 + w_2^2}$$

Par (\vec{w}_0, b_0) mora zadovoljiti sljedeća ograničenja:

$$\vec{w}_0^T \vec{x}_i + b_0 \geq 1 \text{ za } d_i = +1 \quad (1)$$

$$\vec{w}_0^T \vec{x}_i + b_0 < -1 \text{ za } d_i = -1 \quad (2)$$

$$\vec{x}_i \in \{(\vec{x}_i, d_i)\}_{i=1}^N$$

Naravno ovo vrijedi ako su uzorci linearno odvojivi. Uvijek možemo skalirati \vec{w}_0 i b_0 da nejednadžbe (1) i (2) vrijede!

$R = \frac{|g(\vec{x})|}{\|\vec{w}_0\|}$ možemo skalirati \vec{w}_0 i b_0 tako da za najbliže(hiperravnini $g(\vec{x})$!) uzorke iz w_1 i w_2 bude:

$$g(\vec{x}) = 1 \text{ za } w_1$$

$$g(\vec{x}) = -1 \text{ za } w_2$$

Za uzorke (točke u n- dimenzionalnom prostoru) iz skupa za učenje i to za one koje vrijedi

$$\vec{w}_0^T \vec{x} + b_0 = 1 \quad \text{za } d_i = +1$$

$$\vec{w}_0^T \vec{x} + b_0 = -1 \quad \text{za } d_i = -1$$

Kažemo da su potporni vektori.(support vectors)

Potporni vektori su one točke koje leže najbliže decizijskoj hiperravnini i zato se najteže klasificiraju. Zbog toga oni imaju izravan utjecaj na optimalni položaj decizijske hiperravnine.

Potporni vektor $\vec{x}^{(s)}$:

$$g(\vec{x}^{(s)}) = \vec{w}_0^T \vec{x}^{(s)} + b_0 = (-/+)1 \quad \text{za } d^{(s)} = (-/+)1$$

(!)Algebarska udaljenost potpornog vektora $\vec{x}^{(s)}$ od optimalne hiperravnine je

$$r = \frac{|g(\vec{x}^{(s)})|}{\|\vec{w}_0\|}.$$

$$r = \begin{cases} \frac{1}{\|\vec{w}_0\|} & \text{ako je } d^{(s)} = +1 \\ -\frac{1}{\|\vec{w}_0\|} & \text{ako je } d^{(s)} = -1 \end{cases}$$

gdje znak + označava da $\vec{x}^{(s)}$ leži na pozitivnoj strani optimalne hiperravnine, a – predznak pokazuje da je $\vec{x}^{(s)}$ na negativnoj strani optimalne ravnine.

ρ - optimalna vrijednosti MARGINE ODVAJANJA između dva razreda koji definiraju skup uzoraka za učenje.

$$\rho = 2r$$

$$\rho = \frac{2}{\|\vec{w}_0\|}$$

Iz

$$\rho = \frac{2}{\|\vec{w}_0\|}$$

slijedi da maksimiziranje margine odvajanja temelji na minimizaciji norme vektora težinskih koeficijenata $\|\vec{w}_0\|$.

Optimalna hiperravnina:

$$\vec{w}_0^T \vec{x} + b_0 = 0$$

Je jedinstvena u tom smislu da vektor $\|\vec{w}_0\|$ daje maksimalnu separaciju između pozitivnih i negativnih uzoraka iz skupa za učenje.

Cilj: Razvoj djelotvorne procedure (uporabom skupa uzoraka za učenje) tako da nađemo optimalnu hiperravninu uz zadovoljenje ograničenja :

$$d_i * (\vec{w}^T \vec{x}_i + b) \geq 1 \text{ za } i=1,2,\dots,N.$$

Formalno postavljen problem:

- Zada je skup uzoraka za učenje $\{(\vec{x}_i, d_i)\}_{i=1}^N$
- Nađi optimalnu vrijednost vektora težinskih koeficijenata \vec{w} i pomaknuće b tako da su zadovoljena ograničenja

$$d_i * (\vec{w}^T \vec{x}_i + b) \geq 1 \text{ za } i=1,2,\dots,N.$$

a pri tomu vektor težinskih koeficijenata \vec{w} minimizira kriterijsku funkciju:

$$J(\vec{w}) = \frac{1}{2} \vec{w}^T \vec{w}$$

$$\vec{w}^T \vec{w} = \|\vec{w}\|^2$$

- nelinearni optimizacijski zadatak sa skupom linearnih nejednadžbi

Optimizacijski problem riješiti metodom Lagrangeovih multiplikatora.

Primjer:

Određivanje vezanih ekstrema funkcije $z=f(x,y)$ uz uvjet $\phi(x,y)=0$ svodi se na računanje slobodnih ekstrema Lagrangeove funkcije:

$$F=f(x,y)+\lambda \phi(x,y)$$

$$\frac{\partial F}{\partial x} = 0; \frac{\partial F}{\partial y} = 0 \quad \phi(x,y) = 0$$

Iz tog se sustava jednadžbi određuju vrijednosti za x , y i Lagrangev multiplikator λ .

- Ako je $d^2F < 0$ u izračunatoj točki funkcije $z=f(x,y)$ ima maksimum
- Ako je $d^2F > 0$ funkcija $z=f(x,y)$ ima minimum

Tražimo ekstrem funkcije :

$$Z=x + 2y$$

$$\text{Uz uvjet } x^2+y^2=5$$

- Lagrangeova funkcija :

$$F=x + 2y + \lambda(x^2+y^2-5)$$

- Računamo :

$$F_x = \frac{\partial F}{\partial x} = 1 + 2x\lambda$$

$$F_y = \frac{\partial F}{\partial y} = 2 + 2y\lambda$$

- Iz sustava jednačbi :

$$1+2\lambda x=0$$

$$2+2\lambda y=0$$

$$x^2+y^2=5$$

$$\text{slijedi: } x = -\frac{1}{2\lambda} ; y = -\frac{1}{\lambda}$$

uvršćavamo u 3. Jednačbu :

$$\frac{1}{4\lambda^2} + \frac{1}{\lambda^2} = 5/4\lambda^2$$

$$5(1 - 4\lambda^2) = 0$$

$$\lambda_{1,2} = \pm \sqrt{\frac{1}{4}}$$

$$\lambda_1 = +\frac{1}{2} ; \lambda_2 = -\frac{1}{2}$$

za $\lambda_1 = +\frac{1}{2}$ dobivamo:

$$x_1 = -1 \quad y_1 = -2$$

$$\text{za } \lambda_2 = -\frac{1}{2}$$

$$x_2 = 1 \quad y_2 = 2$$

Računamo:

$$d^2F = \frac{\partial^2 F}{\partial x^2} dx^2 + 2 \frac{\partial^2 F}{\partial x \partial y} dx dy + \frac{\partial^2 F}{\partial y^2} dy^2$$

$$F_{xx} = 2\lambda ; F_{yy} = 2\lambda ; F_{xy} = 0$$

$$d^2F = 2\lambda dx^2 + 2\lambda dy^2 = 2\lambda (dx^2 + dy^2)$$

$$\text{za } \lambda_1 = +\frac{1}{2} \quad d^2F > 0 \text{ minimum}$$

$$\text{za } \lambda_2 = -\frac{1}{2} \quad d^2F < 0 \text{ maksimum funkcije } f(x,y).$$

$$J(\vec{w}) = \frac{1}{2} \vec{w}^T \vec{w}$$

$$d_i * (\vec{w}^T \vec{x}_i + b) \geq 1 \quad \text{za } i=1,2,\dots,N.$$

$$1. \text{ Lagrangeova funkcija : } J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i [d_i * (\vec{w}^T \vec{x}_i + b) - 1]$$

λ_i - Lagrangeovi multiplikatori

$$a) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \vec{0}$$

$$b) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial b} = \vec{0}$$

$$c) \quad \lambda_i [d_i * (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i = 1, 2, \dots, N$$

$$d) \quad \lambda_i \geq 0 \quad i = 1, 2, \dots, N$$

$$e) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \vec{0}$$

$$\frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \vec{w} - \sum_{i=1}^N \lambda_i d_i \vec{x}_i = \vec{0}$$

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$\frac{\partial J(\vec{w}, b, \lambda)}{\partial b} = -\sum_{i=1}^N \lambda_i d_i = 0$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

- Traženi vektor \vec{w} određen je s $N_S \leq N$ vektora uzoraka

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$\lambda_i \neq 0$$

Vektor \vec{w} je optimalno rješenje!

- Budući da je skup ograničenja

$$\lambda_i [d_i * (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i = 1, 2, \dots, N$$

Potporni vektori leže u dvije hiperravnine:

$$\vec{w}^T \vec{x} + b = \pm 1$$

Potporni (support) vektori su oni vektori koji leže tako da su NAJBЛИŽI hiperravnini linearnog klasifikatora i određuju kritične elemente skupova za učenje.

- Vektori \vec{x}_i za koje je $\lambda_i = 0$ mogu ležati izvan pojasa odvajanja ali mogu ležati, također, na jednoj od hiperravnina.
- Rezultirajuća (optimalna) hiperravnina je neosjetljiva na broj i položaj takvih vektora
- \vec{w} je eksplicitno određena, b se može dobiti iz jednog od uvjeta

$$(*) \lambda_i [d_i * (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i = 1, 2, \dots, N$$

$$\lambda_i \neq 0.$$

U praksi, b se obično računa kao srednja vrijednost dobivena uporabom svih uvjeta tog tipa (*)

Optimalna hiperravnina linearnog klasifikatora je jedinstvena.



- $J(\vec{w})$ je konveksna (strogo)
- Nejednadžbe su linearne (*lokalni minimum je ujedno i globalni*)

Konveksna funkcija $f(\vec{\theta})$

$F : S \text{ podskup } \mathbb{R}^l \rightarrow \mathbb{R}$

je konveksna u S ako za svaki $\vec{\theta}$ i $\vec{\theta}' \in S$ vrijedi:

$$f(\lambda \vec{\theta} + (1 - \lambda) \vec{\theta}') \leq \lambda f(\vec{\theta}) + (1 - \lambda) f(\vec{\theta}') \quad \text{za svaki } \lambda \in [0, 1]$$



Lagrangeov dualni problem

- Optimizacijski zadatak minimiziraj $J(\vec{w})$ uz ograničenje $\varphi_i(\vec{w}) \geq 0$ $i=1,2,\dots,N$
 Lagrangeova funkcija $J(\vec{w}, \vec{\lambda}) = J(\vec{w}) - \sum_{i=1}^N \lambda_i \varphi_i(\vec{w})$
 Neka je $J^*(\vec{w}, \vec{\lambda}) = \max(J(\vec{w}, \vec{\lambda}))$
 Budući da je $\vec{\lambda} \geq \vec{0}$ i $\varphi_i(\vec{w}) \geq 0$
- Maksimalna vrijednost Lagrangeove funkcije onda kad je $\lambda_i = 0$; $i=1,2,\dots,N$ ili kada je $\varphi_i(\vec{w}) = 0$ (ili oboje) u tom slučaju je $J^*(\vec{w}, \vec{\lambda}) = J(\vec{w})$
- Ogrinalni problem je ekvivalentan sa: $\min_{\vec{w}} J(\vec{w}) = \min_{\vec{w}} \max_{\vec{\lambda}} J(\vec{w}, \vec{\lambda})$

Dualni problem : $\max_{\vec{\lambda} \geq \vec{0}} \min_{\vec{w}} J(\vec{w}, \vec{\lambda})$

$$\underbrace{\vec{\lambda} \geq \vec{0} \quad \vec{w}}$$

Rješenje ovog dijela:

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

i

$$\sum_{i=1}^N \lambda_i d_i = 0$$

Detekcija živosti ruke

85 slika IR

29 živih ruku

56 neživih (umjetnih) ruku

(2 tipa)

}

skup za ispitivanje

SVM


45 slika za učenje

40 slika za ispitivanje

žive ruke nije element u skupu za učenje

umjetne ruke ne pripadaju skupu za učenje

SVM s linearnim jezgrom 5% pogreške



$$(1) : J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i d_i \vec{w}^T \vec{x}_i - b \sum_{i=1}^N \lambda_i d_i + \sum_{i=1}^N \lambda_i$$

$$\vec{w}^T \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{w}^T \vec{x}_i = \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \vec{x}_j$$

$$J(\vec{w}, b, \lambda) = Q(\lambda)$$

$$Q(\lambda) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \vec{x}_j$$

Uz ograničenja:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) \lambda_i \geq 0 \text{ za } i = 1, 2, \dots, N$$

Maksimiziraj $Q(\lambda)$!

Dualni Problem (Lagrangeova dualnost)

a) Ako prvotni problem ima optimalno rješenje tada dualni problemima također optimalno rješenje i odgovarajuća optimalna rješenja su jednaka.

Maksimiziraj $J(\vec{w}, b, \lambda)$ uz $\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$; $\sum_{i=1}^N \lambda_i d_i = 0$; $\lambda_i \geq 0$ za $i = 1, 2, \dots, N$ (ograničenja samo jednačbe, ne nejednačbe)

▪ Nalazimo Lagrangeove multiplikatore koji daju optimalno rješenje!

- Neke značajke dualnog pristupa :

- Kriterijska funkcija koja treba maksimizirati zavisi samo od ulaznih uzoraka u obliku skupa skalarnog produkta $\{\vec{x}_i^T \vec{x}_j\}_{(i,j)=1}^N$
- Optimalno rješenje $\vec{w} = \vec{w}_0$

$$\vec{w}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \vec{x}_i$$

gdje je $\lambda_{0,i}$ optimalni L. multiplikator

$$b_0 = 1 - \vec{w}_0^T \vec{x}^{(s)} \text{ za } d^{(s)} = 1$$

$$(1) J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i \left[d_i * (\vec{w}^T \vec{x}_i + b) - 1 \right]$$

$$(2) \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$(3) \sum_{i=1}^N \lambda_i d_i = 0 ; \lambda_i \geq 0 \text{ za } i = 1, 2, \dots, N$$


Zamjenom (2) i (3) u (1) i nakon uređivanja dobiva se :

$$(**) \max \left(\sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \vec{x}_j \right)$$

$$\lambda \text{ uz uvjet: } \sum_{i=1}^N \lambda_i d_i = 0 ; \lambda_i \geq 0$$

- (4) Optimalni Lagrangeovi multiplikatori se računaju optimiziranjem (MAKSIMIZIRANJEM) izraza (**) a optimalna se hiperravnina dobiva $\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$ (optimalni Lagrangeovi multiplikatori)

Primjer:



$$w_1: [1, 1]^T$$

$$[1, -1]^T$$

$$w_2: [-1, 1]^T$$

$$[-1, -1]^T$$

Vizualno: optimalna ravnina je : $w_1=1, w_2=0, b=0 \rightarrow g(\vec{x})=x_1$

$$g(\vec{x}) = \vec{w}^T \vec{x} + b = 0$$

$$w_1 * x_1 + w_2 * x_2 + b = 0$$

Ograničenja (linearne nejednadžbe):

$$w_1 + w_2 + b - 1 \geq 0$$

$$w_1 - w_2 + b - 1 \geq 0$$

$$w_1 - w_2 - b - 1 \geq 0$$

$$w_1 + w_2 - b - 1 \geq 0$$

$$\text{npr. } d_i * (\vec{w}^T \vec{x}_i + b) \geq 1 \text{ za } w_2 \text{ } d_i = -1$$

$$(-1) * (-1 * w_1 + 1 * w_2 + b) - 1 \geq 0$$

$$J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i \left[d_i * (\vec{w}^T \vec{x}_i + b) - 1 \right]$$

$$J(\vec{w}, b, \lambda) = \frac{w_1^2 + w_2^2}{2} - \lambda_1(w_1 + w_2 - b - 1) - \lambda_2(w_1 - w_2 + b - 1) - \lambda_3(w_1 - w_2 - b - 1) - \lambda_4(w_1 + w_2 - b - 1)$$

KKT uvjeti su zadani sa:

$$\frac{\partial J}{\partial w_1} = 0 \rightarrow w_1 = \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 \quad (1)$$

$$\frac{\partial J}{\partial w_2} = 0 \rightarrow w_2 = \lambda_1 - \lambda_2 - \lambda_3 + \lambda_4 \quad (2)$$

$$\frac{\partial J}{\partial b} = 0 \rightarrow b = \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 \quad (3)$$

$$\lambda_1(w_1 + w_2 - b - 1) = 0 \quad (4)$$

$$\lambda_2(w_1 - w_2 + b - 1) = 0 \quad (5)$$


$$\lambda_3(w_1 - w_2 - b - 1) = 0 \quad (6)$$

$$\lambda_4(w_1 + w_2 - b - 1) = 0 \quad (7)$$

$$\lambda_1, \lambda_2, \lambda_3, \lambda_4 \geq 0$$

7 jednađbi -> 7 nepoznanica

Znam rješenje s maksimalnom marginom (za ovaj jednostavan slučaj): $w_1=1$; $w_2=0$; $b=0$



$$g(\vec{x}) = x_1 = 0$$

Uvrstimo $w_1=1$; $w_2=0$ i $b=0$ u jednađbe:

$$(1) \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1$$

$$(2) \lambda_1 + \lambda_4 - \lambda_2 - \lambda_3 = 0$$

$$(3) \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0$$

Sustav linearnih jednađbi: 3 jednađbe i 4 nepoznanice! Očito -> više od jednog rješenja!

Međutim, svako od rješenja vodi do JEDINSTVENE (OPTIMALNE) LINIJE ODVAJANJA!

Na primjer:

$$(1)+(3) \quad 2\lambda_1 + 2\lambda_2 = 1 \rightarrow \lambda_1 = \frac{1-2\lambda_2}{2}$$

$$(1)+(2) \quad 2\lambda_1 + 2\lambda_4 = 1$$

$$(2)+(3) \quad 2\lambda_1 - 2\lambda_3 = 0 \rightarrow \lambda_1 = \lambda_3$$

$$\text{Uzmimo } \lambda_1 = \frac{1}{8} \Rightarrow \lambda_3 = \frac{1}{8}$$

$$\lambda_2 = \frac{1 - 2\lambda_1}{2} = \frac{\left(1 - 2 \cdot \frac{1}{8}\right)}{2} = \frac{\frac{3}{4}}{2} = \frac{3}{8}$$

$$\lambda_4 = \frac{1 - 2\lambda_1}{2} = \frac{3}{8}$$

$$\vec{w} = \sum_{i=1}^{N=4} \lambda_i d_i \vec{x}_i = \lambda_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \lambda_3 \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \lambda_4 \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\vec{w} = \frac{1}{8} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{3}{8} \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \frac{1}{8} \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \frac{3}{8} \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\vec{w} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\lambda_1 = \frac{1}{4}$$

$$\lambda_3 = \frac{1}{4}$$

$$\lambda_4 = \frac{1}{4}$$

$$\lambda_2 = \frac{1}{4}$$

$$\vec{w} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad g(\vec{x}) = x_1 = 0$$

SVM za $M > 2$ razreda?

Podsjetimo se:

za svaki od razreda tražimo optimalnu decizijsku funkciju $g_i(\vec{x})$ $i = 1, 2, \dots, M$

tako da

$$g_i(\vec{x}) > g_j(\vec{x}) \text{ za svaki } j \neq i$$

ako je $\vec{x} \in \omega_i$

za SVM tražimo decizijsku funkciju $g_i(\vec{x}) = 0$ takva da bude optimalna hiperravnina koja odvaja razred ω_i od svih ostalih

$$g_i(\vec{x}) > 0 \quad \text{za} \quad \vec{x} \in \omega_i$$

$$g_i(\vec{x}) < 0 \quad \text{inače}$$

Klasifikacijsko pravilo

Dodijeli \vec{x} u ω_i ako

$$i = \arg \max \{g_k(\vec{x})\}.$$