
# 1 Model sustava za raspoznavanje uzoraka

## 1.1 Formalni model



Slika 1: Formalni model sustava RU


Okolina O :  $o_k \in O; v_j \in VO$ 

Realizirani prostor uzoraka PU :  $f_k$ -uzorci

Prostor razreda uzoraka  $\Omega\,:\,\Omega=\{\omega_1,\omega_2,\ldots,\omega_M\}$ 


mjerenje m<br/>: $m:o_k->f_k$ klasifikacija c: $c:f_k->\omega_i$ 

Uhrov stožac raspoznavanja - redukcija informacija



Slika 2: Uhrov stožac

### 1.2 Značajke, vektor značajki i klasifikator



Slika 3: Osnovne faze u postupku oblikovanja sustava RU

značajke - promatramo ih kao slučajne varijable:  $x_i$  vektor značajki - slučajni vektori  $\vec{X}, \vec{X} = [x_1, x_2, \dots, x_n]^T$ 


- -značajke koje predstavljaju razlike između razreda uzoraka nazivaju se  $\underline{\text{INTERSET}}$ značajke
- -INTRASET značajke su zajedničke SVIM razredima iz PU (područja uporabe) i ne nose diskriminacijsku informaciju- TAKVE ZNAČAJKE MOGU SE ZANEMARITI

Izbro značajki - izlučiti i izabrati INTERSET značajke

- U većini slučajeva određivanje potpunog skupa diskriminacijskih značajki je IZNIMNO TEŠKO ILI ČAK NEMOGUĆE
- Neke diskriminacijske značajke mogu se naći na temelju raspoloživih rezultata mjerenja (senzoriranja)
- Redukcija dimenzionalnosti vektora značajki uporabom transformacija uz minimalni gubitak informacija
- Vektor značajki predočen kao točka u n-dimenzionalnom prostoru značajki
- Obično definiramo i neku vrstu metrike u takvom prostoru značajki
- Klasifikacija (razvrstavanje) uzorka temelji se na decizijskim funkcijama; PROBLEM: određivanje optimalne decizijske procedure
- Problem klasifikacije može se promatrati kao razvrstavanje nepoznatog uzorka u potprostor prostora značajki na temelju decizijskih granica koje definiraju te procedure
- Decizijske granice određene su decizijskim funkcijama:  $d_1(\vec{X}), d_2(\vec{X}), \dots, d_M(\vec{X}),$ /VAŽNO:  $d_i$  je funkcija koja ima za argument VEKTOR a vraća SKALAR/

• Pravilo razvrstavanja: Ako  $d_i(\vec{X})>d_j(\vec{X})$  za i, j=1,2,...,M te je  $j\neq i$  tada nepoznati uzorak  $\vec{X}$  pripada razredu  $\omega_i$ 


# Blok-dijagram klasifikatora



Slika 4: Blok-dijagram klasifikatora

DFG - generator decizijske funkcije (engl. Decision function generator)

## Model sustava za raspoznavanje



Slika 5: Model sustava za raspoznavanje

- $\bullet\,$  Vanjski, fizički ("analogni") svijet sadrži praktički  $\infty\,$ mnogo značajki
  - senzor ili pretvarač pretvara analogni svijet u zapis koji sadrži r (brojčanih) vrijednosti
- Pretprocesiranje : izlučivanje šuma, poboljšanje mjernog podatka
- Prostor značajki:  $n \ll r$ ,  $\vec{X} = (x_1, x_2, \dots, x_n)^T$
- $\bullet$  Prostor odlučivanja jednodimenzionalni prostor  $R^1$

#### PRIMJER:

 $OB = \{o_k; k = 1, 2, \ldots\}$ 

 $o_i$  - signal EKG-a pacijenta

PU - automatska dijagnoza signala EKG-a u testu opterećenja

Uzorak: 
$$f_k(\vec{X}) - > \vec{X} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

Razred objekata:

Normalni EKG

Granični EKG

#### Nenormalni EKG

Razred uzoraka:

 $C_1/\omega_1$  - Nenormalni EKG

 $C_2/\omega_2$  - Granični EKG

 $C_3/\omega_3$  - Normalni EKG


Skup uzoraka za učenje ili vježbanje  $\mathcal{U}_M = (S_N, \Omega)$ 

Tip uzorka - jednostavan uzorak

Sustav za automatsku dijagnozu EKG-a /Lesterova dijagnostička metoda/



Slika 6: Vanjski svijet




Slika 7: Uzorkovanje ( $f_u$ =800Hz)

### -Pretprocesiranje:

- Elimnacija elektrosistule
- Detekcija stabilnih točaka (maksimalna i minimalna derivacija)
- Filtriranje usrednjavanjem /<br/>eliminacija šuma za faktor $\sqrt{n};$ gdje je n<br/> broj analiziranih perioda
- Utvrđivanje broja otkucaja u minuti
- -Izlučivanje značajki u skladu s Lesterovom dijagnostičkom metodom


#### Problem:

- Koljeno J ima različite oblike
- segment ST se nalazi između kraja (završetka) vala S i početka vala T; duljina segmenta ST zavisi od frekvencije signala EKG-a (broja otkucaja srca u minuti)




Slika 8: Prikaz koljena


Označeni uzorci: u skladu s postulatom 1 $\Omega = \{NenormalanEKG\,\omega_1,\,\text{Granični slučaj}\,\,\omega_2,\,\text{Normalan}\,\,\text{EKG}\,\,\omega_3\\ = \{\omega_1,\,\omega_2,\,\omega_3\,\,M = 3\\ vektorznačajki = \begin{bmatrix} x_1\\x_2 \end{bmatrix};\,x_1$ - nagib segmenta ST,  $x_2$ - depresija koljena J




Slika 9: Primjeri koljena J i segmenata ST



Slika 10: Prostor značajki za primjer




Slika 11: Decizijske funkcije za primjer



Slika 12: Razvrstavanje nepoznatog uzorka

# Linearne funkcije odlučivanja

(engl. Linear discriminant functions)



Slika 13: Linearna funkcija odlučivanja

vektor značajki -  $\vec{X} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \, \mathbf{M}{=}2$ 

Funkcija odlučivanja kao linearna kombinacija komponenti vektora  $\vec{X}$ :

 $d(\vec{X}) = w_1 x_1 + w_2 x_2 + \ldots + w_n x_n + w_{n+1}$ 

za: n=2 funkcija odlučivanaja -> jednadžba pravca

n=3 funkcija odlučivanaja -> jednadžba ravnine

n>3 funkcija odlučivanaja -> hiperravnina

 $w_i$  - težinski koeficijenti; i=1,2,...,n

 $w_{n+1}$  - pomaknuće, utežnosni prag (engl.bias, threshold weight)

Slučaj 2 razreda ( $\omega_1$  i  $\omega_2$ , M=2)

 $d(\vec{X}) = w_1 x_1 + w_2 x_2 + \ldots + w_n x_n + w_{n+1} = 0$ 

 $M=2, \omega_1, \omega_2$ 


Decizijsko pravilo:

ako  $d(\vec{X}) > 0$  onda  $\vec{X} \in \omega_1$ 

 $d(\vec{X}) < 0$  onda  $\vec{X} \in \omega_2$ 

ako  $d(\vec{X}) = 0$  onda nedefinirano

 $d(\vec{X})$  zapišimo u vektorskom obliku:  $d(\vec{X}) = \vec{w_0}^T \vec{X} + w_{n+1} = 0$ 



Slika 14: Geometrijska interpretacija funkcije odlučivanja

Jednadžba hiperravnine: 
$$\vec{u}^T \cdot (\vec{X} - \vec{p}) = 0$$
 
$$\vec{w_0}^T \vec{X} + w_{n+1} = 0 / \|\vec{w_0}\|, \text{ gdje je } \|\vec{w_0}\| = \sqrt{w_1^2 + w_2^2 + \ldots + w_n^2}$$
 
$$\frac{\vec{w_0}^T \vec{X}}{\|\vec{w_0}\|} = -\frac{w_{n+1}}{\|\vec{w_0}\|}$$
 
$$\vec{u}^T \vec{X} = \vec{u}^T \cdot \vec{p}$$

 $\vec{u} = \frac{\vec{w_0}}{\|\vec{w_0}\|}$ -> pokazuje orijentaciju hiperravnine; ako je neka komponenta od  $\vec{u}$  jednaka 0 onda je hiperravnina paralelna s odgovarajućom koordinatnom osi

## Apsolutna vrijednost $\vec{u}^T \cdot \vec{p}$ :

 $\vec{u} = \frac{\vec{w_0}}{\|\vec{w_0}\|}$  i  $\vec{u}^T \cdot \vec{p} = -\frac{w_{n+1}}{\|\vec{w_0}\|}$ 

 $|\vec{u}^T \cdot \vec{p}|$  predstavlja udaljenost hiperravnine od ishodišta.


$$D_u = \frac{|w_{n+1}|}{\|\vec{w_0}\|}$$
  
Posljedice:

- Budući da je  $\vec{u}=\frac{\vec{w_0}}{\|\vec{w_0}\|}$  ispitivanjem vektora težinskih koeficijenata  $\vec{w_0}$  moguće je utvrditi da li je hiperravnina paralelna s bilo kojom koordinat-
- ullet ako je  $w_{n+1}=0$  onda hiperravnina prolazi kroz ishodište koordinatnog
- Udaljenost točke  $\vec{X}$  od hiperravnine je  $D_x = \left| \vec{u}^T \cdot \vec{p} \vec{u}^T \cdot \vec{X} \right| = \left| \frac{\vec{w_0}^T \cdot \vec{p}}{\|\vec{w_0}\|} \frac{w_{n+1} \vec{X}}{\|\vec{w_0}\|} \right|$

# SLUČAJ: VIŠE RAZREDA M>2

- više pristupa rješavanju problema linearnog klasifikatora za M>2 M=c, c>2

Primjer problem se može reducirati na c problema klasifikacije u dva razreda u kojem se i-ti problem rješava linearnom funkcjiom odlučivanja koja odvaja uzorke razreda  $\omega_i$  od svih ostalih razreda  $\omega_i$ .




Slika 15: Klasifikacija više razreda

1. slučaj: Granica između  $\omega_i; i=1,2,\ldots,c$  i preostalih razreda

$$d_i(\vec{X}) = w_{i1}x_1 + w_{i2}x_2 + \ldots + w_{in}x_n + w_{in+1} = 0$$


$$d_i(\vec{X}) = \vec{w_i}^T \vec{X} + w_{in+1}$$

deaj. Gramca između 
$$\omega_i, \ i=1,2,\dots,\ell$$
 i preostami razreda  $d_i(\vec{X}) = w_{i1}x_1 + w_{i2}x_2 + \dots + w_{in}x_n + w_{in+1} = 0$   $d_i(\vec{X}) = \vec{w_i}^T \vec{X} + w_{in+1}$  Svaki je razred uzoraka separabilan od ostalih razreda jednom decizijskom ravninom  $d_i(\vec{X}) = \vec{w_i}^T \vec{X} = \begin{cases} > 0 \text{ za } \vec{X} \in \omega_i \\ < 0 \text{ za } \vec{X} \notin \omega_i \end{cases}$ 



Slika 16: 1. slučaj

2. slučaj: Svaki razred uzoraka je separabilan sa svakim pojedinim (drugim razredom) i to jednom decizijskom ravninom /razredi su po parovima separabilni: M(M-1)/2 decizijskih ravnina/




Slika 17: 2. slučaj

Upotrijebi  $\frac{c(c-1)}{2}$ linearnih funkcija odlučivanja tako da svakom funkcijom odvojiš par (2) razreda

Granica između  $\omega_i$  i  $\omega_j$  je zadana s:  $d_i j(\vec{X}) = w_{ij1} x_1 + w_{ij2} x_2 + \ldots + w_{ijn} x_n + w_{ij_{n+1}} = 0$ 

3. slučaj: Postoji M decizijskih funkcija  $d_k(\vec{X}) = \vec{w_k}^T \vec{X}$ , k = 1, 2, ..., M sa svojstvom da  $\vec{X}$  pripada razredu  $\omega_i$  ako  $d_i(\vec{X}) > d_j(\vec{X})$  za sve  $j \neq i$ To je poseban slučaj 2. slučaja zato što možemo definirati  $d_{ij}(\vec{X}) = d_i(\vec{X}) - d_j(\vec{X}) = (\vec{w_i} - \vec{w_j})^T \vec{X} = \vec{w_{ij}}^T \vec{X}$ ;  $\vec{w_{ij}} = \vec{w_i} - \vec{w_j}$  ako je  $d_i(\vec{X}) > d_j(\vec{X})$  za sve  $j \neq i$ , tada je  $d_{ij}(\vec{X}) > 0$  za sve  $j \neq i$ , što znači: ako su razredi separabilni za 3. slučaj onda su automatski separabilni i za 2. slučaj.

 $d_{ij}(\vec{X}) = d_i(\vec{X}) - d_j(\vec{X}) = (w_{i1} - w_{j1})x_1 + (w_{i2} - w_{j2})x_2 + \ldots + (w_{in} - w_{jn})x_n + (w_{in+1} - w_{jn+1}) = 0$   $d_i(\vec{X}) = \vec{w_i}^T \cdot \vec{X} + w_{in+1} \text{ ako je } d_i(\vec{X}) > d_j(\vec{X}); i = 1, 2, \ldots; j \neq i \text{ onda}$   $\vec{X} \in \omega_i; \text{ klasifikator } -> \text{ linearni sroj (engl. linear machine)}$   $(\vec{w_i} - \vec{w_j})^T \vec{X} + (w_{in+1} - w_{jn+1}) = 0$ 



Slika 18: 3. slučaj

## ODREĐIVANJE FUNKCIJE ODLUČIVANJA -> UČENJE ILI VJEŽBANJE

Problem oblikovanja lineranog klasifikatora: odrediti koeficijente linearne funkcije odlučivanja:

$$\vec{W} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} i w_{n+1}$$

"Automatizirati" postupak određivanja koeficijenata linearne funkcije odluči-

iterativni postupak **učenja** koeficijenata linerane funkcije odlučivanja uporabom uzoraka iz skupa za učenje(engl. training set).

N uzoraka:  $\vec{X_1}, \vec{X_2}, \dots, \vec{X_N}$  razvrstani u dva razreda  $\omega_i$  i  $\omega_2$ Vektori uzoraka  $\vec{X_i}, i = 1, 2, \dots, N$  su <u>"označeni"</u> vektori, tj. oni sa poznatom pripadnosti razredu ( $\omega_i$  ili  $\omega_2$ ). **UPOTRIJEBIT ĆEMO IH ZA UČENJE**  $d(\vec{X})!$ 

Povećat ćemo dimentionalnost vektora  $\vec{X}$ za jedan

$$\vec{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} \text{ radi elegantnijeg zapisa: } d(\vec{X}) = \vec{W}^T \vec{X}$$

Uspijemo li odrediti takav vektor težinskih koeficijenata  $\vec{W}$  tako da pomoću funkcije  $d(\vec{X})$  pravilno razvrstamo sve uzorke (iz skupa za učenje), kažemo da su  $\omega_1$  i  $\omega_2$  LINEARNO RAZDVOJIVI.

M=2

 Uzorak  $\vec{X}$  je pravilno razvrstan ako za sve  $\vec{X}$  iz  $\omega_1$  vrijedi  $\vec{W}^T\vec{X}>0$  i ako za sve  $\vec{X}$  iz  $\omega_2$  vrijedi  $\vec{W}^T \vec{X} < 0$ 

Jedinstven uvjet:  $\vec{W}^T \vec{X} > 0$  ako uzorke iz  $\omega_2$  pmnožimo s -1!

Redefiniran problem: Tražimo vektor koeficijenata  $\vec{W}$ linearne funkcije odlučivanja tako da vrijedi  $\vec{W}^T \vec{X} > 0$  za sve uzorke za učenje. /PAZI: uzorci  $\vec{X} \in \omega_2$ su pomnoženi s -1/

odnosno  $[X]\vec{W}>$  za sve uzorke  $\vec{X}$ 

$$[X] = \begin{bmatrix} \vec{X}_1^T \\ \vec{X}_2^T \\ \vdots \\ \vec{X}_N^T \end{bmatrix}$$

je matrica svih uzoraka iz skupa za učenje s tim da su uzorci iz  $\omega_2$  pomnoženi

 $\vec{W} = (w_1, w_2, \dots, w_n, w_\ell n + 1)^T$  i  $\vec{0}$  - nulti vektor

PRIMJER 1: 
$$\vec{X}_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}; \vec{X}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad \vec{X}_1 \in \omega_1, \vec{X}_2 \in \omega_1$$
 
$$\vec{X}_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}; \vec{X}_4 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \vec{X}_3 \in \omega_2, \vec{X}_4 \in \omega_2$$

-POVEĆAJMO DIMENZIONALNOST VEKTORA: 
$$\vec{X_1} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}; \, \vec{X_2} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}; \, \vec{X_3} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}; \, \vec{X_4} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

POMONOŽIMO SVE UZORKE IZ RAZREDA  $\omega_2$  S -1:

$$\vec{X_3} = \begin{bmatrix} -1 \\ -0 \\ -1 \end{bmatrix}; \vec{X_4} = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

-Oblikujmo matricu [X]

$$[X] = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

 Vektor  $\vec{W}$  koji zadovoljava sustav linearnih nejednadžbi  $[X|\vec{W}>\vec{0}$  nazivamo razdvojni vektor.

### GRADIJENTNI POSTUPCI ODREĐIVANJA RAZDVO-JNOG VEKTORA

 $d(\vec{X})$  - funkcija vektorskog argumenta

Općenito:  $f(\vec{Y}), \vec{Y} = (y_1, y_2, \dots, y_n)^T$ 

Gradijent funkcije vektorskog argumenta:

$$\operatorname{grad} f(\vec{Y}) = \frac{df(\vec{Y})}{d\vec{Y}} = \begin{bmatrix} \frac{df}{dy_1} \\ \frac{df}{dy_2} \\ \vdots \\ \frac{df}{dy_n} \end{bmatrix}$$


### -GRADIJENT SKALARNE FUNKCIJE VEKTORSKOG ARUGU-MENTA JE VEKTOR

-svaka komponenta gradijenta predstavlja veličinu promjene funkcije u smjeru komponente vektora

18

#### VRIJEDI:

- Povećanje argumenta u smjeru pozitivnog gradijenta funkcije f dovodi nas do maksimuma funkcije f
- Povećanje argumenta u smjeru negativnog gradijenta funkcije f dovodi nas do minimuma funkcije f



Slika 19: Primjer gradijente metode