

$\vec{W}^T \vec{X}_i > 0$ za $i = 1, 2, \dots, N$
 $W_{[1 \times 3]}^T \vec{X}_{i[3 \times 1]} > 0_{[1 \times 1]}$ za $i = 1, 2, \dots, N$
 gdje je \vec{X}_i i-ti (transponirani) redak matrice $[X]$ dimenzija $N \times (n+1)$

OSNOVNA ZAMISAO:

IZABRATI NEKU FUNKCIJU KOJA ĆE DOSTIĆI MINIMUM KAD JE IS-
 PUNJEN UVJET: $\vec{W}^T \vec{X}_i > 0$ za $i = 1, 2, \dots, N$

-Zahtijevamo da izabrana funkcija ima samo jedan minimum (i naravno funkcija
 je funkcija vektorskog argumenta (\vec{W}))

apsolutna vrijednost!

UZMIMO FUNKCIJU : $J(\vec{W}, \vec{X}) = (\overbrace{\vec{W}^T \vec{X}} - \vec{W}^T \vec{X})$

-minimum funkcije $J(\vec{W}, \vec{X}) = 0$

-trivijalan slučaj $\vec{W} = 0$

-netrivijalan slučaj:

MINIMUM (KRITERIJSKE) FUNKCIJE $J(\vec{W}, \vec{X})$ POSTIŽE SE PRI ISPUN-
 JENJU UVJETA $\vec{W}^T \cdot \vec{X} > 0$

GRADIJENTNI POSTUPAK: KORAK PO KORAK POVEĆAVAMO ARGU-
 MENT \vec{W} U SMJERU NEGATIVNOG GRADIJENTA FUNKCIJE $J(\vec{W}, \vec{X})$
 SVE DOK NE POSTIGNEMO MINIMUM (KRITERIJSKE) FUNKCIJE $J(\vec{W}, \vec{X})$.

$\vec{W}(k)$ - vrijednost \vec{W} u k-tom koraku

$\vec{W}(k+1) = \vec{W}(k) - c \left\{ \frac{\partial J(\vec{W}, \vec{X})}{\partial \vec{W}} \right\}_{\vec{W}=\vec{W}(k)}$

$\vec{W}(k+1)$ - vrijednost "novog" vektora \vec{W} (u k+1 koraku)

c - pozitivna konstanta različita od 0, koja određuje količinu korekcije

/korekcija se više ne izvodi kada je $\frac{\partial J(\vec{W}, \vec{X})}{\partial \vec{W}} = \vec{0}$; što je uvjet za minimum!/
 /

Funkcija	Derivacija	
C (konst)	0	
x^n	nx^{n-1}	
$\frac{1}{x}$	$-\frac{1}{x^2}$	
$\frac{1}{x^n}$	$-\frac{n}{x^{n+1}}$	
\sqrt{x}	$\frac{1}{2\sqrt{x}}$	Derivacija funkcije s konst. faktorom
$\sqrt[n]{x}$	$\frac{1}{n \sqrt[n]{x^{n-1}}}$	
e^x	e^x	
a^x	$a^x \ln a$	
$\ln x$	$\frac{1}{x}$	

$(cu)' = c \cdot u'$

Derivacija produkta dvije ili nekoliko funkcija

$(uv)' = uv' + u'v$

$(uvw)' = uvw' + uv'w + u'vw$

Derivacija razlomaka

$\left(\frac{u}{v}\right)' = \frac{u \cdot v' - u'v}{v^2}$

Derivacija funkcije od funkcije (složene funkcije)

$y = f(u); u = \varphi(x)$ tada $\frac{dy}{dx} = f'(u) \cdot \varphi'(x)$

Derivacija složene funkcije od nekoliko varijabli: $u = f(x, y, \dots, t)$ gdje je

$x = \varphi(\xi)y = \psi(\xi) \dots t = \chi(\xi)$

$\frac{du}{d\xi} = \frac{\partial u}{\partial x} \frac{dx}{d\xi} + \frac{\partial u}{\partial y} \frac{dy}{d\xi} + \dots + \frac{\partial u}{\partial t} \frac{dt}{d\xi}$

Deriviranje lineranih funkcija:

$$\frac{d}{d\vec{X}}(\vec{X}^T A) = A$$

$$\frac{d}{d\vec{X}}(\vec{X}^T) = I$$

$$\frac{d}{d\vec{X}}(\vec{X}^T \vec{a}) = \frac{d}{d\vec{X}}(\vec{a}^T \vec{X}) = \vec{a}$$

$$\frac{d}{d\vec{X}}(\vec{a}^T X \vec{b}) = \vec{a} \vec{b}^T$$

$$\frac{d}{d\vec{X}}(\vec{a}^T X \vec{a}) = \frac{d}{d\vec{X}}(\vec{a}^T X^T \vec{a}) = \vec{a} \vec{a}^T$$

$$\frac{d}{d\vec{X}}(\vec{X}^T C \vec{X}) = (C + C^T) \vec{X}, \text{ ako je } C = C^T \text{ onda } \frac{d}{d\vec{X}}(\vec{X}^T C \vec{X}) = 2C \vec{X}$$

$$\frac{d}{d\vec{X}}(\vec{X}^T \vec{X}) = 2\vec{X}$$

$$\frac{d}{d\vec{X}}(A\vec{X} + b)^T(D\vec{X} + e) = A^T(D\vec{X} + e) + D^T(A\vec{X} + b)$$

a) Postupak učenja za kriterijsku funkciju


$$J(\vec{W}, \vec{X}) = \frac{1}{2}(|\vec{W}^T \vec{X}| - \vec{W}^T \vec{X})$$

-parcijalna derivacija funkcije:

$$\frac{\partial J}{\partial \vec{W}} = \frac{1}{2} [\vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) - \vec{X}]$$

$$\operatorname{sgn}(\vec{W}^T \vec{X}) = \begin{cases} 1 & \text{ako je } \vec{W}^T \vec{X} > 0 \\ -1 & \text{ako je } \vec{W}^T \vec{X} \leq 0 \end{cases}$$

$$\frac{d}{d\vec{X}}(\vec{X}^T \vec{a}) = \vec{a}, \operatorname{sgn}(x) = \begin{cases} 1 & \text{ako je } x > 0 \\ -1 & \text{ako je } x \leq 0 \end{cases}$$



Slika 1: Funkcija sgn

$$\text{UVRSTIMO } \frac{\partial J}{\partial \vec{W}} \text{ u } \vec{W}(k+1) = \vec{W}(k) - c \left\{ \frac{\partial J(\vec{W}, \vec{X})}{\partial \vec{W}} \right\}$$

$$\vec{W}(k+1) = \vec{W}(k) + \frac{c}{2} \left\{ \vec{X}(k) - \vec{X}(k) \operatorname{sgn} [\vec{W}^T(k) \vec{X}(k)] \right\}$$

$\vec{X}(k)$ - uzorak iz skupa za učenje koji se primjenjuje u k-tom koraku učenja

POSTUPAK PERCEPTRONA SA STALNIM PRIRASTOM (Rosenblatt, 1962.):

$$\vec{W}(k+1) = \vec{W}(k) + c \begin{cases} \vec{0} & \text{ako je } \vec{W}(k)^T \vec{X}(k) > 0 \\ \vec{X}(k) & \text{ako je } \vec{W}^T(k) \vec{X}(k) \leq 0 \end{cases}$$

PRIMJER:

$$\omega_1 = \{(0,0)^T, (0,1)^T\} \text{ i}$$

$$\omega_2 = \{(1,0)^T, (1,1)^T\}$$

-povećajmo dimenzionalnost prostora značajki na dimenziju n+1

$$\{(0,0,1)^T, (0,1,1)^T\}$$

$$\{(1,0,1)^T, (1,1,1)^T\}$$

-pomnožimo sve uzorke iz razreda ω_2 sa -1

$$\{(0,0,1)^T, (0,1,1)^T\}$$

$$\{(-1,0,-1)^T, (-1,-1,-1)^T\}$$

-pretpostavimo da su skupovi uzoraka za učenje razdvojivi linearnom funkcijom odlučivanja

$$d(\vec{X}) = w_1 x_1 + w_2 x_2 + w_3 = \vec{W}^T \vec{X}$$

-postupak perceptrona sa stalnim prirastom

Neka je c=1: neka je početni vektor koeficijenata $\vec{W}(1)$ proizvoljan, npr.

$$\vec{W}(1) = (-1, 0, 0)^T$$

-u prvom koraku učenja uzimamo uzorak $\vec{X}(1) = (0, 0, 1)^T$

Računamo:

$$\vec{W}^T(1) \vec{X}(1) = (-1, 0, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0,$$

$$\text{zbog toga } \vec{W}(2) = \vec{W}(1) + \vec{X}(1) = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

U drugom koraku uzimamo uzorak $\vec{X}(2) = (0, 1, 1)^T$

Računamo:

$$\vec{W}^T(2) \vec{X}(2) = (-1, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1,$$

Zato što je $\vec{W}^T(2) \vec{X}(2) > 0$, u skladu s postupkom učenja $\vec{W}(3) = \vec{W}(2)$

U trećem koraku upotrebljavamo uzorak $\vec{X}(3) = (-1, 0, -1)^T$

Računamo:

$$\vec{W}^T(3) \vec{X}(3) = (-1, 0, 1) \begin{pmatrix} -1 \\ 0 \\ -1 \end{pmatrix} = 0,$$

$$\vec{W}(4) = \vec{W}(3) + \vec{X}(3) = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

U četvrtom koraku upotrebljavamo uzorak $\vec{X}(4) = (-1, -1, -1)^T$

$$\text{Računamo: } \vec{W}^T(4) \vec{X}(4) = (-2, 0, 0) \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix} = 2,$$

Budući da je $\vec{W}^T(4)\vec{X}(4) > 0$ vrijedi $\vec{W}(5) = \vec{W}(4)$

RJEŠENJE ĆEMO DOBITI KADA NA TEMELJU IZRAČUNATOG \vec{W} PRAVILNO RAZVRSTAMO SVE UZORKE

-u ovom primjeru došlo je do pogrešnog razvrstavanja dva uzorka - POSLJEDICA \rightarrow popravljjanje vektora koef. funkcije odlučivanja \vec{W} . Postupak učenja nastavljamo tako da pretpostavimo $\vec{X}(5) = \vec{X}(1)$, $\vec{X}(6) = \vec{X}(2)$, $\vec{X}(7) = \vec{X}(3)$ i $\vec{X}(8) = \vec{X}(4)$

Dobivamo:

$$\vec{W}^T(5)\vec{X}(5) = 0 \text{ slijedi } \vec{W}(6) = \vec{W}(5) + \vec{X}(5) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(6)\vec{X}(6) = 1 \text{ slijedi } \vec{W}(7) = \vec{W}(6)$$

$$\vec{W}^T(7)\vec{X}(7) = 1 \text{ slijedi } \vec{W}(8) = \vec{W}(7) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(8)\vec{X}(8) = 1 \text{ slijedi } \vec{W}(9) = \vec{W}(8) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

I u drugom ponavljanju nisu bili razvrstani svi uzorci pravilno. Treća iteracija :

$$\vec{X}(9) = \vec{X}(1), \vec{X}(10) = \vec{X}(2), \vec{X}(11) = \vec{X}(3), \vec{X}(12) = \vec{X}(4)$$

$$\vec{W}^T(9)\vec{X}(9) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 \rightarrow \vec{W}(10) = \vec{W}(9)$$


$$\vec{W}^T(10)\vec{X}(10) = (-2, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1 \rightarrow \vec{W}(11) = \vec{W}(10)$$

$$\vec{W}^T(11)\vec{X}(11) = (-2, 0, 1) \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} = 3 \rightarrow \vec{W}(12) = \vec{W}(11)$$

$$\vec{W}^T(12)\vec{X}(12) = (-2, 0, 1) \begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix} = 1 \rightarrow \vec{W}(13) = \vec{W}(12)$$

$$\vec{W}^T = (-1, 0, 1)^T$$

$$\text{Decizijska funkcija } d(\vec{X}) = \underline{\vec{W}^T \vec{X} = -2x_1 + 1}$$



Slika 2: Primjer perceptrona

b) Postupak učenja za kriterijsku funkciju:

$$J(\vec{W}, \vec{X}) = \frac{1}{4\vec{X}^T \vec{X}} \left(\left| \vec{W}^T \vec{X} \right|^2 - \left| \vec{W}^T \vec{X} \right| \cdot \vec{W}^T \vec{X} \right)$$

Parcijalna derivacija kriterijske funkcije:

$$\frac{\partial J}{\partial \vec{W}} = \frac{1}{4\vec{X}^T \vec{X}} \left[2 \left| \vec{W}^T \vec{X} \right| \cdot \vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) - \left(\left| \vec{W}^T \vec{X} \right| \cdot \vec{X} + \vec{W}^T \vec{X} \cdot \vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) \right) \right]$$

$$\vec{W}^T \vec{X} \cdot \vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) = \left| \vec{W}^T \vec{X} \right| \cdot \vec{X}$$

$$\frac{\partial J}{\partial \vec{W}} = \frac{1}{4\vec{X}^T \vec{X}} \left[2 \left| \vec{W}^T \vec{X} \right| \cdot \vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) - 2 \left| \vec{W}^T \vec{X} \right| \cdot \vec{X} \right]$$

$$\frac{\partial J}{\partial \vec{W}} = \frac{1}{2\vec{X}^T \vec{X}} \left[\left| \vec{W}^T \vec{X} \right| \cdot \vec{X} \operatorname{sgn}(\vec{W}^T \vec{X}) - \left| \vec{W}^T \vec{X} \right| \cdot \vec{X} \right]$$

Postupak učenja :

$$\vec{W}(k+1) = \vec{W}(k) + \lambda \frac{|\vec{W}^T(k) \vec{X}(k)|}{2\vec{X}^T(k) \vec{X}(k)} \left[\vec{X}(k) - \vec{X}(k) \operatorname{sgn}(\vec{W}^T(k) \vec{X}(k)) \right]$$

$$\vec{W}(k+1) = \vec{W}(k) + \lambda \frac{|\vec{W}^T(k) \vec{X}(k)|}{2\vec{X}^T(k) \vec{X}(k)} \begin{cases} \vec{0} & \text{ako je } \vec{W}^T(k) \vec{X}(k) > 0 \\ \vec{X}(k) & \text{ako je } \vec{W}^T(k) \vec{X}(k) \leq 0 \end{cases}$$

λ - korekcijski faktor

- početna vrijednost \vec{W} različita od $\vec{0}$
- ako je $\lambda > 1$ promatrani uzorak se pravilno razvrstava nakon (svake) korekcije vektora \vec{W}
- postoji dokaz da postupak učenja konvergira (za linerano separabilne razrede) za $0 < \lambda < 2$;

Varijacije algoritma perceptrona

$$\vec{W}(k+1) = \vec{W}(k) + c \begin{cases} \vec{0} & \text{ako je } \vec{W}^T(k) \vec{X}(k) > 0 \\ \vec{X}(k) & \text{ako je } \vec{W}^T(k) \vec{X}(k) \leq 0 \end{cases}$$

varijacija u zavisnosti od izbora korekcijskog inkrementa c :

- 1) algoritam sa stalnim (čvrstim) prirastom (fixed-increment)
c=konst.>0

- 2) algoritam s apsolutnom korekcijom (absolute-correction)
c izabran tako da je dovoljno velik da jamči da će uzorak biti ispravno klasificiran nakon ugađanja težinskog faktora \vec{W}
Ako je $\vec{X}^T(k) \vec{X}(k) \leq 0$ izabire se c tako da vrijedi:

$$\vec{X}^T(k+1) \vec{X}(k) = \left[\vec{X}(k) + c \vec{X}(k) \right]^T \vec{X}(k) > 0, \text{ c je najmanji cijeli broj veći od } \frac{|\vec{W}^T(k) \vec{X}(k)|}{\vec{X}^T(k) \vec{X}(k)}$$

- 3) algoritam s djelomičnom korekcijom (fractional-correction)

c je izabran tako da je $\left| \vec{W}^T(k) \vec{X}(k) - \vec{W}^T(k+1) \vec{X}(k) \right|$ dio λ od $\left| \vec{W}^T(k) \vec{X}(k) \right|$:

$$\left| \vec{W}^T(k) \vec{X}(k) - \vec{W}^T(k+1) \vec{X}(k) \right| = \lambda \left| \vec{W}^T(k) \vec{X}(k) \right|$$

$$\text{Uvrstimo } \vec{W}(k+1) = \vec{W}(k) + c \vec{X}(k)$$

$$\left| \vec{W}^T(k) \vec{X}(k) - (\vec{W}^T(k) + c \vec{X}^T(k)) \vec{X}(k) \right| = \lambda \left| \vec{W}^T(k) \vec{X}(k) \right|$$

$$\text{Dobivamo: } c = \lambda \frac{|\vec{W}^T(k) \vec{X}(k)|}{\vec{X}^T(k) \vec{X}(k)}$$

-zahtijeva se da početna vrijednost vektora \vec{W} bude različita od $\vec{0}$


- za $\lambda > 1$ uzorak se pravilno razvrstava nakon svakog ugađanja tež. vektora
- za $0 < \lambda < 2$ postupak konvergira

PERCEPTRON (Rosenblatt, 1957)

-bionika (biologija-elektronika):

grana znanosti koja traži polazne točke za rješenje tehničkih problema u uzorima što ih čovjeku pruža sama priroda: primjena bioloških koncepata za izgradnju elektroničkih naprava

Perceptron - klasificira uzorke u jedan od dva razreda



Slika 3: Shema perceptrona

Jedinica u polju A generira izlaz različit od 0 ako je dovoljan broj senzorskih jedinica priključenih na A jedinicu pobuđen (aktivan).

x_i - odgovor i-te asocijativne jedinice

w_i - težinska vrijednost

Odgovor R proporcionalan je sumi odgovora A jedinica; odgovori su pomnoženi težinskim vrijednostima W_i :

$$R = \sum_{i=1}^{n+1} w_i x_i = \vec{W}^T \vec{X}$$

Pravilo klasifikacije:

- ako je $R > 0$ nepoznati se uzorak razvrstava u ω_1

- ako je $R \leq 0$ nepoznati se uzorak razvrstava u ω_2

Perceptron - klasifikator uzoraka u dva razreda - ako su razredi linearno separabilni

- modifikacija perceptrona za klasifikaciju uzoraka u $M > 2$ razreda:

M - jedinica R

R_1, R_2, \dots, R_M

Pravilo: uzorak se razvrstava u razred ω_i akko $R_i > R_j$ za sve $i \neq j$.

Osnovni model perceptrona može se raširiti na nelinearne decizijske funkcije umetanjem nelinearnog pretprocesora između A i R polja


-Višeslojni perceptron MLP

ALGORITAM PERCEPTRONA (Reward-Punishment Concept)

Algoritam učenja perceptrona:

- Zadana su dva skupa uzoraka za učenje koji pripadaju razredu ω_1 i ω_2
- $\vec{W}(1)$ početna vrijednost vektora težinskih koeficijenata-proizvoljno izabran
- k -ti korak učenja:
 - Ako $\vec{X}(k) \in \omega_1$ i $\vec{W}^T(k)\vec{X}(k) \leq 0$ zamijeni $\vec{W}(k)$ sa $\vec{W}(k+1) = \vec{W}(k) + c\vec{X}(k)$, gdje je c korekcijski faktor
 - Ako $\vec{X}(k) \in \omega_2$ i $\vec{W}^T(k)\vec{X}(k) \geq 0$ zamijeni $\vec{W}(k)$ sa $\vec{W}(k+1) = \vec{W}(k) - c\vec{X}(k)$, gdje je c korekcijski faktor; c mora biti pozitivan (i konstanta)
 - U drugim slučajevima ostavi $\vec{W}(k) \rightarrow \vec{W}(k+1) = \vec{W}(k)$

PRIMJER:



Slika 4: Prikaz primjera

$$\omega_1 : (0, 0, 1)^T, (0, 1, 1)^T$$

$$\omega_2 : (1, 0, 1)^T, (1, 1, 1)^T$$

$$c=1 \text{ i } \vec{W}(1) = \vec{0}$$

1. korak:

$$\vec{W}^T(1) \cdot \vec{X}(1) = (0, 0, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{W}(2) = \vec{W}(1) + \vec{X}(1) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

2. korak:

$$\vec{W}^T(2) \cdot \vec{X}(2) = (0, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

$$\vec{W}(3) = \vec{W}(2) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

3. korak:

$$\vec{W}^T(3) \cdot \vec{X}(3) = (0, 0, 1) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = 1$$

$$\vec{W}(4) = \vec{W}(3) - \vec{X}(3) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

4. korak:

$$\vec{W}^T(4) \cdot \vec{X}(4) = (-1, 0, 0) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -1$$

$$\vec{W}(4) = \vec{W}(3) = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

Zbog korekcija u 1. i 3. koraku postupak se ponavlja!

[*RJEŠENJE SEDOBIVASAMOKADALGORITAMDAJE POTPUNO ERROR – FREE ITERACIJA*]

(5)=(1), (6)=(2), (7)=(3) i (8)=(4)

DRUGA ITERACIJA DA JE :

5. korak :

$$\vec{W}^T(5) \cdot \vec{X}(5) = (-1, 0, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{W}(6) = \vec{W}(5) + \vec{X}(5) = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

6. korak:

$$\vec{W}^T(6) \cdot \vec{X}(6) = (-1, 0, 1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

$$\vec{W}(7) = \vec{W}(6) = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

7. korak:

$$\vec{W}^T(7) \cdot \vec{X}(7) = (-1, 0, 1) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{W}(8) = \vec{W}(7) - \vec{X}(7) = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

8. korak:

$$\vec{W}^T(8) \cdot \vec{X}(8) = (-2, 0, 0) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -2$$

$$\vec{W}(9) = \vec{W}(8) = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

Dogodile su se dvije pogreške!

Nova iteracija

$$\vec{X}(9) = \vec{X}(1), \vec{X}(10) = \vec{X}(2), \vec{X}(11) = \vec{X}(3) \text{ i } \vec{X}(12) = \vec{X}(4)$$

$$\vec{W}^T(9) \cdot \vec{X}(9) = 0 \quad \vec{W}(10) = \vec{W}(9) + \vec{X}(9) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(10) \cdot \vec{X}(10) = 1 \quad \vec{W}(11) = \vec{W}(10) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(11) \cdot \vec{X}(11) = -1 \quad \vec{W}(12) = \vec{W}(11) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(12) \cdot \vec{X}(12) = -1 \quad \vec{W}(13) = \vec{W}(12) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

Dogodila se pogreška!

Nova iteracija:

$$\vec{X}(13) = \vec{X}(1), \vec{X}(14) = \vec{X}(2), \vec{X}(15) = \vec{X}(3) \text{ i } \vec{X}(16) = \vec{X}(4)$$

$$\vec{W}^T(13) \cdot \vec{X}(13) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 \quad \vec{W}(14) = \vec{W}(13) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(14) \cdot \vec{X}(14) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 \quad \vec{W}(15) = \vec{W}(14) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(15) \cdot \vec{X}(15) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = -1 \quad \vec{W}(16) = \vec{W}(15) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{W}^T(16) \cdot \vec{X}(16) = (-2, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = -1 \quad \vec{W}(17) = \vec{W}(16) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$d(\vec{X}) = -2x_1 + 1 \leftarrow \vec{W} = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

Treća metoda:
LMSE (Least-Mean-Square-Error)
(Ho-Kashyap algorithm, 1965)

- Algoritam perceptrona (i njegove varijacije) konvergira kada su razredi linearno razdvojni
- Ne može se sa sigurnosti utvrditi da li duga sekvenca učenja znači i da su razredi linearno separabilni
- Algoritam koji brže konvergira i ima ugrađen mehanizam za detekciju slučaja kad razredi nisu linearno separabilni

Umjesto nalaženja vektora \vec{W} tako da vrijedi $[X]\vec{W} > \vec{0}$ tražit ćemo vektore \vec{W} i \vec{b} tako da vrijedi $[X]\vec{W} = \vec{b}$, gdje je $\vec{b} = (b_1, b_2, \dots, b_N)^T$ takav da su sve njegove komponente b_i , $i = 1, 2, \dots, N$, pozitivne.

Kriterijska funkcija:

$J(\vec{W}, \vec{X}, \vec{b}) = \frac{1}{2} \sum_{j=1}^N (\vec{W}^T \vec{X}_j - b_j)^2 = \frac{1}{2} \|[X]\vec{W} - \vec{b}\|^2$, gdje $\|[X]\vec{W} - \vec{b}\|$ označava veličinu vektora $([X]\vec{W} - \vec{b})$.

Kriterijska funkcija $J(\vec{W}, \vec{X}, \vec{b})$ postiže minimum kada je $[X]\vec{W} = \vec{b}$

Umjesto traženja vektora \vec{W} koji zadovoljava nejednadžbu tražimo vektore \vec{W} i \vec{b} tako da je zadovoljena jednadžba: $[X]\vec{W} = \vec{b}$

- Možemo obje varijable \vec{W} i \vec{b} upotrijebiti u minimizacijskoj proceduri
- Očekujemo poboljšani postupak (brži) konvergencije
- Gradijenti:

$$\begin{aligned}\frac{\partial J}{\partial \vec{W}} &= [X]^T ([X]\vec{W} - \vec{b}) \\ \frac{\partial J}{\partial \vec{b}} &= -([X]\vec{W} - \vec{b})\end{aligned}$$

Vektor \vec{W} nije ograničen i možemo postaviti:

$$\frac{\partial J}{\partial \vec{W}} = 0$$

$$[X]^T ([X]\vec{W} - \vec{b}) = \vec{0}$$

$$[X]^T [X]\vec{W} - [X]^T \vec{b} = \vec{0}$$

$$[X]^T [X]\vec{W} = [X]^T \vec{b} / ([X]^T [X])^{-1}$$

$$\vec{W} = ([X]^T [X])^{-1} [X]^T \vec{b}$$

$$\vec{W} = [X]^\# \vec{b} \quad (**)$$

$$[X]^\# = ([X]^T [X])^{-1} [X]^T; \text{ generalized inverse of } [X]$$

Vektor \vec{b} je ograničen - to je vektor sa svim pozitivnim komponentama

Vektor \vec{b} treba tako mijenjati da uvijek budu zadovoljeno: $b_i > 0$ za $i = 1, 2, \dots, N$

To se postiže na ovaj način:

$$\vec{b}(k+1) = \vec{b}(k) + \delta \vec{b}(k), \quad (***)$$

$$\text{gdje je } \delta \vec{b}_i(k) = \begin{cases} 2c \left[[X]\vec{W}(k) - \vec{b}(k) \right]_i & \text{ako je } \left[[X]\vec{W}(k) - \vec{b}(k) \right]_i > 0 \\ 0 & \text{ako je } \left[[X]\vec{W}(k) - \vec{b}(k) \right]_i \leq 0 \end{cases} \quad (*)$$

$$\frac{\partial J}{\partial \vec{b}} = -([X]\vec{W} - \vec{b})$$

Jednadžbu (*) zapišemo u vektorskom obliku:

$$\delta \vec{b}(k) = c \left[\overbrace{[X]\vec{W}(k) - \vec{b}(k)}^{\vec{e}(k)} + \overbrace{[X]\vec{W}(k) - \vec{b}(k)}^{\vec{e}(k)} \right]$$

gdje $\left| [X]\vec{W}(k) - \vec{b}(k) \right|$ označava apsolutnu vrijednost svake komponente vektora $[X]\vec{W}(k) - \vec{b}(k)$

Iz jednadžbi (**) i (***) dobivamo:

$$\vec{W}(k+1) = [X]^\# \vec{b}(k+1) = [X]^\# [\vec{b}(k) + \delta \vec{b}(k)] = [X]^\# \vec{b}(k) + [X]^\# \delta \vec{b}(k) = \vec{W}(k) + [X]^\# \delta \vec{b}(k)$$

$$\text{Označimo } \vec{e}(k) = [X]\vec{W}(k) - \vec{b}(k)$$

Ho-kashyap / LMSE Algoritam:

$\vec{W}(1) = [X]^\# \vec{b}(1)$, $\vec{b}(1)$ proizvoljan uz uvjet $b_i > 0$ za sve i

$$\vec{e}(k) = [X]\vec{W}(k) - \vec{b}(k)$$

$$\vec{W}(k+1) = \vec{W}(k) + c[X][\vec{e}(k) - |\vec{e}(k)|]$$

$$\vec{b}(k+1) = \vec{b}(k) + c[\vec{e}(k) - |\vec{e}(k)|]$$

$\vec{W}(k+1)$ može se izračunati i kao:

$$\vec{W}(k+1) = [X]^\# \vec{b}(k+1)$$

Napomena: $|\vec{e}(k)|$ označava vektor čije su komponente apsolutne vrijednosti komponenti vektora $\vec{e}(k)$.

Važno svojstvo algoritma:

- Ako su u bilo kojem iteracijskom koraku sve komponente vektora $\vec{e}(k)$ ne pozitivne (ali ne jednake 0) razredi su linearno neseperabilni!
- Kada je $\vec{e}(k) = \vec{0}$ $\vec{W}(k)$ je rješenje!

Osnovna značajka algoritma:

- Ako rješenje za nejednadžbu $[X]\vec{W} > \vec{0}$ postoji. postupak konvergira za $0 < c \leq 1$
- Razredi nisu separabilni s linearnom decizijskom funkcijom ako u bilo kojem koraku postupka nisu sve komponente vektora $\vec{e}(k)$ pozitivne ili jednake nuli
- Ako je $\vec{e}(k) = \vec{0}$ znači da vrijedi $[X]\vec{W}(k) = \vec{b}(k)$, tj. $\vec{W}(k)$ je rješenje
- Postupak brže konvergira negoli postupak perceptrona i nalazi "bolje" granice između razreda


PRIMJER 1:

$$\omega_1 = (0, 0)^T, (0, 1)^T$$

$$\omega_2 = (1, 0)^T, (1, 1)^T$$

povećajmo vektor i pomnožimo uzorke iz razreda ω_2 sa -1, te tvorimo matricu $[X]$

$$[X] = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}_{4 \times 3}$$



Slika 5: Prikaz primjera 1

Potražimo: $[X]^\# = ([X]^T[X])^{-1}[X]^T$

$$[X]^\# = \frac{1}{2} \begin{bmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & 1 & -1 \\ \frac{3}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

Neka je $\vec{b}(1) = (1, 1, 1, 1)^T$ i $c=1$; $b_i > 0$

$$\vec{W}(1) = [X]^\# \vec{b}(1) = \begin{pmatrix} -2 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{e}(1) = [X] \vec{W}(1) - \vec{b}(1) = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$\vec{W}(1) = (-2, 0, 1)^T$ traženo rješenje

$$d(\vec{X}) = -2x_1 + 1$$

PRIMJER 2:

$$\omega_1 = (0, 0)^T, (1, 1)^T$$

$$\omega_2 = (0, 1)^T, (1, 0)^T$$


Razredi nisu linearno separabilni (XOR problem)

$\vec{b}(1) = (1, 1, 1, 1)^T$ i $c=1$

$$[X] = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 1 & 1 \\ 0 & -1 & -1 \\ -1 & 0 & -1 \end{bmatrix}$$

Izračunajmo $[X]^\# = ([X]^T[X])^{-1}[X]^T$

$$[X]^\# = \frac{1}{2} \begin{bmatrix} -\frac{1}{2} & \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \\ \frac{3}{4} & -\frac{1}{4} & -\frac{1}{4} & -\frac{1}{4} \end{bmatrix}$$



Slika 6: Prikaz primjera 2

$$\vec{W}(1) = [X]^\# \vec{b}(1) = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$\vec{e}(1) = [X] \vec{W}(1) - \vec{b}(1) = \begin{pmatrix} -1 \\ -1 \\ -1 \\ -1 \end{pmatrix}$$

$\vec{e}(1)$ negativno $[X] \vec{W} > 0$ nema rješenja

UČENJE ZA SLUČAJ $M > 2$ RAZREDA

- Problem učenja koeficijenata linearne decizijske funkcije za $M > 2$ razreda skupa za učenje može se riješiti poopćenim postupkom perceptrona ali i postupkom Ho-Kashyapa.

Podsjetimo se: 3. slučaja

1. slučaj: svaki od $M > 2$ razreda separatibilan od ostalih razreda jednom decizijskom (hiper)ravninom; (Traži se $M > 2$ decizijskih funkcija)

2. slučaj: svaki je razred separatibilan od svakog drugog razreda; (Traži se $M/(M-1)/2$ decizijskih funkcija)

3. slučaj: postoji M decizijskih funkcija: d_1, d_2, \dots, d_M ; $\vec{X} \in \omega_i$ ako $d_i(\vec{X}) > d_j(\vec{X})$; $i \neq j$ $i=1, 2, \dots, M$

3. slučaj \rightarrow Poopćeni algoritam perceptrona -istodobno određivanje težinskih koeficijenata; $\vec{W}_1, \vec{W}_2, \dots, \vec{W}_M$

- M razreda uzoraka za učenje: $\omega_1, \omega_2, \dots, \omega_M$

U k -tom koraku postupka: $\vec{X}(k)$ - uzorak iz skupa za učenje $\vec{X}(k) \in \omega_i$

Računamo M decizijskih funkcija: $d_j(\vec{X}(k)) = \vec{W}_j^T(k) \vec{X}(k)$; $j = 1, 2, \dots, M$

Ako je $d_i(\vec{X}(k)) > d_j(\vec{X}(k)); j = 1, 2, \dots, M, j \neq i$ težinski vektori se ne "popravljaju":

$$\vec{W}_j(k+1) = \vec{W}_j(k), j = 1, 2, \dots, M$$

Ako je $d_i(\vec{X}(k)) \leq d_l(\vec{X}(k))$ popravljaju se vrijednosti težinskih vektora:

$$\vec{W}_i(k+1) = \vec{W}_i(k) + c\vec{X}(k)$$

$$\vec{W}_l(k+1) = \vec{W}_l(k) - c\vec{X}(k)$$

$$\vec{W}_j(k+1) = \vec{W}_j(k) \text{ za } j = 1, 2, \dots, M, j \neq i, j \neq l, c\text{-pozitivna konstanta}$$


Postupak konvergira u konačnom broju ponavljanja za proizvoljno izabrane početne vrijednosti vektora težinskih koeficijenata $\vec{W}_j(1); j = 1, 2, \dots, M$ ako su razredi linearno separabilni.

Fisherova linearna diskriminanta

Jedan od pristupa linearnoj klasifikaciji:

d-dimenzionalan vektor značajki \vec{X} reducirati na jednu dimenziju (R^{d1}) i tada ga upotrijebiti za klasifikaciju!

Prvo: $M=2; \omega_1$ i ω_2




Slika 7: Prikaz FLD

Naći orijentaciju pravca na koji se projiciraju d-dimenzionalni uzorci \vec{X}_i $i = 1, 2, \dots, n$, ali tako da su projicirani uzorci separabilni → CILJ "KLASIČNE" DISKRIMINANTNE ANALIZE

Skup od n d-dimenzionalnih uzoraka: $\vec{X}_1, \vec{X}_2, \dots, \vec{X}_n$ od toga n_1 uzoraka čini podskup \mathcal{D}_1 (označeni s ω_1) i n_2 uzoraka u podskupu \mathcal{D}_2 (označeni s ω_2); $n = n_1 + n_2$.
 Tvorimo linearnu kombinaciju komponenti \vec{X} : $y_i = \vec{W}^T \vec{X}_i$, $i = 1, 2, \dots, n$.
 Dobivamo odgovarajući skup od n uzoraka y_1, y_2, \dots, y_n koji su podijeljeni u podskupove \mathcal{Y}_1 i \mathcal{Y}_2 .

Ako je $\|\vec{W}\| = 1$, svaki y_i je projekcija odgovarajućeg vektora \vec{X}_i na pravac (u smjeru \vec{W})



Slika 8: Prikaz projekcije \vec{X}_i na \vec{W}

Veličina vektora \vec{W} nema posebno značenje (ona samo skalira y_i) važan je smjer od \vec{W} !

- Ako zamislimo da uzorci iz ω_1 čine nakupinu, te da uzorci iz ω_2 čine drugu nakupinu ŽELIMO DA PROJEKCIJE NA PRAVAC ODREĐEN S \vec{W} BUDU TAKVE DA SU DOBRO ODVOJIVE!

NAĆI NAJBOLJI SMJER \vec{W} !

Mjera odvojivosti između projiciranih točaka: razlika srednjih vrijednosti projiciranih uzoraka;

Neka je $\vec{m}_i = \frac{1}{n_i} \sum_{\vec{X} \in \mathcal{D}_i} \vec{X}$; $i=1,2$

Srednja vrijednost projiciranih uzoraka $\tilde{m}_i = \frac{1}{n_i} \sum_{y \in \mathcal{Y}_i} y$

Da li je udaljenost srednjih vrijednosti projiciranih uzoraka "dobra mjera"?

$$\tilde{m}_i = \frac{1}{n_i} \sum_{\vec{X} \in \mathcal{D}_i} \vec{W}^T \vec{X} = \vec{W}^T \vec{m}_i$$


\tilde{m}_i je projekcija vektora \vec{m}_i

Razlika između srednjih vrijednosti projiciranih uzoraka:

$$|\tilde{m}_1 - \tilde{m}_2| = \left| \vec{W}^T (\vec{m}_1 - \vec{m}_2) \right|$$

Razliku možemo načiniti proizvoljno velkom skaliranjem \vec{W} !

Da bismo dobili dobro odvajanje projiciranih podataka želimo da "udaljenost" između srednjih vrijednosti projiciranih točaka bude relativno velika u odnosu



Slika 9: Odvojivost s obzirom na smjer \vec{W}

na neku mjeru standardne devijacije za svaki razred!

$$J(\vec{W}) = \frac{(\bar{m}_1 - \bar{m}_2)^2}{\hat{G}_1^2 + \hat{G}_2^2} = \frac{(\text{razlika srednjih vrijednosti})^2}{(\text{varijanca uzoraka unutar razreda})}$$

Fisherova linearna diskriminanta određuje da linearna funkcija $\vec{W}^T \vec{X}$ za koju je kriterijska funkcija $J(\vec{W})$ maksimalna vodi najboljem razdvajanju između projiciranih skupova.

$J(\vec{W}) = \frac{(\bar{m}_1 - \bar{m}_2)^2}{\hat{G}_1^2 + \hat{G}_2^2}$, gdje je \hat{G}_i^2 mjera raspršenosti podataka (projiciranih) unutar razreda i .

Umjesto varijanci \hat{G}_i^2 možemo definirati raspršenost projiciranih podataka unutar razreda i kao:

$$\tilde{s}_i^2 = \sum_{y \in \mathcal{Y}_i} (y - \bar{m}_i)^2$$

$\frac{1}{n}(\tilde{s}_1^2 + \tilde{s}_2^2)$ je procjena varijance podataka i $\tilde{s}_1^2 + \tilde{s}_2^2$ je ukupna mjera raspršenosti projiciranih podataka unutar razreda (total within-class scatter).

$$J(\vec{W}) = \frac{(\bar{m}_1 - \bar{m}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2}$$

želimo dobiti $J(\cdot)$ kao eksplicitnu funkciju od \vec{W} ;

Definirajmo matricu S_i :

$$S_i = \sum_{\vec{X} \in \mathcal{D}_i} (\vec{X} - \bar{m}_i)(\vec{X} - \bar{m}_i)^T \text{ (raspršenost unutar razreda } \omega_i)$$

$$S_W = S_1 + S_2$$

$$\tilde{s}_i^2 = \sum_{\vec{X} \in \mathcal{D}_i} (\vec{W}^T \vec{X} - \vec{W}^T \bar{m}_i)^2 = \sum_{\vec{X} \in \mathcal{D}_i} \vec{W}^T \overbrace{(\vec{X} - \bar{m}_i)(\vec{X} - \bar{m}_i)^T}^{S_i} \vec{W}$$

$$\tilde{s}_i^2 = \vec{W}^T S_i \vec{W}$$

$$\text{suma: } \tilde{s}_1^2 + \tilde{s}_2^2 = \vec{W}^T S_W \vec{W} \quad (*)$$

slično:

$$(\bar{m}_1 - \bar{m}_2)^2 = (\vec{W}^T \bar{m}_1 - \vec{W}^T \bar{m}_2)^2 = \vec{W}^T (\bar{m}_1 - \bar{m}_2)(\bar{m}_1 - \bar{m}_2)^T \vec{W} = \vec{W}^T S_B \vec{W}$$


(**)

$$S_B = (\bar{m}_1 - \bar{m}_2)(\bar{m}_1 - \bar{m}_2)^T$$

$S_W = S_1 + S_2$ - within-class scatter matrix

S_B - between-class scatter matrix

S_W i $S_B \rightarrow$ simetrična i pozitivno semidefinitna i obično nesingularna ako je



Slika 10: Usporedba srednjih vrijednosti

$n > d$ d-dimenzionalnost podataka

$$J(\vec{W}) = \frac{\vec{W}^T S_B \vec{W}}{\vec{W}^T S_W \vec{W}}$$

Uzorci iz skupova podataka \mathcal{D}_1 i \mathcal{D}_2 se koriste za određivanje S_W i S_B .

Tražimo maksimum $J(\vec{W})$!

$$\frac{\partial J}{\partial \vec{W}} = \vec{0}$$

$$\frac{\partial J(\vec{W})}{\partial \vec{W}} = \frac{\partial}{\partial \vec{W}} \left(\frac{\vec{W}^T S_B \vec{W}}{\vec{W}^T S_W \vec{W}} \right) = \vec{0} \quad \left(\frac{u}{v} \right)' = \frac{vu' - uv'}{v^2}$$

$$\frac{(\vec{W}^T S_W \vec{W}) \frac{\partial}{\partial \vec{W}} (\vec{W}^T S_B \vec{W}) - (\vec{W}^T S_B \vec{W}) \frac{\partial}{\partial \vec{W}} (\vec{W}^T S_W \vec{W})}{(\vec{W}^T S_W \vec{W})^2} = \vec{0}$$

$$(\vec{W}^T S_W \vec{W}) \cdot 2S_B \vec{W} - (\vec{W}^T S_B \vec{W}) \cdot 2S_W \vec{W} = \vec{0}$$

$$S_W \hat{\vec{W}} (\hat{\vec{W}}^T S_B \hat{\vec{W}}) (\hat{\vec{W}}^T S_W \hat{\vec{W}})^{-1} = S_B \hat{\vec{W}}$$

$$\text{skalar} \rightarrow \lambda = (\hat{\vec{W}}^T S_B \hat{\vec{W}}) (\hat{\vec{W}}^T S_W \hat{\vec{W}})^{-1}$$

$$\lambda S_W \hat{\vec{W}} = S_B \hat{\vec{W}}$$

Generalizirani problem svojstvenog vektora

Ako S_W^{-1} postoji, onda je smjer (pazi: samo smjer) \vec{W} -a

$$\hat{\vec{W}} = (S_W^{-1} S_B) \hat{\vec{W}}$$

Za naš slučaj nije potrebno rješavati to na takav način da tražimo svojstvene vrijednosti i svojstvene vektore za $S_W^{-1} S_B$ zato što $S_B \vec{W}$ je uvijek usmjerena kao $\vec{m}_1 - \vec{m}_2$

Budući da nas faktor skaliranja za vektor \vec{W} ne zanima (zanima nas samo njegov smjer!) možemo napisati rješenje za $\hat{\vec{W}}$:

$$\vec{m}_1 = \begin{bmatrix} m_{11} \\ m_{12} \\ m_{13} \end{bmatrix}_{[3 \times 1]} \quad \vec{m}_2 = \begin{bmatrix} m_{21} \\ m_{22} \\ m_{23} \end{bmatrix}_{[3 \times 1]}$$

$$S_B = (\vec{m}_1 - \vec{m}_2)(\vec{m}_1 - \vec{m}_2)^T$$

$$S_B = (\vec{m}_1 - \vec{m}_2)_{[3 \times 1]} \cdot (\vec{m}_1 - \vec{m}_2)_{[1 \times 3]}^T = S_{B[3 \times 3]}$$

smjer $S_B \cdot \vec{W}$?

$$S_B \cdot \vec{W} = (\vec{m}_1 - \vec{m}_2)_{[3 \times 1]} \cdot \underbrace{(\vec{m}_1 - \vec{m}_2)_{[1 \times 3]}^T}_{k_{[1 \times 1]}} \cdot \vec{W}_{[3 \times 1]}$$

$S_B \cdot \vec{W} = (\vec{m}_1 - \vec{m}_2) \cdot k$; očito je $S_B \vec{W}$ usmjeren s $(\vec{m}_1 - \vec{m}_2)$

$$\hat{\vec{W}} = S_W^{-1}(\vec{m}_1 - \vec{m}_2)$$

$\hat{\vec{W}}$ u skladu s FLD nam određuje linearnu funkciju koja maksimizira omjer između raspršenja između razreda i raspršenja unutar razreda.

PROBLEM SVOJSTVENIH VRIJEDNOSTI I SVOJSTVENIH VEKTORA (EIGENVALUE/EIGENVECTOR PROBLEM)

Osnovno:

-Kvadratna matrica A $n \times n$

Da li postoji skalar λ i vektor \vec{X} tako da vrijedi:

$$A\vec{X} = \lambda\vec{X} \quad ?$$

Drugim riječima, $A\vec{X}$ ima isti smjer u R^n kao \vec{X} i skaliran je s faktorom λ .

Trivijalno rješenje: $\vec{X} = \vec{0}$

$$(A - \lambda I)\vec{X} = \vec{0}$$

$$\vec{X} = (A - \lambda I)^{-1}\vec{0}$$

Podsjetimo se $(A - \lambda I)^{-1}$ postoji ako je $|A - \lambda I| \neq 0$, $| \cdot |$ označava determinantu.

Netrivijalno rješenje za \vec{X} zahtijeva $|A - \lambda I| = 0$ za $n \times n$ matricu to daje polinom po λ stupnja n $|A - \lambda I| = \lambda^n + a_1\lambda^{n-1} + \dots + a_{n-1}\lambda + a_n = 0$; karakteristična jednačba (polinom) matrice A $P(\lambda)$

n rješenja za λ - svojstvene vrijednosti od A (e-values)

a odgovarajući vektori \vec{X} su - svojstveni vektori (e-vectors)

PRIMJER:

Naći svojstvene vrijednosti i njima pridružene svojstvene vektore za matricu

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 2 \end{bmatrix}.$$

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 2 \end{bmatrix}$$

Tražimo λ i vektor \vec{X} različit od $\vec{0}$ tako da vrijedi $A\vec{X} = \lambda\vec{X}$

$$\begin{bmatrix} 1 & 2 \\ 3 & 2 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$x_1 + 2x_2 = \lambda x_1 \quad \text{ili} \quad (\lambda - 1)x_1 - 2x_2 = 0$$

$$3x_1 + 2x_2 = \lambda x_2 \quad \text{ili} \quad -3x_1 + (\lambda - 2)x_2 = 0$$

Homogen sustav ima rješenje različito od 0 akko je determinanta matrica koeficijena jednaka 0.

$$\begin{vmatrix} \lambda - 1 & -2 \\ -3 & \lambda - 2 \end{vmatrix} = \lambda^2 - 3\lambda - 4 = (\lambda - 4)(\lambda + 1)$$

λ je svojstvena vrijednost matrice A akko je $\lambda = 4$ ili $\lambda = -1$

Uzmimo $\lambda = 4$

$$3x_1 - 2x_2 = 0$$

$$-3x_1 + 2x_2 = 0 \quad \text{ili} \quad 3x_1 - 2x_2 = 0$$

$$x_1 = \frac{2}{3}x_2 \quad \text{uzmimo: } x_2 = 3 \quad \text{onda je } x_1 = 2$$

Dobivamo svojstveni vektor $\vec{X} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ koji pripada svojstvenoj vrijednosti $\lambda = 4$.

Svaki drugi vektor \vec{X} pomnožen s k je također e-vektor

$$\begin{bmatrix} 1 & 2 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 3 \end{bmatrix} = 4 \begin{bmatrix} 2 \\ 3 \end{bmatrix}$$

$$\begin{bmatrix} 1 \cdot 2 + 2 \cdot 3 \\ 3 \cdot 2 + 2 \cdot 3 \end{bmatrix} = \begin{bmatrix} 8 \\ 12 \end{bmatrix} = 4 \begin{bmatrix} 2 \\ 3 \end{bmatrix}$$

Uzmimo $\lambda = -1$

$$(\lambda - 1)x_1 - 2x_2 = 0 \quad \rightarrow \quad -2x_1 - 2x_2 = 0$$

$$-3x_1 + (\lambda - 2)x_2 = 0 \quad \rightarrow \quad -3x_1 - 3x_2 = 0$$

$$x + y = 0 \quad \rightarrow \quad x = -y$$

$\vec{X} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ svojstveni vektor koji pripada e-vrijednosti $\lambda = -1$