

1 Višestruka diskriminantna analiza (Multiple Discriminant Analysis)

Problem c-razreda:

D_1, D_2, \dots, D_c odnosno $\omega_1, \omega_2, \dots, \omega_c$

Generalizirana FLD uključuje c-1 diskriminantnih funkcija :

Projekcija d-dimenzionalnog prostora u (c-1)-dimenzionalni prostor ($d \geq c$)

Generalizirana matrica raspršenosti unutar razreda (within-class scatter matrix):

$S_W = \sum_{i=1}^c S_i$, gdje je $S_i = \sum_{\vec{X} \in D_i} (\vec{X} - \vec{m}_i)(\vec{X} - \vec{m}_i)^T$ i $\vec{m}_i = \frac{1}{n_i} \sum_{\vec{X} \in D_i} \vec{X}$

Matrica S_B kao generalizirana ne dobiva se tako očigledno:

- ukupan vektor srednje vrijednosti $\vec{m} = \frac{1}{n} \sum_{\vec{X}} \vec{X} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$, gdje je n_i broj uzoraka u razredu D_i (ω_i), \vec{m}_i - vektor srednje vrijednosti vektora iz razreda ω_i
- ukupna matrica raspršenosti S_T

$$S_T = \sum_{\vec{X}} (\vec{X} - \vec{m})(\vec{X} - \vec{m})^T$$

$$S_T = \sum_{i=1}^c \sum_{\vec{X} \in D_i} (\vec{X} - \vec{m}_i + \vec{m}_i - \vec{m})(\vec{X} - \vec{m}_i + \vec{m}_i - \vec{m})^T$$

$$S_T = \sum_{i=1}^c \sum_{\vec{X} \in D_i} (\vec{X} - \vec{m}_i)(\vec{X} - \vec{m}_i)^T + \sum_{i=1}^c \sum_{\vec{X} \in D_i} (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_T = S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

Drugi član:

$\sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$ je poopćena matrica raspršenosti između razreda

S_B

$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$

$S_T = S_W + S_B$

Projekcija iz d-dimenzionalnog prostora u (c-1)-dimenzionalni prostor uporabom (c-1) diskriminantnih funkcija $y_i = \vec{W}_i^T \vec{X}$ $i = 1, 2, \dots, c-1$

Ako y_i promatramo kao komponentu vektora \vec{Y} i težinske vektore \vec{W}_i kao stupce $d \times (c-1)$ matrice W tada je projekcija:

$\vec{Y} = W^T \vec{X}$

Uzorci $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$ projiciraju se u odgovarajući skup uzoraka $\vec{y}_1, \vec{y}_2, \dots, \vec{y}_n$ koji mogu biti opisani svojim srednjim vektorima i matricama raspršenosti:

$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{y} \in \mathcal{Y}_i} \vec{y}$

$\vec{m} = \frac{1}{n} \sum n_i \vec{m}_i$

$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} (\vec{y} - \vec{m}_i)(\vec{y} - \vec{m}_i)^T$

$\tilde{S}_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$

$\tilde{S}_W = W^T S_W W$

$\tilde{S}_B = W^T S_B W$

$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} (\vec{y} - \vec{m}_i)(\vec{y} - \vec{m}_i)^T$

$\vec{y} = W^T \vec{X}$ $\vec{m}_i = W^T \vec{m}_i$

$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} (W^T \vec{X} - W^T \vec{m}_i)(W^T \vec{X} - W^T \vec{m}_i)^T$

$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} W^T (\vec{X} - \vec{m}_i)(\vec{X} - \vec{m}_i)^T W$

$$\tilde{S}_W = W^T \underbrace{\sum_{i=1}^c \sum_{\vec{y} \in \mathcal{Y}_i} (\vec{X} - \vec{m}_i)(\vec{X} - \vec{m}_i)^T}_{S_W} W$$

$$S_i = \sum_{\vec{X} \in D_i} (\vec{X} - \vec{m}_i)(\vec{X} - \vec{m}_i)^T$$

$$S_W = \sum_{i=1}^c S_i$$

$$\tilde{S}_W = W^T S_W W$$

$$\tilde{S}_B = W^T S_B W$$

$$\tilde{S}_W = W^T S_W W$$

Gornje jednadžbe pokazuju kako se tzv. within-class i between-class matrice raspršenja TRANSFORMIRAJU projekcijom u višedimenzionalni prostor.
TRAŽIMO TRANSFORMACIJSKU MATRICU W koja maksimizira omjer between-

class raspršenost s within-class raspršenost!! $J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|}$

Jednostavna SKALARNA mjera raspršenosti je determinanta matrice raspršenosti
Determinanta je PRODUKT svojstvenih vrijednosti matrice.

PROBLEM TRAŽENJA (I NALAŽENJA) PRAVOKUTNE(!) MATRICE W koja maksimizira $J(\cdot)$ je težak problem.

RJEŠENJE:


Stupci optimalne matrice W su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u $S_B \vec{W}_i = \lambda_i S_W \vec{W}_i$. Ako je S_W nesingularna onda se problem može pretvoriti u konvencionalni problem svojstvenih vrijednosti. Međutim to zahtjeva računanje inverzne matrice $S_W \cdot S_W^{-1} S_B \vec{W} = \lambda \vec{W}$. Umjesto toga možemo naći svojstvene vrijednosti kao korijene karakterističnog polinoma:

$$|S_B - \lambda_i S_W| = 0$$

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

Naći W koja maksimizira $J(W)$! $S_B \vec{W}_i = \lambda_i S_W \vec{W}_i$

Naći svojstvene vrijednosti kao korijene karakterističnog polinoma: $|S_B - \lambda_i S_W| = 0$ i zatim riješiti: $(S_B - \lambda_i S_W) \vec{W}_i = \vec{0}$



Slika 1: Primjer MDA

Stupci optimalne (pravokutne) matrice W (koja maksimizira $J(W)$) su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u $S_B \vec{W}_i = \lambda_i S_W \vec{W}_i$.

Ako je S_W nesingularna onda se problem pretvara u konvencionalan problem svojstvenih vrijednosti. Međutim, umjesto računanja inverzne matrice S_W^{-1} mogu se naći svojstvene vrijednosti karakterističnog polinoma $|S_B - \lambda_i S_W| = 0$ i riješiti $(S_B - \lambda_i S_W) \vec{W}_i = \vec{0}$ izravno po \vec{W}_i .

$$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_B = n_1 (\vec{m}_1 - \vec{m})(\vec{m}_1 - \vec{m})^T + n_2 (\vec{m}_2 - \vec{m})(\vec{m}_2 - \vec{m})^T + \dots + n_c (\vec{m}_c - \vec{m})(\vec{m}_c - \vec{m})^T$$

Matrica S_B je suma c matrica! Matrice su ranga 1 ili manje i samo $c-1$ od njih su nezavisne. S_B je ranga $c-1$ ili manje.

TO ZNAČI DA JE NAJVIŠE $c-1$ SVOJSTVENIH VRIJEDNOSTI RAZLIČITIH OD 0 I DA (ŽELJENI) SVOJSTVENI VEKTORI ODGOVARAJU TIM SVOJSTVENIM VRIJEDNOSTIMA RAZLIČITIM OD 0.

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

- problem nalaženja (pravokutne) matrice W koja maksimizira $J(\cdot)$ -> složen!

- stupci optimalne matrice W su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u $S_B \vec{W}_i = \lambda_i S_W \vec{W}_i$
- ako je S_W nesingularna onda se problem može transformirati u konvencionalni problem svojstvenih vrijednosti
- međutim, umjesto toga možemo naći svojstvene vrijednosti kao korijene karakterističnog polinoma $|S_B - \lambda_i S_W| = 0$ i onda riješiti $(S_B - \lambda_i S_W) \vec{W}_i = \vec{0}$

IZRAVNO za svojstvene vektore \vec{W}_i budući da je S_B suma c matrica ranga jedan ili manje, i budući da su samo $c-1$ od njih nezavisni, S_B je ranga $c-1$ ili manje

- najviše $c-1$ svojstvenih vrijednosti različito od 0.

2 SKUP UZORAKA ZA UČENJE I SKUP UZORAKA ZA ISPITIVANJE - METODE ISPITIVANJA

Skupa uzoraka za učenje - uzorci s poznatom klasifikacijom (označeni uzorci)

Važna pretpostavka: u uzorcima za učenje sadržana je većina informacija o svojstvima razreda kojima uzorci pripadaju

1. Holdout metoda

- ako imamo dovoljno veliki skup uzoraka s poznatom klasifikacijom



Slika 2: Skup uzoraka

S_u - skup uzoraka za učenje, $\#S_u = N$


S_i - skup uzoraka za ispitivanje

$$S = S_u \cup S_i; \quad S_u \cap S_i = \emptyset$$

S - skup uzoraka s poznatom klasifikacijom

Nedostaci Holdout metode:

- smanjuje se veličina skupa za učenje i skupa za ispitivanje
- kako podijeliti skup S na S_u i S_i ?
- Vjerojatnost greške klasifikatora koji se oblikuje uporabom konačnog skupa za učenje N je uvijek veća negoli je odgovarajuća asimptotska vjerojatnost pogreške ($N \rightarrow \infty$)



Slika 3: Vjerojatnost pogreške

2. Leave-One-Out metoda

- metoda pokušava "zaobići" problem podjele skupa označenih uzoraka. Učenje se obavlja uporabom $N-1$ uzoraka, a ispitivanje se izvodi uporabom onog jednog preostalog uzorka. Ako je taj uzorak pogrešno razvrstan \rightarrow inkrementira se brojilo pogreške; Postupak se ponavlja N puta, ali tako da je svaki put isključen drugi uzorak. Ukupan broj pogrešaka nas upućuje na procjenu vjerojatnosti pogreške klasifikatora. Nedostatak metode: velika računaska složenost

3. Resubstitution metoda (Metoda ponovne zmajenje)

Isti se skup podataka koristi, prvo za učenje, a zatim za ispitivanje.

- optimistička procjena vjerojatnosti pogreške klasifikatora

Od skupa uzoraka za učenje zahtijeva se (za svaki uzorak):

- dovoljnost informacija
- postojanost značajki
- geometrijska postojanost (mala udaljenost među uzorcima u prostoru značajki znači i malu razliku u svojstvima objekata)

N ? Idealno $N \rightarrow \infty$

Preporuka za N

- barem 3 do 5 puta više uzoraka za učenje po razredu od broja značajki (dimenzionalnost vektora značajki)

Primjer: sustav za autorizaciju osoba na temelju lica

580 korisnika ($M=580$)

110 - komponentni vektor značajki

$N=5 \cdot 110 \cdot 580=319000!!!$ (slika lica)

Primjer: Klasifikacija brojčano-slovčanih znakova $M=30+10=40$

$\omega_1, \omega_2, \dots, \omega_{40}$

Dimenzionalnost vektora značajki $n=18$

$N=5 \cdot 18 \cdot 40=3600$ (slika brojčano-slovčanih znakova)