


1 SVM - Support Vector Machines

Strojevi s potpornim vektorima

- Izvorno SVM je linearni stroj
- Osnovna zamisao SVM: konstrukcija hiperravnine kao decizijske plohe, ali tako da je margin odvajanja između "pozitivne" i "negativne" skupine uzoraka (za učenje) maksimalna.



Slika 1: Primjer razdvajanja

Imamo skup uzoraka za učenje:

$$\left\{ \left(\vec{X}_i, d_i \right) \right\}_{i=1}^N, \text{ gdje je}$$

$\vec{X}_i; i = 1, 2, \dots, N$ ulazni vektor uzoraka za i-ti primjer

d_i - željeni odgovor klasifikatora

$\omega_1 \rightarrow d_i = +1$
 $\omega_2 \rightarrow d_i = -1$ } označeni uzorci

Pretpostavka : razredi ω_1 i ω_2 su linearno separatibilni

Jednadžba decizijske ravnine:

$$\vec{W}^T \vec{X} + b = 0$$

\vec{X} - ulazni vektor

\vec{W} - vektor težinskih koeficijenata

b - pomaknuće (w_0)


Vrijedi:

$$\vec{W}^T \vec{X} + b \geq 0 \text{ za } d_i = +1$$

$$\vec{W}^T \vec{X} + b < 0 \text{ za } d_i = -1$$

Margina: za zadani vektor težinskih koeficijenata \vec{W} i pomaknuće b udaljenost između hiperravnine i najbliže točke (uzorka) u n -dimenzionalnom prostoru naziva se MARGINA ODVAJANJA (engl. margin of separation) i označit ćemo ju s ρ .

Cilj: Naći posebnu hiperravninu za koju je margina odvajanja ρ maksimalna. Takva hiperravnina naziva se OPTIMALNA RAVNINA.




Slika 2: Optimalna ravnina

Optimalna hiperravnina: $\underbrace{\{\vec{W}_0, b_0\}}_{\text{optimalne vrijednosti}}$

$$\vec{W}_0^T \vec{X} + b_0 = 0$$

Decizijska funkcija:

$$g(\vec{X}) = \vec{W}_0^T \vec{X} + b_0 \text{ daje mjeru udaljenosti } \vec{X}\text{-a od optimalne hiperravnine}$$



Slika 3: Primjer decizijske funkcije

Par (\vec{W}_0, b_0) mora zadovoljavati sljedeća ograničenja

$$\vec{W}_0^T \vec{X}_i + b_0 \geq 1 \text{ za } d_i = +1 \quad (1)$$

$$\vec{W}_0^T \vec{X}_i + b_0 \leq -1 \text{ za } d_i = -1 \quad (2)$$

$$\vec{X}_i \in \{(\vec{X}_i, d_i)\}_{i=1}^N$$

Naravno ovo vrijedi ako su uzorci linerano odvojivi.

Uvijek možemo skalirati \vec{W}_0 i b_0 tako da nejednadžbe (1) i (2) vrijede!

$$r = \frac{|g(\vec{X})|}{\|\vec{W}_0\|}$$

možemo skalirati \vec{W}_0 i b_0 tako da za najbliže (hiperravnini $g(\vec{X})$) uzorke iz ω_1 i ω_2 bude $g(\vec{X}) = 1$ za ω_1

$$g(\vec{X}) = -1 \text{ za } \omega_2$$

Za uzorke (točke u n-dimenzionalnom prostoru) iz skupa za učenje i to za one za koje vrijedi

$$\vec{W}_0^T \vec{X} + b_0 = 1 \text{ za } d_i = +1$$

$$\vec{W}_0^T \vec{X} + b_0 = -1 \text{ za } d_i = -1$$

kažemo da su potporni vektori (support vectors).

Potporni vektori su one točke koje leže najbliže decizijskoj hiperravnini i zato se najteže klasificiraju. Zbog toga oni imaju izravan utjecaj na optimalni položaj decizijske hiperravnine.

Potporni vektor $\vec{X}^{(s)}$:

$$g^{(s)} = \vec{W}_0^T \vec{X}^{(s)} + b_0 = \mp 1 \text{ za } d^{(s)} = \mp 1$$

Algebarska udaljenost potpornog vektora $\vec{X}^{(s)}$ od optimalne hiperravnine je

$$r = \frac{|g(\vec{X}^{(s)})|}{\|\vec{W}_0\|}$$

$$r = \begin{cases} \frac{1}{\|\vec{W}_0\|} & \text{ako je } d^{(s)} = +1 \\ -\frac{1}{\|\vec{W}_0\|} & \text{ako je } d^{(s)} = -1 \end{cases}$$

gdje znak + označava da $\vec{X}^{(s)}$ leži na pozitivnoj strani optimalne hiperravnine a - predznak pokazuje da je $\vec{X}^{(s)}$ na negativnoj strani optimalne hiperravnine.

ρ - optimalna vrijednost MARGINE ODVAJANJA između dva razreda koji definiraju skup uzoraka za učenje

$$\rho = 2r = \frac{2}{\|\vec{W}_0\|}$$

iz $\rho = 2r = \frac{2}{\|\vec{W}_0\|}$ slijedi da se maksimiziranje margine odvajanja temelji na minimizaciji norme vektora težinskih koeficijenata \vec{W}_0 .

Optimalna hiperravnina: $\vec{W}_0^T \vec{X} + b = 0$ je jedinstvena u tom smislu da vektor \vec{W}_0 daje maksimalnu separaciju između pozitivnih i negativnih uzoraka iz skupa za učenje.

CILJ: Razvoj djelotvorne procedure (uporabom skupa uzoraka za učenje) tako da nađemo optimalnu hiperravninu uz zadovoljenje ograničenja:

$$d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 \text{ za } i = 1, 2, \dots, N$$

Formalno postavljen problem:

- Zadan je skup uzoraka za učenje $\{(\vec{X}_i, d_i)\}_{i=1}^N$
 - Naći optimalnu vrijednost vektora težinskih koeficijenata \vec{W} i pomaknuće b tako da su zadovoljena ograničenja

$$d_i \cdot \vec{W}^T \vec{X}_i + b \geq 1 \text{ za } i = 1, 2, \dots, N$$
 a pri tomu vektor težinskih koeficijenata \vec{W} minimizira kriterijsku funkciju

$$J(\vec{W}) = \frac{1}{2} \vec{W}^T \vec{W} \quad \vec{W}^T \vec{W} = \|\vec{W}\|^2$$
- nelinearni optimizacijski zadatak sa skupom linearnih nejednadžbi

Optimizacijski problem riješiti metodom Lagrangeovih multiplikatora

Primjer:

Određivanje vezanih ekstrema funkcije $z = f(x, y)$ uz uvjet $\varphi(x, y) = 0$ svodi se na računanje slobodnih ekstrema Lagrangeove funkcije:

$$F = f(x, y) + \lambda \varphi(x, y)$$

$$\frac{\partial F}{\partial x} = 0; \frac{\partial F}{\partial y} = 0; \varphi(x, y) = 0$$

Iz tog se sustava jednadžbi određuju vrijednosti x, y i Lagrangeov multiplikator λ .

- Ako je $d^2F < 0$ u izračunatoj točki, funkcija $z=f(x,y)$ ima maksimum
- Ako je $d^2F > 0$ u izračunatoj točki, funkcija $z=f(x,y)$ ima minimum

Tražimo ekstrem funkcije:

$$z = x + 2y \text{ uz uvjet } x^2 + y^2 = 5$$

$$\text{- Lagrangeova funkcija: } F = x + 2y + \lambda(x^2 + y^2 - 5)$$

- Računamo:

$$F_x = \frac{\partial F}{\partial x} = 1 + 2x\lambda$$

$$F_y = \frac{\partial F}{\partial y} = 2 + 2y\lambda$$

- iz sustava jednadžbi:

$$1 + 2\lambda x = 0$$

$$2 + 2\lambda y = 0$$

$$x^2 + y^2 = 5$$

$$\text{slijedi: } x = -\frac{1}{2\lambda}; y = -\frac{1}{\lambda}$$

uvrstavamo u 3. jednadžbu:

$$\frac{1}{4\lambda^2} + \frac{1}{\lambda^2} = 5/4\lambda^2$$

$$5(1 - 4\lambda^2) = 0$$

$$\lambda_{1,2} = \pm \sqrt{\frac{1}{4}}$$

$$\lambda_1 = \frac{1}{2}; \lambda_2 = -\frac{1}{2}$$

$$\text{za } \lambda_1 = \frac{1}{2} \text{ dobivamo : } x_1 = -1 \quad y_1 = -2$$

$$\text{za } \lambda_2 = -\frac{1}{2} \text{ dobivamo : } x_2 = 1 \quad y_2 = 2$$

Računamo:

$$d^2F = \frac{\partial^2 F}{\partial x^2} dx^2 + 2 \frac{\partial^2 F}{\partial x \partial y} dx dy + \frac{\partial^2 F}{\partial y^2} dy^2$$

$$F_{xx} = 2\lambda; F_{yy} = 2\lambda; F_{xy} = 0$$

$$d^2F = 2\lambda dx^2 + 2\lambda dy^2 = 2\lambda(dx^2 + dy^2)$$

$$\text{za } (\lambda_1 = \frac{1}{2}) \quad d^2F > 0 \text{ minimum}$$

$$\text{za } (\lambda_2 = -\frac{1}{2}) \quad d^2F < 0 \text{ maksimum}$$

funkcije $f(x,y)$.

$$J(\vec{W}) = \frac{1}{2} \vec{W}^T \vec{W}$$

$$d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 \text{ za } i = 1, 2, \dots, N$$

Lagrangeova funkcija:

$$J(\vec{W}, b, \lambda) = \frac{1}{2} \vec{W}^T \vec{W} - \sum_{i=1}^N \lambda_i [d_i \cdot (\vec{W}^T \vec{X}_i + b) - 1]$$

λ_i - Lagrangeovi multiplikatori

$$\text{a) } \frac{\partial J(\vec{W}, b, \lambda)}{\partial \vec{W}} = \vec{0}$$

$$\text{b) } \frac{\partial J(\vec{W}, b, \lambda)}{\partial b} = 0$$

c) $\lambda_i \left[d_i \cdot (\vec{W}^T \vec{X}_i + b) - 1 \right] = 0, i = 1, 2, \dots, N$

d) $\lambda_i \geq 0, i = 1, 2, \dots, N$

$$\frac{\partial J(\vec{W}, b, \lambda)}{\partial \vec{W}} = \vec{W} - \sum_{i=1}^N \lambda_i d_i \vec{X}_i = \vec{0}$$

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i$$

$$\frac{\partial J(\vec{W}, b, \lambda)}{\partial b} = - \sum_{i=1}^N \lambda_i d_i = 0$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

- Traženi vektor \vec{W} određen je s $N_s \leq N$ vektora uzoraka

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i, \lambda_i \neq 0$$

Vektor \vec{W} je optimalno rješenje!

- Budući da je skup ograničenja

$\lambda_i \left[d_i \cdot (\vec{W}^T \vec{X}_i + b) - 1 \right] = 0, i = 1, 2, \dots, N$ potporni vektori leže u dvije hiperravnine:

$$\vec{W}^T \vec{X} + b = \pm 1$$

Potporni (support) vektori su oni vektori koji leže tako da su NAJBЛИŽI hiperravnini linearnog klasifikatora i određuju kritične elemente skupa za učenje.

- Vektori \vec{X}_i za koje je $\lambda_i = 0$ mogu ležati izvan pojasa odvajanja, ali mogu ležati, također na jednoj od hiperravnina

- Rezultirajuća (optimalna) hiperravnina je neosjetljiva na broj i položaj takvih vektora

- \vec{W} je eksplicitno određena, b se može dobiti iz jednog od uvjeta

$$\lambda_i \left[d_i \cdot (\vec{W}^T \vec{X}_i + b) - 1 \right] = 0, i = 1, 2, \dots, N \text{ za } \lambda_i \neq 0 (*)$$

U praksi, b se obično računa kao srednja vrijednost dobivena uporabom svih uvjeta tog tipa(*).

Optimalna hiperravnina linearnog klasifikatora je jedinstvena.

- $J(\vec{W})$ je konveksna (strogo)

- Nejednadžbe su linearne

lokalni minimum je ujedno i globalni!


Konveksna funkcija $f(\vec{\theta})$

$$f: S \subseteq \mathbb{R}^L \rightarrow \mathbb{R}$$

je konveksna u S ako za svaki $\vec{\theta}, \vec{\theta}' \in S$ vrijedi: \nwarrow NIE Lagrangeov multiplikator!

$$f(\lambda \vec{\theta} + (1-\lambda) \vec{\theta}') \leq \lambda f(\vec{\theta}) + (1-\lambda) f(\vec{\theta}')$$

za svaki $\lambda \in [0, 1]$



Slika 4: Konveksno-konkavno

Lagrangeov dualni problem

- Optimizacijski zadatak: minimiziraj $J(\vec{W})$ uz ograničenje $\varphi_i(\vec{W}) \geq 0$, $i = 1, 2, \dots, N$

Lagrangeova funkcija $J(\vec{W}, \vec{\lambda}) = J(\vec{W}) - \sum_{i=1}^N \lambda_i \varphi_i(\vec{W})$

Neka je $J^*(\vec{W}, \vec{\lambda}) = \max_{\vec{X}} (J(\vec{W}, \vec{\lambda}))$

Budući da je $\vec{\lambda} \geq \vec{0}$ i $\varphi_i(\vec{W}) \geq 0$

- Maksimalna vrijednost Lagrangeove funkcije onda kad je $\lambda_i = 0$; $i = 1, 2, \dots, N$ ili kada je $\varphi_i(\vec{W}) = 0$ (ili oboje) u tom slučaju je $J^*(\vec{W}, \vec{\lambda}) = J(\vec{W})$

Originalni problem je ekvivalentan sa:

$$\min_{\vec{W}} J(\vec{W}) = \min_{\vec{W}} \max_{\vec{\lambda}} J(\vec{W}, \vec{\lambda})$$

Dualni problem:

$$\max_{\vec{\lambda} \geq \vec{0}} \underbrace{\min_{\vec{W}} J(\vec{W}, \vec{\lambda})}_{\text{rješenje ovog dijela}}$$

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i$$

i

$$\sum_{i=1}^N \lambda_i d_i = 0$$

Detekcija živosti ruke

85 slika IR

29 živih ruku

56 neživih (umjetnih) ruku (2 tipa) } skup za ispitivanje

SVM

45 slika za učenje

40 slika za ispitivanje

žive ruke \notin skupu za učenje

umjetne ruke ne pripadaju skupu za učenje

SVM s linearnom jezgrom 5% pogreške



Slika 5:

$$(1) \quad J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i \cdot d_i \vec{w}^T \vec{x}_i - b \sum_{i=1}^N \lambda_i d_i + \sum_{i=1}^N \lambda_i$$

$$\vec{w}^T \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{w}^T \vec{x}_i = \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \cdot \vec{x}_j$$

$$J(\vec{w}, b, \lambda) = Q(\lambda)$$

$$Q(\lambda) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \cdot \vec{x}_j$$

uz ograničenja:

$$(1) \quad \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) \quad \lambda_i \geq 0 \quad \text{za} \quad i = 1, 2, \dots, N$$

maksimiziraj $Q(\lambda)$!

Slika 6: Primjer SVM

Dualni problem - Lagrangeova dualnost (Wolfe dual representation)

Ako prvotni problem ima optimalno rješenje tada dualni problem ima također optimalno rješenje i odgovarajuća optimalna rješenja su jednaka.

Maksimiziraj $J(\vec{W}, b, \lambda)$ uz

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, N$$

Nalazimo Lagrangeove multiplikatore koji daju optimalno rješenje!
 Neke značajke dualnog pristupa: Kriterijska funkcija koja se treba maksimizirati zavisi samo od ulaznih uzoraka u obliku skupa skalarnog produkta $\left\{ \vec{X}_i^T | \vec{x}_j \right\}_{(i,j)=1}^N$

Optimalno rješenje $\vec{W} = \vec{W}_0$
 $\vec{W}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \vec{X}_i$ gdje je $\lambda_{0,i}$ optimalni Lagrangeov multiplikator
 $b_0 = 1 - \vec{W}_0^T \vec{X}^{(s)}$ za $d^{(s)} = 1$

$$\begin{aligned} (1) \quad & J(\vec{W}, b, \lambda) = \frac{1}{2} \vec{W}^T \vec{W} - \sum_{i=1}^N \lambda_i \left[d_i \cdot (\vec{W}^T \vec{X}_i + b) - 1 \right] \\ (2) \quad & \vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i \\ (3) \quad & \sum_{i=1}^N \lambda_i d_i = 0, \quad \lambda_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

Zamjenom (2) i (3) u (1) i nakon uređivanja dobiva se :

$$(**) \quad \max_{\lambda} \left(\sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j d_i d_j \vec{X}_i^T \vec{X}_j \right) \text{ uz uvjet } \sum_{i=1}^N \lambda_i d_i = 0, \lambda_i \geq 0$$

Optimalni Lagrangeovi multiplikatori se računaju optimiziranjem (MAK-SIMIZIRANJEM) izraza (**), a optimalna se hiperravnina dobiva $\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i$, gdje su λ_i optimalni Lagrangeovi multiplikatori

PRIMJER:


$$\begin{aligned} \omega_1 &= \{[1, 1]^T, [1, -1]^T\} \\ \omega_2 &= \{[-1, 1]^T, [-1, -1]^T\} \\ g(\vec{X}) &= \vec{W}^T \vec{X} + b = 0 \\ w_1 x_1 + w_2 x_2 + b &= 0 \end{aligned}$$

Ograničenja (linearne nejednadžbe):

$$\begin{aligned} w_1 + w_2 + b - 1 &\geq 0 \\ w_1 - w_2 + b - 1 &\geq 0 \\ w_1 - w_2 - b - 1 &\geq 0 \\ w_1 + w_2 - b - 1 &\geq 0 \\ d_i(\vec{W}^T \vec{X}_i + b) &\geq 1 \\ J(\vec{W}, b, \lambda) &= \frac{1}{2} \vec{W}^T \vec{W} - \sum_{i=1}^4 \lambda_i [d_i(\vec{W}^T \vec{X}_i + b) - 1] \\ J(\vec{W}, b, \lambda) &= \frac{w_1^2 + w_2^2}{2} - \lambda_1(w_1 + w_2 + b - 1) - \lambda_2(w_1 - w_2 + b - 1) - \lambda_3(w_1 - w_2 - b - 1) - \lambda_4(w_1 + w_2 - b - 1) \end{aligned}$$

KKT uvjeti su zadani sa:

$$\begin{aligned} \frac{\partial J}{\partial w_1} = 0 &\Rightarrow w_1 = \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 \quad (1) \\ \frac{\partial J}{\partial w_2} = 0 &\Rightarrow w_2 = \lambda_1 + \lambda_4 - \lambda_2 - \lambda_3 \quad (2) \\ \frac{\partial J}{\partial b} = 0 &\Rightarrow \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0 \quad (3) \\ \lambda_1(w_1 + w_2 + b - 1) &= 0 \quad (4) \\ \lambda_2(w_1 - w_2 + b - 1) &= 0 \quad (5) \\ \lambda_3(w_1 - w_2 - b - 1) &= 0 \quad (6) \\ \lambda_4(w_1 + w_2 - b - 1) &= 0 \quad (7) \\ \lambda_1, \lambda_2, \lambda_3, \lambda_4 &\geq 0 \end{aligned}$$



Slika 7: Primjer zadatka

7 jednadžbi \rightarrow 7 nepoznanica

Znamo rješenje s maksimalnom marginom (za ovaj jednostavan slučaj):

$w_1 = 1, w_2 = 0, b = 0$

$$g(\vec{X}) = X_1 = 0$$

Uvrstimo $w_1 = 1; w_2 = 0$ i $b = 0$ u jednadžbe:

$$(1) \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1$$

$$(2) \lambda_1 + \lambda_4 - \lambda_2 - \lambda_3 = 0$$

$$(3) \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0$$

Sustav linearnih jednadžbi: 3 jednadžbe i 4 nepoznanice!

Očito \rightarrow više od jednog rješenja!

Međutim svako od rješenja vodi do JEDINSTVENE (OPTIMALNE) LIN-IJE RAZDVAJANJA!

Na primjer:

$$(1)+(3) \quad 2\lambda_1 + 2\lambda_2 = 1 \Rightarrow \lambda_1 = \frac{1-2\lambda_2}{2}$$

$$(1)+(2) \quad 2\lambda_1 + 2\lambda_4 = 1$$

$$(2)+(3) \quad 2\lambda_1 - 2\lambda_3 = 0 \Rightarrow \lambda_1 = \lambda_3$$


$$\text{Uzmimo } \lambda_1 = \frac{1}{8} \Rightarrow \lambda_3 = \frac{1}{8}$$

$$\lambda_2 = \frac{1-2\lambda_1}{2} = \frac{1-2\frac{1}{8}}{2} = \frac{\frac{3}{4}}{2} = \frac{3}{8}$$

$$\lambda_4 = \frac{1-2\lambda_1}{2} = \frac{3}{8}$$

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i = \lambda_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \lambda_3 \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \lambda_4 \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\vec{W} = \frac{1}{8} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{3}{8} \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \frac{1}{8} \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \frac{3}{8} \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$



Slika 8: Prikaz margine zadatka

$$\vec{W} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\lambda_1 = \frac{1}{4}, \lambda_2 = \frac{1}{4}, \lambda_3 = \frac{1}{4}, \lambda_4 = \frac{1}{4}$$

$$\vec{W} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad g(\vec{X}) = x_1 = 0$$

SVM za $M > 2$ razreda?

Podsjetimo se :

- za svaki od razreda tražimo optimalnu decizijsku funkciju $g_i(\vec{X})$, $i = 1, 2, \dots, M$ tako da $g_i(\vec{X}) > g_j(\vec{X})$, $\forall j \neq i$ ako je $\vec{X} \in \omega_i$

za SVM tražimo decizijsku funkciju $g(\vec{X}) = 0$ takva da bude optimalna hiperravnina koja odvaja razred ω_i od svih ostalih $g_i(\vec{X}) > 0$, za $\vec{X} \in \omega_i$, $g_i(\vec{X}) < 0$ inače

Klasifikacijsko pravilo: dodijeli \vec{X} u ω_i ako $i = \operatorname{argmax}_k \{g_k(\vec{X})\}$.