

1 Poopćene (linearne) decizijske funkcije

- složenost granica: linearne \rightarrow vrlo nelinearne!

- vrlo nelinearne?

Rješenje:

Poopćeni oblik (linearne) decizijske funkcije:

$$d(\vec{X}) = w_1 f_1(\vec{X}) + w_2 f_2(\vec{X}) + \dots + w_k f_k(\vec{X}) + w_{k+1} = \sum_{i=1}^{k+1} w_i f_i(\vec{X})$$

$$\{f_i(\vec{X})\}, i = 1, 2, \dots, k, f_{k+1} = 1$$

Pazi: $f_i(\vec{X})$

$$\vec{X}^* = \begin{bmatrix} f_1(\vec{X}) \\ f_2(\vec{X}) \\ \vdots \\ f_k(\vec{X}) \\ 1 \end{bmatrix} \quad d(\vec{X}) = \vec{W}^T \vec{X}^*$$

$d(\vec{X})$ je linearna funkcija po \vec{X}^*

$$d(\vec{X}) = \vec{W}^T \vec{X}^*$$

$$\vec{X}^* = \begin{bmatrix} f_1(\vec{X}) \\ f_2(\vec{X}) \\ \vdots \\ f_k(\vec{X}) \\ 1 \end{bmatrix} \quad \vec{W} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_k \\ w_{k+1} \end{bmatrix}$$

Decizijska funkcija $d(\vec{X})$ može se promatrati kao linearna funkcija u k-dimenzionalnom prostoru!

Transformacija:

$$\vec{X}_{n\text{-dimenzija}} \rightarrow \vec{X}_{k\text{-dimenzija}}^*$$

Vrijedi: $k > n$

$d(\vec{X})$ se često naziva i "virtualno linearna"

Kako izabrati $\{f_i(\vec{X})\}_{i=1}^k$?

Mogućnost: $\{f_i(\vec{X})\}$ $f_i(\vec{X})$ u obliku polinoma

- Najjednostavniji slučaj: linearna funkcija

$$\begin{aligned} \vec{X} &= (x_1, x_2, \dots, x_n)^T \\ f_i(\vec{X}) &= x_i \quad \vec{X} = \vec{X}^* \\ k &= n \end{aligned}$$

- Polinom drugog stupnja:

$$\begin{aligned} \text{Npr. } n=2 \quad \vec{X} &= (x_1, x_2)^T \\ d(\vec{X}) &= w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3 \\ d(\vec{X}) &= \vec{W}^T \vec{X}^* \\ \vec{X}^* &= (x_1^2, x_1x_2, x_2^2, x_1, x_2, 1)^T \end{aligned}$$

Opći slučaj kvadratnog oblika:

$$d(\vec{X}) = \underbrace{\sum_{j=1}^n w_{jj}x_j^2}_{n\text{-izraza}} + \underbrace{\sum_{j=1}^{n-1} \sum_{k=j+1}^n w_{jk}x_jx_k}_{\frac{n(n-1)}{2}\text{-izraza}} + \underbrace{\sum_{j=1}^n w_jx_j}_{n\text{-izraza}} + \underbrace{w_{n+1}}_{1 \text{ izraz}}$$

Kvadratnu decizijsku funkciju možemo promatrati kao linearnu ("linear by virtue") funkciju s $k = \frac{(n+1)(n+2)}{2}$ varijabli

$$\begin{aligned} \{f_1(\vec{X}), \dots, f_n(\vec{X})\} &= \{x_1^2, x_2^2, \dots, x_n^2\} \\ \{f_{n+1}(\vec{X}), \dots, f_{2n}(\vec{X})\} &= \{x_1, x_2, \dots, x_n\} \\ \{f_{2n+1}(\vec{X}), \dots, f_k(\vec{X})\} &= \{x_1x_2, x_1x_3, \dots, x_{n-1}x_n\} \end{aligned}$$

- Decizijske duncije višeg reda (polinomi stupnja $r > 2$) možemo promatrati

kao linearne funkcije $\frac{(n+r)!}{r!n!}$ varijabli

n - dimenzionalnost vektora \vec{X}

r - stupanj polinoma

Funkcije iz skupa $\{f_i(\vec{X})\}$ određene su s $f_i(\vec{X}) = x_{p_1}^{s_1} x_{p_2}^{s_2} \dots x_{p_r}^{s_r}$

$p_1, p_2, \dots, p_r = 1, 2, \dots, n$

$s_1, s_2, \dots, s_r = 0, 1$

Decizijsku funkciju u obliku polinoma r -tog stupnja možemo zapisati u rekurzivnom obliku:

$$d^r(\vec{X}) = \left(\sum_{p_1=1}^n \sum_{p_2=p_1}^n \dots \sum_{p_r=p_{r-1}}^n w_{p_1 p_2 \dots p_r} x_{p_1} x_{p_2} \dots x_{p_r} \right) + d^{r-1}(\vec{X}) ;$$

$$d^0(\vec{X}) = w_{n+1}$$

Primjer: za $r=2$ i $n=2$:

$$d^2(\vec{X}) = \sum_{p_1=1}^2 \sum_{p_2=p_1}^2 w_{p_1 p_2} x_{p_1} x_{p_2} + d^1(\vec{X})$$

$$d^1(\vec{X}) = \sum_{p_1=1}^2 w_{p_1} x_{p_1} + d^0(\vec{X})$$

$$d^1(\vec{X}) = w_1 x_1 + w_2 x_2 + w_3$$

$$d^2(\vec{X}) = w_{11} x_1^2 + w_{12} x_1 x_2 + w_{22} x_2^2 + d^1(\vec{X})$$

$$d^2(\vec{X}) = w_{11} x_1^2 + w_{12} x_1 x_2 + w_{22} x_2^2 + w_1 x_1 + w_2 x_2 + w_3$$

$$\vec{W} = [w_{11}, w_{12}, w_{22}, w_1, w_2, w_3] \quad \vec{X}^* = \begin{bmatrix} x_1^2 \\ x_1 x_2 \\ x_2^2 \\ x_1 \\ x_2 \\ 1 \end{bmatrix}$$

Primjer: za $r=3$ i $n=2$:

$$d^3(\vec{X}) = \left(\sum_{p_1=1}^2 \sum_{p_2=p_1}^2 \sum_{p_3=p_2}^2 w_{p_1 p_2 p_3} x_{p_1} x_{p_2} x_{p_3} \right) + d^2(\vec{X});$$

$$d^3(\vec{X}) = w_{111} x_1^3 + w_{112} x_1^2 x_2 + w_{122} x_1 x_2^2 + w_{222} x_2^3 + d^2(\vec{X})$$


$$d^3(\vec{X}) = w_{111} x_1^3 + w_{112} x_1^2 x_2 + w_{122} x_1 x_2^2 + w_{222} x_2^3 + w_{11} x_1^2 + w_{12} x_1 x_2 + w_{22} x_2^2 + w_1 x_1 + w_2 x_2 + w_3$$

Cijena koju plaćamo za linearizaciju:

- broj koeficijenata (težinskih faktora) za funkciju r-tog stupnja i različite n:

n \ r	1	2	3	...	6	...	10
1	2	3	4		7		11
2	3	6	10		28		66
3	4	10	20		84		286
...							
9	10	55	220		5005		92378
10	1	66	286		8008		184756

Dimenzionalnost "lineariziranog prostora"!



Slika 1: Blok shema sustava za raspoznavanje

PRIMJER

Zadan je skup uzoraka za učenje:


- $U_4^1 = \{(0, 0)^T, (0, 4)^T, (4, 0)^T, (4, 4)^T\}$
- $U_4^2 = \{(1, 1)^T, (1, 3)^T, (3, 1)^T, (3, 3)^T\}$
- $U_1^3 = \{(2, 2)^T\}$

U_c^s — c-broj uzoraka u razredu, s-oznaka razreda

Zadane uzorke ne možemo odijeliti linearnim decizijskim funkcijama!

Pokušajmo kvadratnim! $\rightarrow r=2; n=2;$

$n=2$



Slika 2: Prikaz uzoraka iz primjera

$k = \frac{(n+1)(n+2)}{2} = 6$ - dimensionalni prostor
2-dim. \rightarrow 6-dim.

Preslikavanje 2- u 6- dimensionalni prostor funkcijama

$$f_1 = x_1^2 \quad f_2 = x_1 x_2 \quad f_3 = x_2^2 \quad f_4 = x_1 \quad f_5 = x_2 \quad f_6 = 1$$

Preslikan skupa za učenje je :

$$U_4^1 = \{(0, 0, 0, 0, 0, 1)^T, (0, 0, 16, 0, 4, 1)^T, (16, 0, 0, 4, 0, 1)^T, (16, 16, 16, 4, 4, 1)^T\}$$


$$U_4^2 = \{(1, 1, 1, 1, 1, 1)^T, (1, 3, 9, 1, 3, 1)^T, (9, 3, 1, 3, 1, 1)^T, (9, 9, 9, 3, 3, 1)^T\}$$

$$U_1^3 = \{(4, 4, 4, 2, 2, 1)^T\}$$

$$\vec{X}^* = \begin{bmatrix} x_1^2 \\ x_1 x_2 \\ x_2^2 \\ x_1 \\ x_2 \\ 1 \end{bmatrix} \quad d(\vec{X}^*) = \vec{W}^T \vec{X}^* \quad \vec{W} = ?$$

Upotrijebimo poopćeni algoritam perceptrona (M=3)

Dva od mogućih rezultata (u zavisnosti od izbora početnih vrijednosti):



Slika 3: Prikaz dobivenih granica

(Decizijske se granice dobivaju nakon nešto više od 2000 koraka poopćenog algoritma perceptrona)

Poopćeni algoritam perceptrona

M razreda : $\omega_1, \omega_2, \dots, \omega_M$

Pretpostavimo da u k-tom koraku tijekom učenja uzorak $\vec{X}(k)$ pripada razredu ω_i . Računamo M decizijskih funkcija.

Ako je $d_i[\vec{X}(k)] > d_j[\vec{X}(k)] \quad j = 1, 2, \dots, M; \quad j \neq i$

težinski faktor se ne ugađa:

$$\vec{W}_j(k+1) = \vec{W}_j(k), \quad j = 1, 2, \dots, M$$

Pretpostavimo da je za neki l

$$d_i[\vec{X}(k)] \leq d_l[\vec{X}(k)]$$

težinski faktori se sada ugađaju:

$$\vec{W}_i(k+1) = \vec{W}_i(k) + c\vec{X}(k)$$

$$\vec{W}_l(k+1) = \vec{W}_l(k) - c\vec{X}(k)$$

$$\vec{W}_j(k+1) = \vec{W}_j(k); \quad j = 1, 2, \dots, M; \quad j \neq i; \quad j \neq l$$

c - pozitivna konstanta

$\vec{W}_i(1)$ su proizvoljni početni vektori $i = 1, 2, \dots, M$.

2 Skalarno produktno jezgro (Inner-Product Kernel)


- Kako naći optimalnu hiperravninu za linearno neodvojive razrede uporabom SVM?

Odgovor: Uporabom sljedećih koraka:

1. Nelinearnim preslikavanjem izvornog (ulaznog) vektora u prostor značajki većih dimenzija;
2. Konstrukcijom optimalne hiperravnine za odvajanje vektora značajki dobivenih u 1. koraku;

Opaska: Korak 1. temelji se na Coverovom teoremu (1965. godina) → višedimenzionalni prostor može biti transformiran u novi prostor značajki u kojem su uzorci linearno separabilni (s visokom vjerojatnosti) ako su zadovoljena dva uvjeta:

- a) transformacija mora biti NELINEARNA;
- b) dimenzionalnost prostora mora biti DOVOLJNO VELIKA;



Slika 4: Pretvorba uzoraka

- Označimo s \vec{X} vektor iz ulaznog prostora; dimenzija vektora nema je m_0
- Označimo $\{\varphi_j(\vec{X})\}_{j=1}^{m_1}$ skup nelinearnih transformacija iz ulaznog prostora u prostor značajki
- Pretpostavlja se da je $\varphi_j(\vec{X})$ definiran apriori za sve j .
- Za tako zadani skup nelinearnih transformacija možemo definirati decizijsku ravninu:
$$\sum_{j=1}^{m_1} w_j \varphi_j(\vec{X}) + b = 0$$
, gdje $\{w_j\}_{j=1}^{m_1}$ označava skup linearnih težina (težinskih koeficijenata) a b -pomaknuće.
Možemo zapisati:
$$\sum_{j=0}^{m_1} w_j \varphi_j(\vec{X}) = 0$$
, gdje je $\varphi_0(\vec{X}) = 1$ za sve \vec{X} tako da w_0 označava b .

Definirajmo vektor:

$\vec{\varphi}(\vec{X}) = [\varphi_0(\vec{X}), \varphi_1(\vec{X}), \dots, \varphi_{m_1}(\vec{X})]^T$ gdje je $\varphi_0(\vec{X}) = 1$ za sve \vec{X} .

Vektor $\vec{\varphi}(\vec{X})$ predstavlja sliku "induciranu" u prostoru značajki zbog ulaznog vektora \vec{X} .

Vrijedi $\vec{W}^T \vec{\varphi}(\vec{X}) = 0$

U prostoru značajki zahtijevamo "linearnu" separatibilnost!

SVM nam je dao rezultat:

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i, \text{ odnosno}$$

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{\varphi}(\vec{X}_i), \text{ gdje vektor } \vec{\varphi}(\vec{X}_i) \text{ odgovara transformiranom ulaznom}$$

vektoru \vec{X}_i u i-tom slučaju (primjerku)

$$\text{Uvrstimo } \vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{\varphi}(\vec{X}_i) \text{ u } \vec{W}^T \vec{\varphi}(\vec{X}) = 0 !$$

$$\text{Dobivamo: } \sum_{i=1}^N \lambda_i d_i \vec{\varphi}^T(\vec{X}_i) \vec{\varphi}(\vec{X}) = 0$$

$\vec{\varphi}^T(\vec{X}_i) \vec{\varphi}(\vec{X})$ predstavlja skalarni produkt dvaju vektora iz prostora značajki koji su "inducirani" ulaznim vektorima \vec{X} i \vec{X}_i .

$K(\vec{X}, \vec{X}_i) = \vec{\varphi}^T(\vec{X}) \vec{\varphi}(\vec{X}_i) \leftarrow$ skalarno produktno jezgro

$$K(\vec{X}, \vec{X}_i) = \sum_{j=0}^{m_1} \varphi_j(\vec{X}) \varphi_j(\vec{X}_i), \quad \text{za } i = 1, 2, \dots, N$$

Jezgro $K(\vec{X}, \vec{X}_i)$ je simetrična funkcija svojih argumenata $K(\vec{X}, \vec{X}_i) = K(\vec{X}_i, \vec{X})$ za sve i

Najvažnije:

Možemo koristiti jezgro $K(\vec{X}, \vec{X}_i)$ za konstrukciju optimalne hiperravnine u prostoru značajki:

Optimalna hiperravnina je definirana s :

$$\sum_{i=1}^N \lambda_i d_i K(\vec{X}, \vec{X}_i) = 0$$

Optimalni dizajn SVM

Jezgro $K(\vec{X}, \vec{X}_i)$ i njegova ekspanzija $\sum_{j=0}^{m_1} \varphi_j(\vec{X}) \varphi_j(\vec{X}_i)$ nam omogućava kon-

strukciju decizijske ravnine koja je nelinearna u ulaznom (izvornom) prostoru značajki, ali je njena slika u (transformiranom) prostoru značajki linearna.

Dualni oblik za optimizaciju (SVM):

- Zadan je skup uzoraka za učenje $\left\{ \vec{X}_i, d_i \right\}_{i=1}^N$, nađi Lagrangeove multiplikatore

$\{\lambda_i\}_{i=1}^N$ koji maksimiziraju funkciju:

$$J(\vec{\lambda}) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j K(\vec{X}_i, \vec{X}_j)$$

uz ograničenja:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) 0 \leq \lambda_i \leq c \quad \text{za } i = 1, 2, \dots, N, \text{ gdje je } c \text{ user-specific pozitivni parametar}$$

Kad nađemo optimalne vrijednosti Lagrangeovih multiplikatora $\lambda_{0,i}$ dobivamo \vec{W}_0

$$\vec{W}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \varphi(\vec{X}_i)$$

Prva komponenta vektora \vec{W}_0 predstavlja pomaknuće $b_0 \leftarrow$ optimalno pomaknuće Jezgro?

Marcer-ov teorem(1908):

Neka je $K(\vec{X}, \vec{X}')$ kontinuirano simetrično jezgro koje je definirano na zatvorenom intervalu $\vec{a} \leq \vec{X}, \vec{X}' \leq \vec{b}$

Jezgro $K(\vec{X}, \vec{X}')$ može se razviti kao:

$$K(\vec{X}, \vec{X}') = \sum_{i=1}^{\infty} \alpha_i \varphi_i(\vec{X}) \varphi_i(\vec{X}') \text{ gdje je } \alpha_i > 0 \text{ za sve } i.$$

Taj razvoj je valjan ako vrijedi $\int_b^a \int_b^a K(\vec{X}, \vec{X}') \psi(\vec{X}) \psi(\vec{X}') d\vec{X} d\vec{X}' \geq 0$

i za sve $\psi(\cdot)$ za koje vrijedi: $\int_b^a \psi^2(\vec{X}) d\vec{X} < \infty$;

$\varphi_i(\vec{X})$ - svojstvena funkcija (engl. eigenfunction);

α_i - svojstvena vrijednost (engl. eigenvalue);

- funkcije $\varphi_i(\vec{X})$ se zovu svojstvene funkcije

α_i - svojstvene vrijednosti

Jezgra: $K(\vec{X}, \vec{X}_i)$ $i = 1, 2, \dots, N$

- polinomske funkcije

$$(\vec{X}^T \vec{X}_i + 1)^p$$

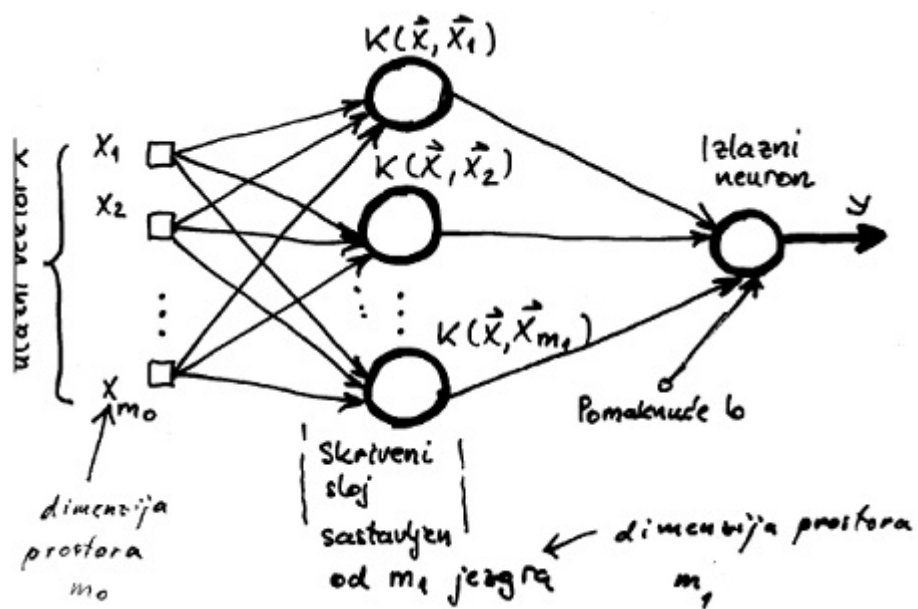
- radijalne bazne funkcije

$$\exp\left(-\frac{1}{2\sigma^2} \left\| \vec{X} - \vec{X}_i \right\|^2\right)$$

- dvorazinski perceptron


$$\tanh(\beta_0 \vec{X}^T \vec{X}_i + \beta_1)$$

Pozor: za jezgro dvorazinskog perceptrona Marcerov teorem je zadovoljen za samo neke vrijednosti β_0 i β_1 !



Slika 5: Arhitektura SVM

Primjer: XOR (Exclusive OR)	
Ulazni vektor \vec{X}	Željeni odgovor d
(-1, -1)	-1
(-1, +1)	+1
(+1, -1)	+1
(+1, +1)	-1



Slika 6: Uzorci za primjer

$$\{([-1, -1]^T, d_1 = -1), ([-1, +1]^T, d_2 = +1), ([+1, -1]^T, d_3 = +1), ([+1, +1]^T, d_4 = -1)\}$$

Izaberimo jezgro $K(\vec{X}, \vec{X}_i) = (1 + \vec{X}^T \vec{X}_i)^2$

$$\vec{X} = [x_1, x_2]^T$$

$$\vec{X}_i = [x_{i1}, x_{i2}]^T$$

$$\text{Jezgro } K(\vec{X}, \vec{X}_i) = 1 + x_1^2 x_{i1}^2 + 2x_1 x_2 x_{i1} x_{i2} + x_2^2 x_{i2}^2 + 2x_1 x_{i1} + 2x_2 x_{i2}$$

Slika ulaznog vektora \vec{X} u prostoru značajki je :

$$\vec{\varphi}(\vec{X}) = [1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2]^T$$

$$\vec{\varphi}(\vec{X}_i) = [1, x_{i1}^2, \sqrt{2}x_{i1}x_{i2}, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}]^T \quad i = 1, 2, 3, 4$$

$K(\vec{X}_i, \vec{X}_j)$ - javlja nam se u izrazu za SVM

$$\mathbf{K} = \left\{ K(\vec{X}_i, \vec{X}_j) \right\}_{(i,j)=1}^N$$

$K(\vec{X}_i, \vec{X}_j)$ možemo promatrati kao ij-ti element simetrične matrice \mathbf{K}

$$\vec{\varphi}(\vec{X}_1) = [1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}]^T$$

$$\vec{X}_1 = (-1, -1) \quad K(\vec{X}_1, \vec{X}_1) = \vec{\varphi}^T(\vec{X}_1) \vec{\varphi}(\vec{X}_1)$$

$$K(\vec{X}_1, \vec{X}_1) = 9$$

Dualni oblik za optimizaciju (SVM):

$$\left\{ \vec{X}_i, d_i \right\}_{i=1}^N$$

Treba naći Lagrangeove multiplikatore $\{\lambda_i\}_{i=1}^N$ koji maksimiziraju funkciju

$$J(\vec{\lambda}) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j K(\vec{X}_i, \vec{X}_j)$$

uz ograničenja:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

(2) $0 \leq \lambda_i \leq c$ za $i = 1, 2, \dots, N$, c - pozitivna konstanta

Npr.

$$K(\vec{X}_1, \vec{X}_4)$$

$$\vec{\varphi}(\vec{X}_1) = [1, 1, \sqrt{2}, 1, -\sqrt{2}, -\sqrt{2}]^T$$

$$\vec{\varphi}(\vec{X}_4) = [1, 1, \sqrt{2}, 1, \sqrt{2}, \sqrt{2}]^T$$

$$\vec{X}_4 = [1, 1]^T$$

$$\vec{\varphi}^T(\vec{X}_1)\vec{\varphi}(\vec{X}_4) = 1$$

$$\mathbf{K} = \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 9 & 1 & 1 \\ 1 & 1 & 9 & 1 \\ 1 & 1 & 1 & 9 \end{bmatrix}$$

Funkcija (za dualni problem):

$$J(\vec{\lambda}) = \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 - \frac{1}{2}(9\lambda_1^2 - 2\lambda_1\lambda_2 - 2\lambda_1\lambda_3 + 2\lambda_1\lambda_4 + 9\lambda_2^2 + 2\lambda_2\lambda_3 - 2\lambda_2\lambda_4 + 9\lambda_3^2 - 2\lambda_3\lambda_4 + 9\lambda_4^2)$$

Optimiziranje funkcije $J(\vec{\lambda})$ u odnosu na Lagrangeove multiplikatore daje skup jednažbi:

$$9\lambda_1 - \lambda_2 - \lambda_3 + \lambda_4 = 1$$

$$-\lambda_1 + 9\lambda_2 + \lambda_3 - \lambda_4 = 1$$

$$-\lambda_1 + \lambda_2 + 9\lambda_3 - \lambda_4 = 1$$

$$\lambda_1 - \lambda_2 - \lambda_3 + 9\lambda_4 = 1$$

Optimalne vrijednosti su $\lambda_{0,1} = \lambda_{0,2} = \lambda_{0,3} = \lambda_{0,4} = \frac{1}{8}$

- sva četiri vektora u EXOR problemu su potporni vektori

$$J_0(\vec{\lambda}) = \frac{1}{4}$$

$$\frac{1}{2} \|\vec{W}_0\|^2 = \frac{1}{4} \quad \rightarrow \quad \|\vec{W}_0\| = \frac{1}{\sqrt{2}}$$

Nađimo \vec{W}_0

$$\vec{W}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \varphi(\vec{X}_i)$$

$$\vec{W}_0 = \frac{1}{8} [-\varphi(\vec{X}_1) + \varphi(\vec{X}_2) + \varphi(\vec{X}_3) - \varphi(\vec{X}_4)]$$

$$\vec{W}_0 = \frac{1}{8} \left[- \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \end{bmatrix} \right]$$

$$\vec{W}_0 = \begin{bmatrix} 0 \\ 0 \\ -\frac{1}{\sqrt{2}} \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad \text{Pomaknuće } b = w_0 = 0$$


Optimalna hiperravnina je $\vec{W}_0^T \vec{\varphi}(\vec{X}) = 0$

$$[0, 0, \frac{-1}{\sqrt{2}}, 0, 0, 0] \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0$$

$$-x_1x_2 = 0$$

za $x_1 = x_2 = -1$ i $x_1 = x_2 = 1$, izlaz $y=-1$

za $x_1 = -1$ i $x_2 = 1$ te za $x_1 = 1$ i $x_2 = -1$, $y=1$



Slika 7: Prikaz rješenja