

1 Karhunen-Loeva transformacija

I. pristup: K-L transformacija kao postupak minimizacije srednje kvadratne pogreške približnog zapisa uzorka

- Za svaki potpuni skup ortonormiranih jediničnih vektora $\{\vec{e}_j\}$ možemo uzorak \vec{X} zapisati kao:

$$\vec{X} = \sum_{j=1}^r c_j \vec{e}_j.$$

gdje su c_j ; $j = 1, 2, \dots, r$ koeficijenti reda.

Ako uzorak \vec{X} aproksimiramo pomoću $n < r$ članova /koeficijenata reda

izazvat ćemo srednju kvadratnu pogrešku $\vec{\mathcal{E}}^2 = E \left\{ \left| \vec{X} - \sum_{j=1}^n c_j \vec{e}_j \right|^2 \right\}$, gdje

je E operator matematičkog očekivanja.

$$\vec{\mathcal{E}}^2 = E \left\{ \left| \sum_{j=1}^r c_j \vec{e}_j - \sum_{j=1}^n c_j \vec{e}_j \right|^2 \right\}$$

- ako uzmemo u obzir ortonormalnost jediničnih vektora:

$$\vec{e}_j^T \vec{e}_i = \begin{cases} 1, & \text{ako je } j = i \\ 0, & \text{ako je } j \neq i \end{cases}$$

$$\text{dobivamo } \vec{\mathcal{E}}^2 = E \left\{ \sum_{j=n+1}^r c_j^2 \right\}$$

- uzevši u obzir ortonormalnost jediničnih vektora \vec{e}_j dobivamo:

$$\vec{X} = \sum_{j=1}^n c_j \vec{e}_j \Big/ \cdot \vec{e}_j^T$$

$$\vec{e}_j^T \vec{X} = \vec{e}_j^T (c_1 \vec{e}_1 + c_2 \vec{e}_2 + \dots + c_r \vec{e}_r)$$

$$\vec{e}_j^T \vec{X} = \vec{e}_j^T \vec{e}_j c_j$$

$$c_j = \vec{e}_j^T \vec{X} \quad (1. \text{ međurezultat})$$

uvrstimo 1. međurezultat u $\vec{\mathcal{E}}^2$:

$$\vec{\mathcal{E}}^2 = E \left\{ \sum_{j=n+1}^r \underbrace{\vec{e}_j^T \vec{X} \vec{X}^T \vec{e}_j}_{c_j^2} \right\}$$

- Vektori \vec{e}_j su deterministički zato možemo zamijeniti redoslijed operacija zbrajanja i matematičkog očekivanja:

$$\vec{\mathcal{E}}^2 = \sum_{j=n+1}^r \vec{e}_j^T [E \{ \vec{X} \vec{X}^T \}] \vec{e}_j$$

$$\text{Što je } E \{ \vec{X} \vec{X}^T \}?$$

– korelacijska matrica uzorka R

Možemo zapisati:

$$\vec{\mathcal{E}}^2 = \sum_{j=n+1}^r \vec{e}_j^T R \vec{e}_j$$

Skup ortonormalnih vektora \vec{e}_j (koordinatni sustav) koji minimizira srednju kvadratnu pogrešku $\vec{\mathcal{E}}^2$ možemo dobiti pomoću Lagrangeovih multiplikatora

Lagrangeovu funkciju:

$$\mathcal{L}(\vec{e}_j) = \sum_{j=n+1}^r \vec{e}_j^T R \vec{e}_j - \sum_{j=n+1}^r \lambda_j \cdot (\vec{e}_j^T \vec{e}_j - 1)$$

deriviramo po \vec{e}_j i izjednačimo s nulom.

Najmanju vrijednost kriterijske funkcije dobivamo s vektorima \vec{e}_j koji zadovoljavaju jednadžbu:

$(R - \lambda_j I) \vec{e}_j = \vec{0}$, odnosno jednadžbu:

$$R \vec{e}_j = \lambda_j \vec{e}_j$$

Najbolji vektori \vec{e}_j - koordinatne osi Karhunen-Loeve - su **svojstveni vektori korelacijske matrice** $R = E \{ \vec{X} \vec{X}^T \}$, gdje svojstvenom vektoru \vec{e}_j odgovara svojstvena vrijednost korelacijske matrice λ_j

- **Svojstveni vektori korelacijske matrice su ortonormalni \rightarrow koeficijenti K-L reda su međusobno nekorelirani**
- Korelacijska matrica vektora koeficijenata reda $R = E \{ \vec{C} \vec{C}^T \}$ je dijagonalna matrica elemenata koji su jednaki svojstvenim vrijednostima korelacijske matrice $R = E \{ \vec{X} \vec{X}^T \}$
- Ako u izrazu za srednje kvadratnu pogrešku $\vec{\mathcal{E}}^2$ zamijenimo $R \vec{e}_j$ sa $\lambda_j \vec{e}_j$ i uzmemo u obzir ortonormalnost vektora \vec{e}_j dobivamo $\vec{\mathcal{E}}^2 = \sum_{j=n+1}^r \lambda_j$

ZAKLJUČAK: Najmanju srednju kvadratnu pogrešku dobivamo (kada imamo približni zapis uzorka \vec{X} pomoću $n < r$ koeficijenata reda) ako vektor \vec{X} zapišemo s koeficijentima onih svojstvenih vektora \vec{e}_j koji odgovaraju najvećim svojstvenim vrijednostima korelacijske matrice R.

- Transformacijsku matricu A koja minimizira $\vec{\mathcal{E}}^2$ tvorimo iz prvih n vektora koordinatnih osi \vec{e}_j ; $j = 1, 2, \dots, n$ koji su uređeni po padajućem redoslijedu svojstvenih vrijednosti matrice R:

$$A = \begin{bmatrix} \vec{e}_1^T \\ \vec{e}_2^T \\ \vdots \\ \vec{e}_n^T \end{bmatrix}, \text{ gdje } \vec{e}_j, j = 1, 2, \dots, n \text{ odgovaraju članovima niza } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq \dots \geq \lambda_r$$

- Vektor uzoraka \vec{Y} dobivamo :

$$\vec{Y}_{[n \times 1]} = A_{[n \times r]} \cdot \vec{X}_{[r \times 1]} \quad n < r$$

\vec{Y} je reducirani vektor uzoraka s r dimenzija na n !

Na području raspoznavanja uzoraka umjesto korelacijske matrice R upotrebljavamo kovarijantnu matricu K (inačica K-L transformacije) koja je osnova za računanje koordinatnih osi reda:

$$K e_j = \lambda_j e_j. \text{ gdje je } K = E \{ (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T \}$$

- Uporabom kovarijantne matrice (umjesto korelacijske matrice) naglašavamo varijacije uzoraka u razredima / od svakog smo uzorka oduzeli srednju vrijednost svih uzoraka /

- Srednja kvadratna pogreška ako uzorak \vec{X} zapišemo uzorkom \vec{Y} , $\vec{Y} = A\vec{X}$ je:


$$\vec{\mathcal{E}}^2 = \sum_{j=n+1}^r E \{ c_j \} e_j$$

Primjer:

Zadani su uzorci za učenje:

$$\text{Razred } \omega_1 = \{ (0, 0, 0)^T, (1, 0, 0)^T, (1, 0, 1)^T, (1, 1, 0)^T \}$$

$$\text{Razred } \omega_2 = \{ (0, 0, 1)^T, (0, 1, 0)^T, (0, 1, 1)^T, (1, 1, 1)^T \}$$



Slika 1: Primjer

Pretpostavimo $P(\omega_1) = P(\omega_2) = 0.5$

- Vektore za učenje (radi lakšeg računanja) označimo dvama indeksima

$$\omega_1 = \{ \vec{X}_{11}, \vec{X}_{12}, \vec{X}_{13}, \vec{X}_{14} \}$$

$$\omega_1 = \{ \vec{X}_{21}, \vec{X}_{22}, \vec{X}_{23}, \vec{X}_{24} \}$$

\vec{X}_{ij} , i označava pripadnost razredu, j označava redoslijed uzoraka u razredu

Izračunajmo korelacijsku matricu R :

$$R = E \{ \vec{X} \vec{X}^T \}$$

$$R = \sum_{i=1}^2 P(\omega_i) \cdot E \{ \vec{X}_i \vec{X}_i^T \} = \frac{1}{2} E \{ \vec{X}_1 \vec{X}_1^T \} + \frac{1}{2} E \{ \vec{X}_2 \vec{X}_2^T \}, \text{ gdje } E \{ \vec{X}_1 \vec{X}_1^T \}$$

i $E \{ \vec{X}_2 \vec{X}_2^T \}$ označavaju očekivanje svih uzoraka u razredima ω_1 i ω_2 , respektivno.

$$R = \frac{1}{N_1} P(\omega_1) \sum_{j=1}^{N_1=4} \vec{X}_{1j} \vec{X}_{1j}^T + \frac{1}{N_2} P(\omega_2) \sum_{j=1}^{N_2=4} \vec{X}_{2j} \vec{X}_{2j}^T$$

$$\begin{aligned}
R &= \frac{1}{4} \frac{1}{2} \left\{ \left(\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \end{bmatrix} \right) + \left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \right) + \left(\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \end{bmatrix} \right) + \left(\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \end{bmatrix} \right) \right\} + \\
&\frac{1}{4} \frac{1}{2} \left\{ \left(\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 1 \end{bmatrix} \right) + \left(\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \right) + \left(\begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 \end{bmatrix} \right) + \left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \end{bmatrix} \right) \right\} \\
&= \frac{1}{8} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} + \frac{1}{8} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 3 \end{bmatrix} \\
R &= \frac{1}{4} \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}
\end{aligned}$$

Svojstvene vrijednosti i normalizirani vektori su:

$$\begin{aligned}
\lambda_1 &= 1 \quad \vec{e}_1 = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \\
\lambda_2 &= \frac{1}{4} \quad \vec{e}_2 = \frac{1}{\sqrt{6}} \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix} \\
\lambda_3 &= \frac{1}{4} \quad \vec{e}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}
\end{aligned}$$

Izaberimo \vec{e}_1 i \vec{e}_2 koji odgovaraju najvećim svojstvenim vrijednostima te dobivamo transformacijsku matricu A:

$$A = \begin{bmatrix} \vec{e}_1^T \\ \vec{e}_2^T \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ \frac{\sqrt{3}}{2} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$

Transformirajmo uzorke \vec{X} i \vec{Y}

$$\vec{Y} = A \cdot \vec{X}$$

Dobivamo:

$$\begin{aligned}
\vec{Y}_1 &= \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ \frac{\sqrt{3}}{2} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad Y_{11} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\
\vec{Y}_2 &= \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ \frac{\sqrt{3}}{2} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{\sqrt{3}}{2} \end{bmatrix} \quad Y_{12} = \frac{1}{\sqrt{6}} \begin{bmatrix} \sqrt{2} \\ -2 \end{bmatrix}
\end{aligned}$$

$$\vec{Y}_{13} = \frac{1}{\sqrt{6}} \begin{bmatrix} 2\sqrt{2} \\ -1 \end{bmatrix}$$

$$\vec{Y}_{14} = \frac{1}{\sqrt{6}} \begin{bmatrix} 2\sqrt{2} \\ -1 \end{bmatrix}$$


Uzorci iz razreda ω_2 :

$$\vec{Y}_{21} = \frac{1}{\sqrt{6}} \begin{bmatrix} \sqrt{2} \\ 1 \end{bmatrix}$$

$$\vec{Y}_{22} = \frac{1}{\sqrt{6}} \begin{bmatrix} \sqrt{2} \\ 1 \end{bmatrix}$$

$$\vec{Y}_{23} = \frac{1}{\sqrt{6}} \begin{bmatrix} 2\sqrt{2} \\ 2 \end{bmatrix}$$

$$\vec{Y}_{24} = \frac{1}{\sqrt{6}} \begin{bmatrix} 3\sqrt{2} \\ 0 \end{bmatrix}$$



Slika 2: Prikaz uzoraka u 2D prostoru

Vidimo: u reduciranom prostoru uzorci su i dalje linearno separatibilni
Što će se dogoditi ako uzorke transformiramo u 1-dimenzionalni prostor?

II. pristup: K-L transformacija kao postupak kojim se maksimizira varijanca

- ako imamo vektor \vec{X} koji je r -dimenzionalan i želimo ga predložiti uporabom $n < r$ komponenti \rightarrow vektor \vec{X} reduciramo tako da srednja kvadratna pogreška između vektora \vec{X} i aproksimiranog vektora bude jednaka sumi varijanci komponenti koje su eliminirane iz \vec{X}
Drugim riječima: aproksimaciju vektora \vec{X} "gradimo" iz $n < r$ komponenti koje imaju najveću varijancu!
- Označimo s \vec{X} r -dimenzionalni vektor (slučajni)!
- Pretpostavimo da slučajni vektor \vec{X} ima srednju vrijednost 0:
 $E[\vec{X}] = \vec{0}$, gdje je E operator matematičkog očekivanja!
- ako \vec{X} nema srednju vrijednost $\vec{0}$ možemo srednju vrijednost oduzeti od \vec{X} prije negoli nastavimo daljnji postupak
- označimo s \vec{e} jedinični vektor koji je također r -dimenzionalan
- Projiciramo vektor \vec{X} na \vec{e} !
/ Projekcija je definirana kao skalarni produkt vektora \vec{X} i \vec{e} /
 $A = \vec{X}^T \vec{e} = \vec{e}^T \vec{X}$
uz ograničenje
 $\|\vec{e}\| = (\vec{e}^T \vec{e})^{1/2} = 1$
- Projekcija A je slučajna varijabla sa srednjom vrijednosti i varijancom u kojima se zrcali statistika slučajnog vektora \vec{X}
- uz pretpostavku da slučajni vektor \vec{X} ima srednju vrijednost $\vec{0}$ slijedi da je srednja vrijednost projekcije A
 $E[A] = E[\vec{e}^T \vec{X}] = \vec{e}^T E[\vec{X}] = 0$
- Varijanca projekcije A (zato što je $E[A] = 0$) je:
 $\sigma^2 = E[A^2] = E[(\vec{e}^T \vec{X})(\vec{X}^T \vec{e})] = \vec{e}^T E[\vec{X} \vec{X}^T] \vec{e} = \vec{e}^T R \vec{e}$, gdje je R $r \times r$ korelacijska matrica slučajnog vektora \vec{X} :
 $R = E[\vec{X} \vec{X}^T]$
- Korelacijska matrica je simetrična:
 $R^T = R$
/iz tog svojstva slijedi:
 $\vec{a}^T R \vec{b} = \vec{b}^T R \vec{a}$, gdje su \vec{a} i \vec{b} $r \times 1$ vektori/
- Označimo s Ψ varijancu σ^2
 $\Psi(\vec{e}) = \sigma^2$
 $\Psi(\vec{e}) = \vec{e}^T R \vec{e}$
- Tražimo one jedinične vektore \vec{e} uzduž koji $\Psi(\vec{e})$ ima ekstreme ili stacionarne vrijednosti (lokalni maksimum ili lokalni minimum)
/ uz ograničenja koje se odnosi na Euklidsku normu vektora \vec{e} ;
 $\vec{e}^T \vec{e} = 1$ /

Optimizacijski problem:

$\Psi(\vec{e})$ - maksimalna vrijednost uz ograničenje $\vec{e}^T \vec{e} = 1$

$\mathcal{L}(\vec{e}) = \vec{e}^T R \vec{e} - \lambda(\vec{e}^T \vec{e} - 1)$


Rješenje:

$(R - \lambda I)\vec{e} = \vec{0}$

odnosno: $R\vec{e} = \lambda\vec{e}$

Primjer: Zadan je skup 2-D vektora:

$$\begin{aligned} \vec{X}_1 &= \begin{bmatrix} 1.5 \\ 2 \end{bmatrix} & \vec{X}_2 &= \begin{bmatrix} 0.9 \\ 1.3 \end{bmatrix} & \vec{X}_3 &= \begin{bmatrix} 1.4 \\ 1.3 \end{bmatrix} & \vec{X}_4 &= \begin{bmatrix} 2 \\ 2.3 \end{bmatrix} & \vec{X}_5 &= \begin{bmatrix} 2.6 \\ 2.5 \end{bmatrix} \\ \vec{X}_6 &= \begin{bmatrix} 2.8 \\ 3 \end{bmatrix} & \vec{X}_7 &= \begin{bmatrix} 2.3 \\ 2.7 \end{bmatrix} & \vec{X}_8 &= \begin{bmatrix} 1.3 \\ 1.5 \end{bmatrix} & \vec{X}_9 &= \begin{bmatrix} 1.8 \\ 1.6 \end{bmatrix} & \vec{X}_{10} &= \begin{bmatrix} 2.4 \\ 2.1 \end{bmatrix} \end{aligned}$$



Slika 3: Primjer

Izračunajmo srednju vrijednost i kovarijantnu matricu:

$$E[\vec{X}] = \frac{1}{N} \sum_{k=1}^N \vec{X}_k = \frac{1}{10} \sum_{k=1}^{10} \vec{X}_k = \begin{bmatrix} 1.9 \\ 2 \end{bmatrix}$$

K umjesto R

$$K = \frac{1}{N-1} \sum_{k=1}^N (\vec{X}_k - E[\vec{X}])(\vec{X}_k - E[\vec{X}])^T$$


$$K = \begin{bmatrix} 0.3990 & 0.3456 \\ 0.3456 & 0.4044 \end{bmatrix}$$

-svojstvene vrijednosti matrice K su $\lambda_1 = 0.7423$ i $\lambda_2 = 0.051$ a svojstveni vektori

$$\vec{e}_1 = \begin{bmatrix} 0.6991 \\ 0.715 \end{bmatrix} \text{ i } \vec{e}_2 = \begin{bmatrix} -0.715 \\ 0.6991 \end{bmatrix}$$

svojstveni vektori \vec{e}_1 i \vec{e}_2 s ishodištem u $E[\vec{X}]$ razapinju novi prostor na kojeg preslikavamo novi prostor na kojeg preslikavamo uzorke \vec{X}_k ; $k = 1, 2, \dots, 10$!

- Svojstvene vrijednosti λ_1 i λ_2 su varijance uzduž osi \vec{e}_1 i \vec{e}_2
- Vidimo da je raspršenje skupa najveće uzduž osi \vec{e}_1 jer je $\lambda_1 > \lambda_2$!



Slika 4: Normalizirani skup točaka s ucrtanim svojstvenim vektorima

- Izvorni skup je dvodimenzionalan. Možemo ga aproksimirati preslikavanjem na jednodimenzionalni prostor koristeći e_1 kao os projekcije:

$$\vec{Y}_1 = e_1^T \begin{bmatrix} x_1^* \\ x_2^* \end{bmatrix} = [0.6991, 0.715] \begin{bmatrix} 1.5 - 1.9 \\ 2 - 2 \end{bmatrix}$$

$$\text{PAZI } x_1^* = x_1 - E[\vec{X}]; x_2^* = x_2 - E[\vec{X}]$$

$$\vec{Y}_1 = -0.28 \quad \vec{Y}_2 = -1.2 \quad \vec{Y}_3 = -0.99 \quad \vec{Y}_4 = 0.28 \quad \vec{Y}_5 = 0.85$$

$$\vec{Y}_6 = 1.34 \quad \vec{Y}_7 = 0.78 \quad \vec{Y}_8 = -0.78 \quad \vec{Y}_9 = -0.43 \quad \vec{Y}_{10} = 0.42$$

\vec{Y}_i promatramo kao jednodimenzionalni vektor!

Izvorne podatke, uz gubitak informacije, možemo rekonstruirati primjenimo li inverznu transformaciju

$$\vec{Y} = A \cdot \vec{X} \rightarrow \vec{X} = A^{-1} \vec{Y}$$

$$\text{vrijedi: } A^{-1} = A^T \quad \vec{X}_{[2 \times 1]} = A_{[2 \times 1]}^T \vec{Y}_{[1 \times 1]}$$

$$\text{za naš slučaj } \vec{X}_{[2 \times 1]} \quad \vec{Y}_{[1 \times 1]}$$

$$A = [0.6991 \quad 0.715]_{[1 \times 2]}$$

$$A^T = \begin{bmatrix} 0.6991 \\ 0.715 \end{bmatrix}$$

$$\vec{X}_1^A = \begin{bmatrix} 0.6991 \\ 0.715 \end{bmatrix} \cdot [-0.28] + \begin{bmatrix} 1.9 \\ 2 \end{bmatrix} \rightarrow \text{DODALI SREDNJU VRIJEDNOST}$$

$$\vec{X}_1^A = \begin{bmatrix} -0.195 \\ -0.2002 \end{bmatrix} + \begin{bmatrix} 1.9 \\ 2 \end{bmatrix}$$

$$\vec{X}_1^A = \begin{bmatrix} 1.705 \\ 1.7998 \end{bmatrix} \rightarrow \text{APROKSIMIRANA VRIJEDNOST}$$


$$\text{za } \vec{X}_6 = \begin{bmatrix} 2.8 \\ 3 \end{bmatrix} \leftarrow \text{izvorna vrijednost}$$

$$\vec{Y}_6 = [1.34]$$

$$\vec{X}_6^A = A^T \cdot \vec{Y}_6 = \begin{bmatrix} 0.6991 \\ 0.715 \end{bmatrix} \cdot [1.34] + \begin{bmatrix} 1.9 \\ 2 \end{bmatrix} = \begin{bmatrix} 0.9367 \\ 0.9581 \end{bmatrix} + \begin{bmatrix} 1.9 \\ 2 \end{bmatrix} = \begin{bmatrix} 2.8367 \\ 2.9581 \end{bmatrix}$$

Primjer:

- horizontalna i vertikalna os predstavlja "prirodni" koordinatni sustav skupa podataka



Slika 5: Primjer

- rotirane osi označene 1 i 2 su rezultat uporabe K-L transformacije na zadanom skupu podataka
- vidimo da projicirani skup podataka na os 1 sadrži istaknutu (engl. salient) karakteristiku podataka, tj. činjenicu da je skup podataka bimodalan
- varijanca projekcija skupa podataka na os 1 je veća od bilo koje druge projekcije (na osi u slici)


POZOR!

K-L transformacijom preslikavamo uzorke iz r -dimenzionalnog prostora u n -dimenzionalan prostor ($n < r$) uz kriterij najmanje srednje kvadratne pogreške preslikavanja! **To nužno ne znači da će separatibilnost razreda u n -dimenzionalnom prostoru biti jednaka ili približno jednaka separatibilnosti uzoraka u r -dimenzionalnom prostoru** (razumljivo jer je kriterijska funkcija takva da optimira rekonstrukciju!)

Ilustrirajmo to!

$$\lambda_1 > \lambda_2$$

Uzorci razreda ω_1 i ω_2 neka imaju normalnu distribuciju



Slika 6: Ilustracija