

1 Optimalna hiperravnina za slučaj linearno neodvojivih razreda

-SVMs (Support Vector Machines)

- do sada stroj s potpunim vektorima \rightarrow razredi linearno odvojivi

Teži slučaj - linearno neodvojivi uzorci

- za zadani skup uzoraka za učenje (engl. training set) NIJE MOGUĆE KONSTRUIRATI HIPERRAVNINU KOJA RAZDVAJA UZORKE BEZ POGREŠKE


ŽELIMO: Naći optimalnu hiperravninu koja minimizira vjerojatnost klasifikacijske pogreške

Margina razdvajanja naziva se mekom (engl. soft) ako za uzorak (\vec{X}_i, d_i) ne vrijedi

$$d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq +1, i = 1, 2, \dots, N$$

Povreda uvjeta $d_i(\vec{W}^T \vec{X}_i + b) \geq 1$ može nastupiti na dva načina

- Uzorak (\vec{X}_i, d_i) pada unutar područja odvajanja ALI na "pravu" stranu decizijske hiperravnine (na slici a)
- Uzorak (\vec{X}_i, d_i) pada na "krivu" stranu decizijske hiperravnine (na slici b)




Slika 1: Prikaz slučajeva povrede uvjeta

- Margina je definirana kao udaljenost između para paralelnih hiperravnina opisanih s:

$$\vec{W}^T \vec{X} + b = \pm 1$$

Uzorci za učenje pripadaju jednoj od tri kategorije uzoraka:

- vektori koji padaju izvan pojasa i koji su ispravno klasificirani /ti vektori zadovoljavaju: $d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1, i = 1, 2, \dots, N$



Slika 2: Drugačiji prikaz povrede

- (ii) vektori koji padaju unutar pojasa (margine) ali su pravilno razvrstani: (x)(o)
za njih vrijedi: $0 \leq d_i \cdot (\vec{W}^T \vec{X}_i + b) < 1$
- (iii) vektori s pogrešnom klasifikacijom: [o][x]
za njih vrijedi $d_i \cdot (\vec{W}^T \vec{X}_i + b) < 0$

Sva tri slučaja mogu se objediniti u jedinstveni oblik: $d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 - \zeta_i$
- novi skup varijabli: $\{\zeta_i\}_{i=1}^N$

- (i) slučaj: odgovaraju uzorci za koje je $\zeta_i = 0$
- (ii) slučaj: $0 < \zeta_i \leq 1$
- (iii) slučaj: $\zeta_i > 1$

- Varijable ζ_i se nazivaju "labave" varijable (engl. slack variables) - one su mjera odstupanja vektora od idealnog uvjeta separabilnosti uzoraka.
- za $0 \leq \zeta_i \leq 1$ uzorak se nalazi unutar područja odvajanja ALI s prave strane decizijske ravnine
- za $\zeta_i > 1$ uzorak pada na krivu stranu decizijske ravnine
- potporni vektori su oni posebni uzorci koji zadovoljavaju jednadžbu $d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 - \zeta_i$, $i = 1, 2, \dots, N$ čak i za slučaj $\zeta_i > 0$.

ZADATAK: Naći decizijsku funkciju (hiperravninu razdvajanja) za koju je klasifikacijska pogreška minimalna!

Drugačije interpretirano: Učiniti marginu što je moguće većom ali uz uvjet da je broj uzoraka sa $\zeta_i > 0$ što je moguće manji!

Matematička interpretacija:

- minimizirati funkciju koštanja (funkcional)

$$J(\vec{W}, b, \vec{\zeta}) = \frac{1}{2} \|\vec{W}\|^2 + C \sum_{i=1}^N I(\zeta_i), \text{ gdje je } \vec{\zeta} \text{ vektor s komponentama } \zeta_i \text{ i}$$

$$I(\zeta_i) = \begin{cases} 1 & \zeta_i > 0 \\ 0 & \zeta_i = 0 \end{cases}$$

Parametar C je pozitivna konstanta kojom se upravlja relativan međuutjecaj $\frac{1}{2} \|\vec{W}\|^2$ i $\sum_{i=1}^N I(\zeta_i)$

S. Haykin (1999.) predlaže dva moguća načina izbora C :

- (i) eksperimentalno preko standardne uporabe uzoraka za učenje i validaciju
- (ii) C se određuje analitički procjenom VC (Vapnik-Chervonenkis) dimenzije - koja je mjera ekspresivnosti porodice klasifikacijskih funkcija koje su ostvarene strojem za učenje:
 dimenzija h , $h \leq \min \left\{ \left\lceil \frac{D^2}{\rho^2} \right\rceil, m_0 \right\} + 1$
 D - promjer najmanje kugle koja sadrži sve ulazne vektore $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$
 ρ - margina = $\frac{2}{\|\vec{W}\|}$ i
 m_0 - je dimenzionalnost ulaznog prostora

Optimizacija izraza: $J(\vec{W}, b, \vec{\zeta}) = \frac{1}{2} \|\vec{W}\|^2 + C \sum_{i=1}^N I(\zeta_i)$, teška je jer je uključena i funkcija $I(\cdot)$ koja je diskontinuirana!

Uobičajen pristup \rightarrow izabrati optimizaciju funkcije koja je "bliska" funkciji koštanja:

$$J(\vec{W}, b, \vec{\zeta}) = \frac{1}{2} \|\vec{W}\|^2 + C \sum_{i=1}^N \zeta_i, \text{ uz } d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 - \zeta_i, i = 1, 2, \dots, N \text{ i } \zeta_i \geq 0, i = 1, 2, \dots, N$$

Formalno: primarni problem za neseparabilne razrede

- Za zadani skup uzoraka za učenje $\{\vec{X}_i, d_i\}_{i=1}^N$ naći optimalne vrijednosti težinskog vektora \vec{W} i pomaknuća b tako da su zadovoljena sljedeća ograničenja:
 $d_i \cdot (\vec{W}^T \vec{X}_i + b) \geq 1 - \zeta_i$, za $i = 1, 2, \dots, N$ i $\zeta_i \geq 0$, za sve i
 i to takve da \vec{W} i labave varijable ζ_i minimiziraju funkciju koštanja

$J(\vec{W}, b, \vec{\zeta}) = \frac{1}{2} \vec{W}^T \vec{W} + C \sum_{i=1}^N \zeta_i$, pri čemu je C korisničko definiran pozitivni parametar.

Uporabom metode Lagrangeovih multiplikatora i postupkom sličnim za lin. separabilni SM slijedi:

$$\mathcal{L}(\vec{W}, b, \vec{\zeta}, \vec{\lambda}, \vec{\mu}) = \frac{1}{2} \|\vec{W}\|^2 + C \sum_{i=1}^N \zeta_i - \sum_{i=1}^N \mu_i \zeta_i - \sum_{i=1}^N \lambda_i \cdot [d_i (\vec{W}^T \vec{X}_i + b) - 1 + \zeta_i]$$

Odgovarajući K-K-T (Karush-Kuhn-Tucker) uvjeti su

$$\frac{\partial \mathcal{L}}{\partial \vec{W}} = \vec{0} \text{ ili } \vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \text{ ili } \sum_{i=1}^N \lambda_i d_i = 0$$

$$\frac{\partial \mathcal{L}}{\partial \zeta_i} = \vec{0} \text{ ili } C - \mu_i - \lambda_i = 0$$

$$i = 1, 2, \dots, N$$

$$\lambda_i [d_i (\vec{W}^T \vec{X}_i + b) - 1 + \zeta_i] = 0, i = 1, 2, \dots, N$$

$$\mu_i \zeta_i = 0, i = 1, 2, \dots, N$$

$$\mu_i \geq 0, \lambda_i \geq 0, i = 1, 2, \dots, N$$

Pridružena Wolfeova dualna reprezentacija postaje:

maksimiziraj $\mathcal{L}(\vec{W}, b, \vec{\lambda}, \vec{\zeta}, \vec{\mu})$ uz ograničenja :

$$\vec{W} = \sum_{i=1}^N \lambda_i d_i \vec{X}_i$$

$$C - \mu_i - \lambda_i = 0, i = 1, 2, \dots, N$$

$$\lambda_i \geq 0, \mu_i \geq 0, i = 1, 2, \dots, N$$

Uvrštavanjem nejednadžbi u \mathcal{L} dobiva se:

$$\max_{\vec{\lambda}} \left(\sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \lambda_i \lambda_j d_i d_j \vec{X}_i^T \vec{X}_j \right) \text{ uz uvjete } 0 \leq \lambda_i \leq C, i = 1, 2, \dots, N \text{ i}$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

Lagrangeovi multiplikatori koji odgovaraju točkama (uzorcima) koji leže unutar margine ili na krivoj stani klasifikatora, tj. $\zeta_i > 0$ su svi jednaki maksimalno dopuštenoj vrijednosti C .

- promotrimo izraz:

$$\max_{\vec{\lambda}} \left(\sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \lambda_i \lambda_j d_i d_j \vec{X}_i^T \vec{X}_j \right)$$

vidimo da niti labave varijable ζ_i niti Lagrangeovi multiplikatori pridruženi labavim varijablama μ_i ne ulaze eksplicitno u problem

- oni su prisutni neizravno kroz C , odnosno kroz uvjet: $0 \leq \lambda_i \leq C$

Razlika u odnosu na linearno separabilni slučaj:

Lagrangeovi multiplikatori su (moraju biti) ograničeni sa C . / $0 \leq \lambda_i \leq C$ /

-za linearno separabilni slučaj $C \rightarrow \infty$ / $\lambda_i \geq 0$ /

Osim ove modifikacije

$$\lambda_i \geq 0 \rightarrow 0 < \lambda_i \leq C$$

postupak računanja optimalnih vrijednosti vektora \vec{W} i pomaknuća b je jednak kao i kod separabilnog slučaja

Rješenje:

$$\vec{W}_0 = \sum_{i=1}^{N_s} \lambda_{0,i} d_i \vec{X}_i, \text{ gdje je } N_s \text{ broj vektora koji su potporni, a } 0 < \lambda_{0,i} < C$$

pomaknuće b_0 se može odrediti uzimajući bilo koji (\vec{X}_i, d_i) iz skupa za učenje za koji vrijedi $0 < \lambda_{0,i} < C$ i zato je $\zeta_i = 0$