


1 Klasifikacija temeljena na Bayesovoj decizijskoj teoriji

/Statistički pristup raspoznavanju uzoraka/

PRIMJER: M=2

$\omega = \omega_1$ JASEN

$\omega = \omega_2$ JELA



Slika 1: Primjer


x_0 - nije dovoljan

DRUGA KARAKTERISTIKA: IZRAŽENOST STRUKTURE DRVETA!

JASEN ima izraženiju strukturu drveta

VEKTOR UZORKA

$$\vec{X} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad x_1 - \text{TON}, x_2 - \text{STRUKTURA}$$



Slika 2: Prikaz klasa

PRETPOSTAVKA: PROMATRAMO POJAVLJIVANJE DASKE
 - SLUČAJNO POJAVLJIVANJE VRSTE DASKE (JASEN ili JELA)
 "IGRA PRIRODE" → STANJE PRIRODE (ili VANJSKOG SVIJETA) NEKA JE ω
 $\omega = \omega_1$ jasen
 $\omega = \omega_2$ jela

- Budući da se stanje prirode ne može predvidjeti ω se promatra kao slučajna (engl. random) varijabla
- Ako tvornica proizvodi jednak broj jelovih i jasenovih dasaka → slijedeći komad daske ima jednaku vjerojatnost da bude jasen ili pak jela

$\left. \begin{array}{l} \text{á priori vjerojatnost } P(\omega_1) / \text{ da daska bude jasena} / \\ \text{á priori vjerojatnost } P(\omega_2) / \text{ jelova daska} / \end{array} \right\} \text{ NAŠE "ZNANJE" O PRO-}$
 CESU: $P(\omega_1) \geq 0$; $P(\omega_2) \geq 0$ i $P(\omega_1) + P(\omega_2) = 1$

Pretpostavimo da odluku moramo donijeti samo na temelju vrijednosti á priori vjerojatnosti:

DECIZIJSKO PRAVILO: Odlučujem se za ω_1 ako je $P(\omega_1) > P(\omega_2)$, inače odlučujem ω_2

"Čudno pravilo" → uvijek donosim istu odluku iako znamo da se oba tipa dasaka pojavljuju

Ako je $P(\omega_1) \gg P(\omega_2)$ OK

Ako je $P(\omega_1) = P(\omega_2)$ 50%-50%

UZMIMO U OBZIR SVJETLINU odn. TON DRVETA!


- različiti uzorci dasaka daju različitu svjetlinu: Neka je x kontinuirana slučajna varijabla čija distribucija zavisi od stanja prirode.

- uvjetna gustoća razdiobe vjerojatnosti (state-conditional probability density function)

$p(x|\omega_j)$ - gustoća razdiobe vjerojatnosti

Funkcija gustoće razdiobe vjerojatnosti (probability density function) za kontinuiranu varijablu x jeste takva funkcija $f(x)$ koja ima svojstva:

1. $f(x) \geq 0$ za svaki x
2. $\int_{-\infty}^{+\infty} f(x)dx = 1$
3. $\int_{x_1}^{x_2} f(x)dx = P\{x_1 < x < x_2\}$



Slika 3: Gustoća razdiobe vjerojatnosti

PRETPOSTAVKA:

- znamo *á priori* vjerojatnosti $P(\omega_j)$ i uvjetne gustoće razdiobe vjerojatnosti $p(x|\omega_j)$ (engl. likelihood of ω_j , vjerodostojnost)


Pretpostavimo da smo izmjerili svjetlinu daske i dobili vrijednost x
KAKO TO MJERENJE UTJEČE NA NAŠU ODLUKU O PRAVOM STANJU PRIRODE?

BAYESOVO PRAVILO:

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{\underbrace{p(x)}_{\text{engl. evidence}}}$$

$$p(x) = \sum_{j=1}^2 p(x|\omega_j)P(\omega_j)$$

BAYESOVO PRAVILO → pokazuje kako promatrana vrijednost x mijenja *á priori* vjerojatnost $P(\omega_j)$ u *á posteriori* vjerojatnost $P(\omega_j|x)$



Slika 4: Aposteriori vjerojatnosti

- imamo promatranje x za koje je $P(\omega_1|x) > P(\omega_2|x)$ odluka: stanje prirode je ω_2 ! **VJEROJATNOST POGREŠKE?**

(vjerojatnost pogreške pri svakoj odluci: $P(error|x)$)

$$P(error|x) = \begin{cases} P(\omega_1|x) & \text{ako se odlučimo za } \omega_2 \\ P(\omega_2|x) & \text{ako se odlučimo za } \omega_1 \end{cases}$$

MINIMIZIRAJMO VJEROJATNOST POGREŠKE DONOŠENJEM SLIJEDEĆIH ODLUKA:

ω_1 ako je $P(\omega_1|x) > P(\omega_2|x)$ ili ω_2 ako je $P(\omega_2|x) > P(\omega_1|x)$

Da li ovo pravilo minimizira srednju vjerojatnost pogreške?

$$\text{Da} \rightarrow P(error) = \int_{-\infty}^{+\infty} P(error, x) dx = \int_{-\infty}^{+\infty} P(error|x) p(x) dx$$

jer ako je za svaki x $P(error|x)$ najmanja moguća vrijednost tada i integral mora biti najmanji.

Bayesovo decizijsko pravilo za minimizaciju vjerojatnosti pogreške:

ODLUČI SE ZA ω_1 ako je $P(\omega_1|x) > P(\omega_2|x)$ inače odluči se za ω_2

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{\underbrace{p(x)}}_{\text{(nije bitno!!!)}}$$

$p(x)$ samo skalarni faktor koji osigurava da $P(\omega_1|x) + P(\omega_2|x) = 1$

MODIFICIRANO PRAVILO:

ODLUČI SE ZA ω_1 ako je $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$ inače ω_2

Pretpostavimo neke situacije:

- ako je za neki x $p(x|\omega_1) = p(x|\omega_2)$ odluka se temelji na á priori vjerojatnosti
- ako je $P(\omega_1) = P(\omega_2)$ odluka se temelji na $p(x|\omega_j) \rightarrow$ vjerojatnost ω_j u odnosu na x .

UOPĆENJE:

1. upotreba više od jedne značajke,
2. više od dva stanja prirode,
3. dopustit ćemo i akciju umjesto same odluke o stanju prirode,
4. uvest ćemo funkciju gubitka kao općenitiju mjeru u odnosu na vjerojatnost pogreške

1. upotreba više od jedne značajke

- umjesto skalar x rabimo vektor značajki $\vec{X} \in R^d$; \vec{X} je d -dimenzionalni vektor iz Euklidskog prostora R^d

2. više od dva stanja prirode

- Neka je $\{\omega_1, \dots, \omega_c$ konačan skup od c stanja (razreda, kategorija)

3. uvodjenje akcije umjesto samo odluke o stanju prirode

- skup $\{\alpha_1, \dots, \alpha_a$ konačan skup od a mogućih akcija

4. funkcija gubitka (engl. loss function) $\lambda(\alpha_i|\omega_j)$

$\lambda(\alpha_i|\omega_j)$ opisuje gubitak nastao poduzimanjem akcije α_i kada je stanje prirode ω_j

\vec{X} - d -dimenzionalni vektor značajki

$p(\vec{X}|\omega_j)$ - funkcija uvjetne razdiobe gustoće vjerojatnosti

$p(\omega_j)$ - apriorna vjerojatnost da je stanje prirode ω_j

Posteriorna vjerojatnost $P(\omega_j|\vec{X})$ (Bayesova formula):

$$P(\omega_j|\vec{X}) = \frac{p(x|\omega_j)P(\omega_j)}{p(\vec{X})}$$

$$p(\vec{X}) = \sum_{j=1}^c p(x|\omega_j)P(\omega_j)$$

- Pretpostavimo da smo promatrali \vec{X} i da smo na temelju tog promatranja poduzeli akciju α_i

- ako je stanje prirode ω_j , po definiciji, pretrpili smo gubitak $\lambda(\alpha_i|\omega_j)$

- Budući da je $P(\omega_j|\vec{X})$ vjerojatnost da je stanje prirode zaista ω_j očekujemo gubitak koji nastaje poduzimanjem akcije α_i

$$R(\alpha_i|\vec{X}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\vec{X}) \rightarrow \text{Očekivani gubitak (rizik)}$$

$$R(\alpha_i|\vec{X}) \rightarrow \text{uvjetni rizik}$$

Kadgod se susretnemo s određenim \vec{X} , možemo MINIMIZIRATI očekivani gubitak tako da izaberemo AKCIJU koja minimizira uvjetni rizik - Bayesova decizijska procedura daje optimalnu performansu

Decizijsko pravilo je funkcija $\alpha(\vec{X})$ koja nam kaže koju akciju poduzeti za svako promatranje \vec{X} :

Za svaki \vec{X} decizijska funkcija $\alpha(\vec{X})$ podrazumijeva izbor jedne od a akcija $\alpha_1, \dots, \alpha_a$.

Ukupan rizik R je očekivani gubitak pridružen zadanom decizijskom pravilu.

$R(\alpha_i|\vec{X})$ je uvjetni rizik pridružen akciji α_i a budući da decizijsko pravilo specificira akciju ukupan rizik je :

$$R = \int R(\alpha(\vec{X}), \vec{X}) p(\vec{X}) d\vec{X},$$

$d\vec{X}$ d-volumenski element a \int se "proteže" nad cijelim prostorom značajki.

Ako $\alpha(\vec{X})$ je izabran tako da je $R(\alpha_i(\vec{X}))$ što je moguće manji za svaki \vec{X} , tako da se ukupan rizik minimizira.

Bayesovo decizijsko pravilo:

Da bi minimizirali ukupan rizik, izračunajmo uvjetni rizik

$$R(\alpha_i|\vec{X}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j) P(\omega_j|\vec{X}) \text{ za } i = 1, 2, \dots, a \text{ i tada IZABERIMO AKCIJU}$$

α_i za koju je $R(\alpha_i|\vec{X})$ MINIMUM.

Rezultirajući minimalni ukupni rizik naziva se Bayesov rizik.

Primjer klasifikacije za M=2

α_1 - akcija koja odgovara odluci da je pravo stanje prirode ω_1

α_2 - akcija koja odgovara odluci ω_2

Ispišimo uvjetni rizik:

$$R(\alpha_1|\vec{X}) = \lambda(\alpha_1|\omega_1)P(\omega_1|\vec{X}) + \lambda(\alpha_1|\omega_2)P(\omega_2|\vec{X})$$

$$R(\alpha_2|\vec{X}) = \lambda(\alpha_2|\omega_1)P(\omega_1|\vec{X}) + \lambda(\alpha_2|\omega_2)P(\omega_2|\vec{X})$$

Bayesovo decizijsko pravilo:

Odluči se za ω_1 ako je $R(\alpha_1|\vec{X}) < R(\alpha_2|\vec{X})$

Kraće pišemo $\lambda_{ij} = \lambda(\alpha_i|\omega_j)$!

$$\lambda_{11}P(\omega_1|\vec{X}) + \lambda_{12}P(\omega_2|\vec{X}) < \lambda_{21}P(\omega_1|\vec{X}) + \lambda_{22}P(\omega_2|\vec{X})$$

$$(\lambda_{11} - \lambda_{21})P(\omega_1|\vec{X}) < (\lambda_{22} - \lambda_{12})P(\omega_2|\vec{X})$$

$$-(\lambda_{21} - \lambda_{11})P(\omega_1|\vec{X}) < -(\lambda_{12} - \lambda_{22})P(\omega_2|\vec{X}) \quad \Big/ (-1)$$

$$(\lambda_{21} - \lambda_{11})P(\omega_1|\vec{X}) > (\lambda_{12} - \lambda_{22})P(\omega_2|\vec{X})$$

Odlučujemo se za ω_1 ako je $(\lambda_{21} - \lambda_{11})P(\omega_1|\vec{X}) > (\lambda_{12} - \lambda_{22})P(\omega_2|\vec{X})$

Općenito vrijedi da je $\lambda_{11} < \lambda_{21}$ i $\lambda_{22} < \lambda_{12}$

(gubitak za ispravnu klasifikaciju je manji negoli za neispravnu)

$$\lambda_{21} - \lambda_{11} > 0$$

$$\lambda_{12} - \lambda_{22} > 0$$

Odlučimo se za ω_1 ako je:

$$(\lambda_{21} - \lambda_{11})P(\omega_1|\vec{X}) > (\lambda_{12} - \lambda_{22})P(\omega_2|\vec{X})$$

$$\frac{p(\vec{X}|\omega_1)}{p(\vec{X}|\omega_2)} > \frac{(\lambda_{12}-\lambda_{22})}{(\lambda_{21}-\lambda_{11})} \cdot \frac{P(\omega_2)}{P(\omega_1)} \rightarrow \text{omjer vjerodostojnosti (engl. likelihood ratio)}$$

Odlučujemo se za ω_1 , ako je omjer vjerodostojnosti prešao prag koji je nezavisan od \vec{X} !

$$\text{Prag: } \frac{\lambda_{12}-\lambda_{22}}{\lambda_{21}-\lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

- Klasifikacija s najmanjom pogreškom

U problemu klasifikacije \rightarrow svakom se stanju prirode obično pridružuje jedan od c razreda, a akcija α_i se tumači kao odluka da je pravo stanje prirode ω_i :

- Ako je α_i akcija poduzeta i ako je pravo stanje prirode ω_j tada je odluka ispravna ako je $i=j$, a pogrešna ako je $i \neq j$.
- Ako se pogreška želi izbjeći prirodno je tražiti decizijsko pravilo koje minimizira vjerojatnost pogreške (error rate).

Funkcija gubitka za ovaj slučaj (klasifikacija) se obično izabire kao SIMETRINČNA ili NULA-JEDAN funkcija gubitka:

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad i, j = 1, \dots, c$$

- funkcija gubitka dodjeljuje gubitak 0 za ispravnu odluku, 1 za bilo koju pogrešku (sve pogreške jednako "koštaju").

Rizik koji odgovara toj funkciji je:

$$R(\alpha_i|\vec{X}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\vec{X}) = \sum_{j \neq i} P(\omega_j|\vec{X}) = 1 - P(\omega_i|\vec{X})$$

$P(\omega_i|\vec{X})$ je uvjetna vjerojatnost da je akcija α_i .

Bayesovo decizijsko pravilo koje minimizira rizik traži izbor akcije koja minimizira uvjetni rizik.

Da minimiziramo srednju vjerojatnost pogreške, moramo izabrati i koji maksimizira posteriori vjerojatnost $P(\omega_i|\vec{X})$.

Minimalna pogreška se dobiva na ovaj način:

Odluči se za ω_i ako je $P(\omega_i|\vec{X}) > P(\omega_j|\vec{X})$ za sve $j \neq i$

Bayesovo decizijsko pravilo za minimiziranje vjerojatnosti pogreške: Odluči se za ω_1 ako je $P(\omega_1|\vec{X}) > P(\omega_2|\vec{X})$ inače odluči se za ω_2

Primjer:

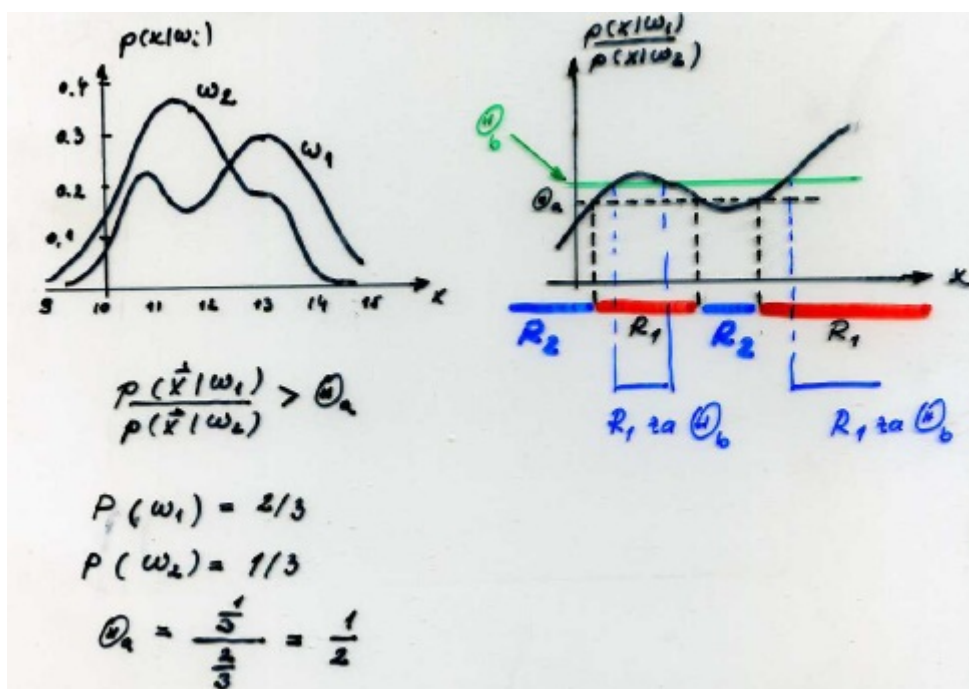
$$\frac{p(\vec{X}|\omega_1)}{p(\vec{X}|\omega_2)} > \frac{(\lambda_{12}-\lambda_{22})}{(\lambda_{21}-\lambda_{11})} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

"0-1" funkcija gubitka:

$$\lambda_{22} = 0; \lambda_{11} = 0; \lambda_{12} = 1; \lambda_{21} = 1;$$

$$\frac{p(\vec{X}|\omega_1)}{p(\vec{X}|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$$


- Ako funkcija gubitka "kažnjava" više pogrešnu klasifikaciju uzorka \vec{X} koji stvarno pripada ω_2 onda je $\lambda_{12} = \lambda(\alpha_1|\omega_2) > \lambda(\alpha_2|\omega_1)$ i pri $\lambda_{11} = \lambda_{22}$ $\Theta_a \rightarrow \Theta_b$ (područje R_1 se smanjuje!)



Slika 5: Primjer

Primjer klasifikacije za $M=c$ ($c>2$) razreda

- skup diskriminantnih funkcija $g_i(\vec{X}), i = 1, \dots, c$
- klasifikator razvrstava nepoznati vektor značajki \vec{X} u razred ω_i ako $g_i(\vec{X}) > g_j(\vec{X})$ za sve $j \neq i$
Klasifikator kao "stroj" koji računa c diskriminantnih funkcija i izabire razred koji ima najveću vrijednost diskriminante funkcije



Slika 6: Shema klasifikatora

Bayesov klasifikator se također može prikazati strukturom na slici

- Za opći slučaj s rizikom možemo izabrati $g_i(\vec{X}) = -R(\alpha_i|\vec{X})$ (maksimalna vrijednost diskriminantne funkcije odgovara minimalnoj vrijednosti uvjetnog rizika)
- za slučaj minimalne pogreške možemo uzeti $g_i(\vec{X}) = P(\omega_i|\vec{X})$ tako da maksimum diskriminantne funkcije odgovara maksimumu posteriorne vjerojatnosti
- VAŽNO: izbor diskriminantne funkcije nije jedinstven
Npr.

- diskriminantne funkcije možemo pomnožiti s istom pozitivnom konstantom
- diskriminantnim funkcijama možemo pribrojiti istu pozitivnu konstantu
- svaku $g_i(\vec{X})$ možemo zamijeniti s $f(g_i(\vec{X}))$, gdje je $f(\cdot)$ monotono rastuća funkcija

$$g_i(\vec{X}) = P(\omega_i|\vec{X}) = \frac{p(\vec{X}|\omega_i) \cdot P(\omega_i)}{\sum_{j=1}^c p(\vec{X}|\omega_j) \cdot P(\omega_j)}$$

$$g_i(\vec{X}) = p(\vec{X}|\omega_i) \cdot P(\omega_i)$$

$$g_i(\vec{X}) = \ln p(\vec{X}|\omega_i) + \ln P(\omega_i), \text{ gdje je } \ln \text{ prirodni logaritam.}$$

- Bez obzira na oblik diskriminante funkcije decizijsko pravilo ostaje isto
Efekt decizijskog pravila je dijeljenje prostora značajki na decizijska područja R_1, R_2, \dots, R_c .
Ako je $g_i(\vec{X}) > g_j(\vec{X})$ za sve $i \neq j$ tada je \vec{X} iz R_i te decizijsko pravilo razvrstava \vec{X} u razred ω_i . Područja su odjeljena decizijskim granicama

Diskriminantne funkcije i decizijske plohe

- minimizacija vjerojatnosti pogreške je ekvivalentna dijeljenju prostora značajki u M područja (za M razreda);
- Ako su područja R_i i R_j susjedna tada ih dijeli decizijska ploha (u višedimenzionalnom prostoru značajki)
- decizijska ploha je u tom slučaju definirana jednadžbom:
$$\frac{P(\omega_i|\vec{X}) - P(\omega_j|\vec{X})}{2} = 0$$
 /s jedne strane plohe razlika je pozitivna, a s druge strane plohe negativna/
- $g_i(\vec{X}) = f(P(\omega_i|\vec{X}))$ gdje je $f(\cdot)$ monotono rastuća funkcija
 $g_i(\vec{X})$ - diskriminantna funkcija
Pravilo klasifikacije:
Klasificiraj \vec{X} u ω_i ako $g_i(\vec{X}) > g_j(\vec{X})$; $j \neq i$
- decizijska ploha koja odvaja dvije susjedne regije (područja) je opisana s:
 $g_{ij}(\vec{X}) = g_i(\vec{X}) - g_j(\vec{X}) = 0$; $i, j = 1, 2, \dots, M$; $i \neq j$

Bayesova klasifikacija za normalne distribucije

- Jedna od najčešće korištenih funkcija gustoće razdiobe vjerojatnosti (pdf-probability density function) u praksi je Gaussova ili normalna gustoća razdiobe vjerojatnosti.
Razlog : modelira razdiobu u velikom broju slučajeva
- Pretpostavimo da funkcija vjerodostojnosti (engl. likelihood function) od ω_i u odnosu na \vec{X} su u l -dimenzionalnom prostoru značajki predočene s:
$$p(\vec{X}|\omega_i) = \frac{1}{(2\pi)^{l/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(\vec{X} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{X} - \vec{\mu}_i)\right)$$
, gdje je $\vec{\mu}_i = E(\vec{X})$ srednja vrijednost razreda ω_i ; Σ_i je $l \times l$ kovarijantna matrica definirana kao:
$$\Sigma_i = E[(\vec{X} - \vec{\mu}_i)(\vec{X} - \vec{\mu}_i)^T]$$

 $|\Sigma_i|$ - označava determinantu od Σ_i , a $E[\cdot]$ je srednja vrijednost (ili matematička nada; očekivanje) slučajne varijable.

Gaussova distribucija (pdf):
 $\mathcal{N}(\vec{\mu}, \Sigma)$
 Zadatak: Oblikovati Bayesov klasifikator

- eksponencijalni oblik nije podoban!
- koristit ćemo diskriminantnu funkciju koja rabi monotonu logaritamsku funkciju $\ln(\cdot)$:

$$g_i(\vec{X}) = \underbrace{f}_{\ln(\cdot)}(P(\omega_i|\vec{X}));$$

$$g_i(\vec{X}) = \ln(p(\vec{X}|\omega_i)P(\omega_i)) = \ln p(\vec{X}|\omega_i) + \ln P(\omega_i)$$

$$g_i(\vec{X}) = -\frac{1}{2}\vec{X}^T \Sigma_i^{-1} \vec{X} +$$

$$\frac{1}{2}\vec{X}^T \Sigma_i^{-1} \vec{\mu}_i -$$

$$\frac{1}{2}\vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i +$$

$$\frac{1}{2}\vec{\mu}_i^T \Sigma_i^{-1} \vec{X} + \ln P(\omega_i) + c_i,$$

gdje je c_i konstanta jednaka $-\frac{l}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i|$

Općenito, $g_i(\vec{X})$ je nelinearna kvadratna forma; Na primjer, za $l=2$ i za

$$\Sigma_i = \begin{pmatrix} \sigma_i^2 & 0 \\ 0 & \sigma_i^2 \end{pmatrix}$$

decizijska funkcija $g_i(\vec{X})$ ima oblik:

$$g_i(\vec{X}) = -\frac{1}{2\sigma_i^2}(x_1^2 + x_2^2) + \frac{1}{\sigma_i^2}(\mu_{i1}x_1 + \mu_{i2}x_2) - \frac{1}{2\sigma_i^2}(\mu_{i1}^2 + \mu_{i2}^2) + \ln P(\omega_i) + c_i$$

Decizijske krivulje:

$g_i(\vec{X}) - g_j(\vec{X}) = 0$ su kvadratnog oblika (elipsoidi, parabole, hiperbole)


za $l > 2$ decizijske granice \rightarrow hiperkvad. forme.

Primjer:

$$P(\omega_1) = P(\omega_2)$$

$$\vec{\mu}_1 = [0, 0]^T \text{ i } \vec{\mu}_2 = [1, 0]^T$$

$$\Sigma_1 = \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.15 \end{bmatrix}, \Sigma_2 = \begin{bmatrix} 0.2 & 0.0 \\ 0.0 & 0.25 \end{bmatrix}$$



Slika 7: Primjer Gauss

Decizijske hiperravnine(plohe)

Doprinos kvadratnom obliku u izrazu:

$$g_i(\vec{X}) = -\frac{1}{2}\vec{X}^T \Sigma_i^{-1} \vec{X} + \frac{1}{2}\vec{X}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2}\vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \frac{1}{2}\vec{\mu}_i^T \Sigma_i^{-1} \vec{X} + \ln P(\omega_i) + c_i$$

je prvi član $\vec{X}^T \Sigma_i^{-1} \vec{X}$

Ako pretpostavimo da je kovarijantna matrica ista za sve razrede:

$$\Sigma_i = \Sigma$$

kvadratni izraz $\vec{X}^T \Sigma_i^{-1} \vec{X}$ bit će jednak za sve diskriminantne funkcije!

- $\vec{X}^T \Sigma_i^{-1} \vec{X}$ i c_i možemo ispustiti!

Decizijska funkcija poprima oblik:

$$g_i(\vec{X}) = \vec{W}_i^T \vec{X} + w_{i0}, \text{ gdje je :}$$

$$\vec{W}_i = \Sigma^{-1} \vec{\mu}_i \text{ i } w_{i0} = \ln P(\omega_i) - \frac{1}{2}\vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i$$

$$\text{imamo } g_i(\vec{X}) = (\Sigma^{-1} \vec{\mu}_i)^T \vec{X} + (\ln P(\omega_i) - \frac{1}{2}\vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i)$$

$g_i(\vec{X})$ je LINEARNA FUNKCIJA od \vec{X} i decizijske plohe su hiperravnine!

Istražimo malo dalje:

• Kovarijantna matrica neka je dijagonalna s jednakim elementima

- pojedine značajke koje oblikuju vektor značajki su međusobno nekorrelirane i imaju jednaku varijancu:

$$E[(x_i - \mu_i)(x_j - \mu_j)] = \sigma^2 \delta_{ij}$$

$\Sigma = \sigma^2 I$, gdje je I $l \times l$ jedinična matrica $g_i(\vec{X}) = \vec{W}_i^T \vec{X} + w_{i0}$, gdje je $\vec{W}_i = \Sigma^{-1} \vec{\mu}_i$ postaje:

$$g_i(\vec{X}) = \frac{1}{\sigma^2} \vec{\mu}_i^T \vec{X} + w_{i0} \text{ jer je } \Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma^2} & 0 & 0 & \dots & 0 \\ 0 & \frac{1}{\sigma^2} & 0 & \dots & 0 \\ \vdots & & & & \\ 0 & 0 & 0 & \dots & \frac{1}{\sigma^2} \end{bmatrix}$$

- Decizijska hiperravnina je:

$$g_{ij}(\vec{X}) = g_i(\vec{X}) - g_j(\vec{X}) = \vec{W}^T (\vec{X} - \vec{X}_0) = 0 \text{ gdje je}$$

$$\vec{W} \vec{\mu}_i - \vec{\mu}_j \text{ i } \vec{X}_0 = \frac{1}{2}(\vec{\mu}_i + \vec{\mu}_j) - \sigma^2 \ln\left(\frac{P(\omega_i)}{P(\omega_j)}\right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

gdje je $\|\vec{X}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_l^2}$ Euklidska norma od \vec{X} .

- hiperravnina prolazi kroz točku \vec{X}_0 ; ako je $P(\omega_i) = P(\omega_j)$ onda je $\vec{X}_0 = \frac{1}{2}(\vec{\mu}_i + \vec{\mu}_j)$
tj. hiperravnina prolazi srednjom vrijednosti od $\vec{\mu}_i$ i $\vec{\mu}_j$

- decizijska hiperravnina (u našem slučaju: pravac) je ortogonalan na $\vec{\mu}_i - \vec{\mu}_j$

- za svaku točku \vec{X} koja leži na decizijskoj hiperravnini, vektor $\vec{X} - \vec{X}_0$ također leži na hiperravnini i vrijedi


$$g_{ij}(\vec{X}) = 0 \Rightarrow \vec{W}^T (\vec{X} - \vec{X}_0) = (\vec{\mu}_i - \vec{\mu}_j)^T \cdot (\vec{X} - \vec{X}_0) = 0.$$

Iz toga slijedi da je $\vec{\mu}_i - \vec{\mu}_j$ ortogonalan na decizijsku hiperravninu.

- hiperravnina je bliža $\vec{\mu}_i$ ako je $P(\omega_i) < P(\omega_j)$, odnosno bliža $\vec{\mu}_j$ ako je $P(\omega_i) > P(\omega_j)$

$$\vec{X}_0 = \frac{1}{2}(\vec{\mu}_i + \vec{\mu}_j) - \sigma^2 \ln\left(\frac{P(\omega_i)}{P(\omega_j)}\right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

- ako je σ^2 mala vrijednost u odnosu na $\|\vec{\mu}_i - \vec{\mu}_j\|$ položaj hiperravnine je prilično "neostjetljiv" na vrijednosti $P(\omega_i)$ i $P(\omega_j)$.



Slika 8: Slika za dvodimenzionalni slučaj

/ mala varijanca pokazuje da su slučajni vektori grupirani u malom radijusu oko njihovih srednjih vrijednosti, tako da mali pomak hiper-ravnine ima mali utjecaj na rezultat klasifikacije/

- Konvarijantna matrica nije dijagonalna

$$g_{ij}(\vec{X}) = \vec{W}^T(\vec{X} - \vec{X}_0) = 0$$

$$\vec{W} = \Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j) \text{ i } \vec{X}_0 = \frac{1}{2}(\vec{\mu}_i + \vec{\mu}_j) - \ln\left(\frac{P(\omega_i)}{P(\omega_j)}\right) \frac{\vec{\mu}_i - \vec{\mu}_j}{\|\vec{\mu}_i - \vec{\mu}_j\|^2}$$

gdje je $\|\vec{X}\|_{\Sigma^{-1}} \equiv (\vec{X}^T \Sigma^{-1} \vec{X})^{1/2}$, Σ^{-1} norma od \vec{X}

Komentari izneseni za slučaj prije vrijede i sada (hiperravnina prolazi kroz točku \vec{X}_0 , odnos hiperravnine naprema $\vec{\mu}_i$ i $\vec{\mu}_j$ u zavisnosti od $P(\omega_i)$ i $P(\omega_j)$) ali uz razliku da decizijska hiperravnina nije više ortogonalna na vektor $\vec{\mu}_i$ i $\vec{\mu}_j$ već na njegovu linearnu transformaciju $\Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j)$.

Klasifikator na temelju minimalne udaljenosti

- pojednostavimo izraz:

$$g_i(\vec{X}) = -\frac{1}{2}(\vec{X} - \vec{\mu}_i)^T \Sigma_i^{-1}(\vec{X} - \vec{\mu}_i) + \ln P(\omega_i) + c_i$$

pretpostavkom da su svi razredi jednako vjerojatni i da imaju istu kovarijantnu matricu:


$$g_i(\vec{X}) = -\frac{1}{2}(\vec{X} - \vec{\mu}_i)^T \Sigma_i^{-1}(\vec{X} - \vec{\mu}_i)$$

/konstantu c_i isto zanemarimo/

- za slučaj $\Sigma = \sigma^2 I$ maksimum $g_i(\vec{X})$ podrazumijeva minimum $d_e = \|\vec{X} - \vec{\mu}_i\|$, gdje je d_e Euklidska udaljenost

- Vektor značajki klasificira se u razred u skladu s minimalnom vrijednosti Euklidske udaljenosti (između točke koja predstavlja taj vektor

i srednju vrijednost $\vec{\mu}_i$)



Slika 9: Klasifikacija najmanjom udaljenosti

- za slučaj kada Σ nije dijagonalna matrica;
 $g_i(\vec{X})$ postiže maksimum kada je Σ^{-1} norma minimalna:
 $d_m = (\vec{X} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{X} - \vec{\mu}_i)^{1/2}$ $d_m =$ Mahalanobisova udaljenost
 - u tom slučaju za $d_m = c$ krivulje su elipse (hiperelipse)
 - Kovarijantna matrica je simetrična i može biti dijagonalizirana
 $\Sigma = \phi \Lambda \phi^T$, gdje je $\phi^T = \phi^{-1}$ i Λ je dijagonalna matrica čiji elementi su svojstvene vrijednosti od Σ .
 ϕ ima stupce koji predstavljaju odgovarajuće (ortonormalne) svojstvene vektore od Σ
 $\phi = [\vec{v}_1, \vec{v}_2, \dots, \vec{v}_l]$
Kombinacijom $d_m = ((\vec{X} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{X} - \vec{\mu}_i))^{1/2}$ i $\Sigma = \phi \Lambda \phi^T$ dobivamo:
 $(\vec{X} - \vec{\mu}_i)^T \phi \Lambda^{-1} \phi^T (\vec{X} - \vec{\mu}_i) = c^2$
te $\vec{X}' = \phi^T \vec{X}$ dobivamo da su koordinate od \vec{X}' jednake $\vec{v}_k^T \vec{X}$, $k = 1, 2, \dots, l$, tj. projekcije \vec{X} na svojstvene vektore.