

## 4. Višestruka diskriminantna analiza (Multiple Discriminant Analysis)

Problem c-razreda:

$$D_1, D_2, \dots, D_c \text{ odnosno } \omega_1, \omega_2, \dots, \omega_c$$

**Generalizirana FLD** uključuje (c-1) diskriminantnih funkcija:

Projekcija d-dimenzionalnog prostora u (c-1)-dimenzionalni prostor ( $d \geq c$ ).

Generalizirana matrica raspršenosti unutar razreda (engl. *within-class scatter matrix*):

$$S_W = \sum_{i=1}^c S_i$$

gdje je

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T$$

i

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{x} \in D_i} \vec{x}.$$

Matrica  $S_B$  kao generalizirana ne dobiva se tako očigledno.

Ukupan vektor srednje vrijednosti  $\vec{m}$

$$\vec{m} = \frac{1}{n} \sum_{\vec{x} \in D_i} \vec{x} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

gdje je  $n_i$  broj uzoraka u razredu  $D_i$  odnosno  $\omega_i$ , a  $\vec{m}_i$  vektor srednje vrijednosti vektora iz razreda  $\omega_i$ .

Ukupna matrica raspršenosti  $S_T$

$$S_T = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T$$
$$S_T = \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})^T$$

$$S_T = \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T + \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_T = S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T.$$

Drugi član

$$\sum_{i=1}^c (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

je poopćena matrica raspršenosti između razreda  $S_B$

$$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_T = S_W + S_B.$$

Projekcija iz d-dimenzionalnog prostora u (c-1)-dimenzionalni prostor uporabom (c-1) diskriminantnih funkcija

$$y_i = \vec{w}_i^T \vec{x}, i = 1, 2, \dots, c-1.$$

Ako  $y_i$  promatramo kao komponentu vektora  $\vec{Y}$  i težinske vektore  $\vec{w}_i$  kao stupce  $d \times (c-1)$  matrice  $W$  tada je projekcija:

$$\vec{Y} = W^T \vec{x}.$$

Uzorci  $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$  projiciraju se u odgovarajući skup uzoraka  $\vec{Y}_1, \vec{Y}_2, \dots, \vec{Y}_n$  koji mogu biti opisani svojim srednjim vektorima i matricama raspršenosti:

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{y} \in Y_i} \vec{y}$$

$$\vec{m} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{y} - \vec{m}_i)(\vec{y} - \vec{m}_i)^T$$

$$\tilde{S}_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$\tilde{S}_W = W^T S_W W$$

$$\tilde{S}_B = W^T S_B W.$$


---

$y_i = \bar{w}_i^T \vec{x}, i = 1, 2, \dots, c-1$ . **Dodatak 1.**

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{y} - \tilde{m}_i)(\vec{y} - \tilde{m}_i)^T$$

$$\vec{y} = W^T \vec{x} \quad \tilde{m}_i = W^T \bar{m}_i$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (W^T \vec{x} - W^T \bar{m}_i)(W^T \vec{x} - W^T \bar{m}_i)^T$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} W^T (\vec{x} - \bar{m}_i)(\vec{x} - \bar{m}_i)^T W$$

$$\tilde{S}_W = W^T \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{x} - \bar{m}_i)(\vec{x} - \bar{m}_i)^T W$$

$$S_W = \sum_{i=1}^c S_i$$

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \bar{m}_i)(\vec{x} - \bar{m}_i)^T$$

$$\tilde{S}_W = W^T S_W W$$

$$\tilde{S}_B = W^T S_B W$$

$$\tilde{S}_W = W^T S_W W$$

Gornje jednađbe pokazuju kako se tzv. *within-class* i *between-class* matrice raspršenja transformiraju projekcijom u nižedimenzionalni prostor.

Tražimo transformacijsku matricu  $W$  koja maksimizira omjer *between-class* i *within-class* raspršenosti. Jednostavna skalarna mjera raspršenosti je determinanta matrice raspršenosti:

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|}.$$

Determinanta je produkt svojstvenih vrijednosti matrice. Problem traženja (i nalaženja) pravokutne matrice  $W$  koja maksimizira  $J(\cdot)$  je težak problem.

**Rješenje:**

Stupci optimalne matrice  $W$  su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i.$$

Ako je  $S_W$  nesingularna onda se problem može pretvoriti u konvencionalni problem svojstvenih vrijednosti. Međutim, to zahtijeva računanje inverzne matrice  $S_W$ :

$$S_W^{-1} S_B \vec{w} = \lambda \vec{w}.$$

Umjesto toga možemo naći svojstvene vrijednosti kao korijene karakterističnog polinoma:

$$|S_B - \lambda_i S_W| = 0.$$

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

Naći  $W$  koja maksimizira  $J(W)$ .

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i$$

Naći svojstvene vrijednosti kao korijene karakterističnog polinoma:


$$|S_B - \lambda_i S_W| = 0$$

i zatim riješiti:

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}.$$

**Primjer za 3D:**

3D distribucija se projicira na 2D podprostore koji su opisani normalnim vektorima  $\vec{w}_1$  i  $\vec{w}_2$ . MDA traži podprostor u kojem je odvojivost projekcija najveća.



## Dodatak 2.

Stupci optimalne (pravokutne) matrice  $W$  (koja maksimizira  $J(W)$ ) su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i.$$

Ako je  $S_W$  nesingularna onda se problem pretvara u konvencionalan problem svojstvenih vrijednosti. Međutim, umjesto računanja inverzne matrice  $S_W^{-1}$  mogu se naći svojstvene vrijednosti karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

i riješiti

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

izravno po  $\vec{w}_i$ .

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

Problem nalaženja (pravokutne) matrice  $W$  koja maksimizira  $J(\cdot)$  je složen. Stupci optimalne matrice  $W$  su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i.$$

Ako je  $S_W$  nesingularna onda se problem može transformirati u konvencionalan problem svojstvenih vrijednosti. Međutim, umjesto toga možemo naći svojstvene vrijednosti kao korijene karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

i onda riješiti

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

izravno za svojstvene vektore  $\vec{w}_i$ .

Budući da je  $S_B$  suma c matrica ranga jedan ili manje i budući da su samo (c-1) od njih nezavisne  $S_B$  je ranga (c-1) ili manje. Najviše je (c-1) svojstvenih vrijednosti različito od 0.

$$\tilde{S}_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_B = n_1 (\vec{m}_1 - \vec{m})(\vec{m}_1 - \vec{m})^T + n_2 (\vec{m}_2 - \vec{m})(\vec{m}_2 - \vec{m})^T + \dots + n_c (\vec{m}_c - \vec{m})(\vec{m}_c - \vec{m})^T$$

Matrica  $S_B$  je suma c matrica. Matrice su ranga jedan ili manje i samo (c-1) od njih su nezavisne.  $S_B$  je ranga (c-1) ili manje. To znači da je najviše (c-1) svojstvenih vrijednosti različito od 0 i da (željeni) svojstveni vektori odgovaraju tim svojstvenim vrijednostima različitim od 0.

## 5. Skup uzoraka za učenje i skup uzoraka za ispitivanje - metode ispitivanja

Skup uzoraka za učenje je skup uzoraka s poznatom klasifikacijom (označeni uzorci).

**Važna pretpostavka:** U uzorcima za učenje sadržana je većina informacija o svojstvima razreda kojima uzorci pripadaju.

## 1. Holdout metoda

Ako imamo dovoljno velik skup uzoraka s poznatom klasifikacijom.

$S_u$  – skup uzoraka za učenje ( $|S_u| = N$ )

$S_i$  – skup uzoraka za ispitivanje

$$S = S_u \cup S_i$$


$$S_u \cap S_i = \emptyset$$

$S$  = skup uzoraka s poznatom klasifikacijom



Nedostaci Holdout metode:

- smanjuje se veličina skupa za učenje i skupa za ispitivanje;
- kako podijeliti skup  $S$  na  $S_u$  i  $S_i$ ?
- vjerojatnost greške klasifikatora koji se oblikuje uporabom konačnog skupa za učenje  $N$  je uvijek veća negoli odgovarajuća asimptotska vjerojatnost pogreške ( $N \rightarrow \infty$ ).



## 2. Leave-One-Out metoda

Metoda pokušava *zaobići* problem podijele skupa označenih uzoraka. Učenje se obavlja uporabom  $(N - 1)$  uzoraka, a ispitivanje se izvodi uporabom onog jednog preostalog uzorka. Ako je taj uzorak pogrešno razvrstan inkrementira se brojilo pogreške. postupak se ponavlja  $N$  puta, ali tako da je svaki put isključen drugi uzorak. Ukupan broj pogrešaka nas upućuje na procjenjenu vjerojatnost pogreške klasifikatora. Nedostatak metode je velika računska složenost.

## 3. Resubstitution metoda (Metoda ponovne zamjene)

Isti se skup uzoraka koristi prvo za učenje, a zatim za ispitivanje. Optimistička procjena vjerojatnosti pogreške klasifikatora.

Od skupa uzoraka za učenje zahtijeva se (za svaki uzorak):

- dovoljnost informacije;
- postojanost značajki;
- geometrijska postojanost (mala udaljenost među uzorcima u prostoru značajki znači i mali razliku u svojstvima objekta).

$N?$

Idealno  $N \rightarrow \infty$ .

### Preporuka za N:

Barem 3 do 5 puta više uzoraka za učenje po razredu od broja značajki (dimenzionalnost vektora značajki).

### Primjer:

Sustav za autorizaciju osoba na temelju lica 580 korisnika - 110-komponentni vektor značajki.

$$M = 580$$

$$N = 5 \times 110 \times 580 = 319000 \text{ slika lica.}$$

### Primjer:

Klasifikacija brojčano-slovčanih znakova.

$$M = 30 + 10 = 40$$

$$\omega_1, \omega_2, \dots, \omega_{40}$$

Dimenzionalnost vektora značajki  $n = 18$ .

$$N = 5 \times 18 \times 40 = 3600 \text{ slika brojčano – slovčanih znakova.}$$



