

## Višestruka diskriminantna analiza

(Multiple Discriminant Analysis)

Problem c-razreda:

$D_1, D_2, \dots, D_c$  odnosno  $w_1, w_2, \dots, w_c$

Generalizirana FLD uključuje

$c-1$  diskriminantnih funkcija:

Projekcija  $d$ -dimenzionalnog prostora  
u  $(c-1)$ -dimenzionalni prostor  
( $d \geq c$ ).

Generalizirana matrica raspršenosti  
unutar razreda (within-class  
scatter matrix):

$$S_W = \sum_{i=1}^c S_i, \text{ gdje je}$$

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T$$

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{x} \in D_i} \vec{x}$$

Matrica  $S_B$  kao generalizirana log 13  
ne dobiva se tako očigledno:

- ukupan vektor srednje vrijednosti  $\vec{m}$

$$\vec{m} = \frac{1}{n} \sum_{\vec{x}} \vec{x} = \frac{1}{n} \sum_{i=1}^c n_i \vec{m}_i,$$

gdje je  $n_i$  broj uzoraka u  
razredu  $D_i$  ( $w_i$ ),

$\vec{m}_i$  - vektor srednje vrijednosti  
vektora iz razrada  $w_i$

- ukupna matrica raspršenosti  $S_T$

$$S_T = \sum_{\vec{x}} (\vec{x} - \vec{m})(\vec{x} - \vec{m})^T$$

$$S_T = \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})(\vec{x} - \vec{m}_i + \vec{m}_i - \vec{m})^T$$

$$S_T = \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i)(\vec{x} - \vec{m}_i)^T + \sum_{i=1}^c \sum_{\vec{x} \in D_i} (\vec{m}_i - \vec{m}) \cdot (\vec{m}_i - \vec{m})^T$$

$$S_T = S_W + \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

Drugi član :

$$\sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

je poprečna matrica raspršenosti između razreda  $S_B$

$$S_B = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_T = S_W + S_B$$

Projekcija iz  $d$ -dimenzionalnog prostora u  $(c-1)$  dimenzionalni prostor uporabom  $(c-1)$  diskriminantnih funkcija

$$y_i = \vec{w}_i^T \vec{x} \quad i = 1, 2, \dots, c-1$$

Ako  $y_i$  promatramo kao komponentu vektora  $\vec{y}$  i težinske vektore  $\vec{w}_i$  kao stupce  $d \times (c-1)$  matrice  $W$  tada je projekcija:

$$\vec{y} = W^T \vec{x}$$

Uzorci  $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$  projiciraju se u odgovarajući skup uzoraka

$\vec{y}_1, \vec{y}_2, \dots, \vec{y}_n$  koji mogu biti

opisani svojim srednjim vektorima i matricama raspršenosti:

$$\tilde{m}_i = \frac{1}{n_i} \sum_{\vec{y} \in Y_i} \vec{y}$$

$$\tilde{m} = \frac{1}{n} \sum_{i=1}^c n_i \tilde{m}_i$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{y} - \tilde{m}_i)(\vec{y} - \tilde{m}_i)^T$$

$$\tilde{S}_B = \sum_{i=1}^c n_i (\tilde{m}_i - \tilde{m})(\tilde{m}_i - \tilde{m})^T$$

$$\tilde{S}_W = W^T S_W W$$

$$\tilde{S}_B = W^T S_B W$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{y} - \tilde{m}_i) (\vec{y} - \tilde{m}_i)^T$$

$$\vec{y} = W^T \vec{x} \quad \tilde{m}_i = W^T \vec{m}_i$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} (W^T \vec{x} - W^T \vec{m}_i) (W^T \vec{x} - W^T \vec{m}_i)^T$$

$$\tilde{S}_W = \sum_{i=1}^c \sum_{\vec{y} \in Y_i} W^T (\vec{x} - \vec{m}_i) (\vec{x} - \vec{m}_i)^T W$$

$$\tilde{S}_W = W^T \underbrace{\sum_{i=1}^c \sum_{\vec{y} \in Y_i} (\vec{x} - \vec{m}_i) (\vec{x} - \vec{m}_i)^T}_{S_W} W$$

$$S_W = \sum_{i=1}^c S_i$$

$$S_i = \sum_{\vec{x} \in D_i} (\vec{x} - \vec{m}_i) (\vec{x} - \vec{m}_i)^T$$

$$\tilde{S}_W = W^T S_W W$$

$$\tilde{S}_B = W^T S_B W$$

$$\tilde{S}_W = W^T S_W W$$

Gornje jednačbe pokazuju kako se

tzv. within-class i between-class matrice raspršenja TRANSFORMIRAJU projekcijom u niže-dimenzionalni prostor.

### TRAŽIMO TRANSFORMACIJSKU MATRICU

W koja maksimizira omjer

between-class raspršenosti  
within-class raspršenosti



- Jednostavna skalarna mjera raspršenosti je determinanta matrice raspršenosti

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|}$$

Determinanta je PRODUKT svojstvenih vrijednosti matrice.

PROBLEM TRAŽENJA (I NALAZENJA) PRAVOKUTNE(!) MATRICE W koja maksimizira  $J(\cdot)$  je težak problem.

RIEŠENÍ, ě:

efd  
1592

Stupci optimalne matrice  $W$   
su generalizirani svojstveni  
vektori koji odgovaraju najvećim  
svojstvenim vrijednostima  $\lambda$

$$S_B \vec{W}_i = \lambda_i S_W \vec{W}_i$$

Ako je  $S_W$  neregularna onda  
se problem može pretvoriti u  
konvencionalni problem  
svojstvenih vrijednosti. Međutim,  
to zahtijeva računanje inverzne  
matrice  $S_W$ .

$$S_W^{-1} S_B \vec{W} = \lambda \vec{W}$$

Umjesto toga možemo naći  
svojstvene vrijednosti kao  
korijene karakterističnog

polinoma:

$$|S_B - \lambda_i S_W| = 0$$

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

Naći:

$W$  koja maksimizira  $J(W)$ !

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i$$


Naći svojstvene vrijednosti kao korijene  
karak. polinoma:  $|S_B - \lambda_i S_W| = 0$   
i zatim riješiti:

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

Primjer za 3D:

3-D distribucija se projicira na  
2-D potprostore koji su opisani

normalnim vektorima  
 $\vec{w}_1$  i  $\vec{w}_2$



MDA

traži potprostor

u kojem je

najveća odvojivost  
projekcija !!!

**TO JE TAJ PROSTOR!**



Stupci optimalne (pravokutne) matrice  $W$  (koja maksimizira  $J(W)$ ) su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima

$$S_B \vec{w}_i = \lambda_i S_W \vec{w}_i$$

- ako je  $S_W$  nesingularna onda se problem pretvara u konvencionalan problem svojstvenih vrijednosti;

Međutim, umjesto računanja inverzne matrice  $S_W^{-1}$  mogu se naći svojstvene vrijednosti karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

i riješiti

$$(S_B - \lambda_i S_W) \vec{w}_i = \vec{0}$$

izravno po  $\vec{w}_i$ .

od 16c

$$S_D = \sum_{i=1}^c n_i (\vec{m}_i - \vec{m})(\vec{m}_i - \vec{m})^T$$

$$S_D = n_1 (\vec{m}_1 - \vec{m})(\vec{m}_1 - \vec{m})^T + \\ n_2 (\vec{m}_2 - \vec{m})(\vec{m}_2 - \vec{m})^T + \dots + \\ n_c (\vec{m}_c - \vec{m})(\vec{m}_c - \vec{m})^T$$

Matrica  $S_D$  je suma  $\checkmark$  matrica!

Matrice su ranga 1 ili manje

i samo  $c-1$  od njih su nezavisne.

$S_D$  je ranga  $c-1$  ili manje.

TO ZNAČI DA JE

NAJVIŠE  $c-1$  SVOJSTVENIH  
VRIEDNOSTI RAZLIČITO OD 0  
I DA (BESYENI) SVOJSTVENI  
VEKTORI ODGOVARAJU  
TIM SVOJSTVENIM  
VRIEDNOSTIMA  
RAZLIČITIM OD 0.

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} = \frac{|W^T S_B W|}{|W^T S_W W|}$$

- problem nalaženja (pravokutne) matrice  $W$  koja maksimizira  $J(\cdot)$ .  $\rightarrow$  složen!
- stupci optimalne matrice  $W$  su generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima  $\lambda$

$$S_B \vec{w}_i = \lambda_i S_W \cdot \vec{w}_i$$

- ako je  $S_W$  nesingularna onda se problem može transformirati u konvencionalni problem svojstvenih vrijednosti.

- međutim, umjesto toga možemo naći svojstvene vrijednosti kao korijene karakterističnog polinoma

$$|S_B - \lambda_i S_W| = 0$$

i onda riješiti

$$(S_B - \lambda_i S_W) \vec{w}_i = 0$$

IZRAVNO za svojstvene vektore  $\vec{w}_i$ :

Budući da je  $S_B$  suma  $C$  matrica ranga jedan ili manje, i budući da su samo  $C-1$  od njih nezavisni

$S_B$  je ranga  $C-1$  ili manje.

- najviše je  $C-1$  svojstvenih vrijednosti različito od 0.


# SKUP UZORAKA ZA UČENJE I SKUP UZORAKA ZA

## ISPITIVANJE - METODE ISPITIVANJA

Skup uzoraka za učenje - uzorci  
s poznatom klasifikacijom  
( označeni uzorci )

Važna pretpostavka: u uzorcima za  
učenje sadržana je većina  
informacije o svojstvima  
razreda kojima uzorci pripadaju

1. Ako imamo dovoljno veliki skup  
uzoraka s poznatom klasifikacijom



Holdout  
metoda

$$\#S_u = N$$

$S_u$  - skup uzoraka za učenje


$S_i$  - skup uzoraka za  
ispitivanje

$$S = S_u \cup S_i \quad ; \quad S_u \cap S_i = \emptyset$$

$S$  - skup uzoraka s poznatom  
klasifikacijom

Nedostaci Holdout metode:

- smanjuje se veličina skupa za učenje i skupa za ispitivanje
- kako podijeliti skup  $S$  na  $S_u$  i  $S_i$ ?
- vjerojatnost greške klasifikatora koji se oblikuje uporabom konačnog skupa za učenje  $N$  je uvijek veća nego li je odgovarajuća asimptotska vjerojatnost pogreške ( $N \rightarrow \infty$ )



## 2. Leave-One-Out metoda

- metoda pokušava "zaobići" problem podjele skupa označenih uzoraka
- Učenje se obavlja uporabom  $N-1$  uzoraka a ispitivanje se izvodi uporabom onog jednog preostalog uzorka.

Ako je taj uzorak pogrešno razvrstan → inkrementira se brojilo pogreške;

Postupak se ponavlja  $N$  puta ali tako da je svaki put isključen drugi uzorak.

Ukupan broj pogrešaka nas upućuje na procijenjenu vjerojatnost pogreške klasifikatora

Nedostatak metode: velika računska složenost

### 3. Resubstitution metoda (Metoda ponovne zamjene)

Isti se skup podataka koristi, prvo za učenje a zatim za ispitivanje.

- optimistička procjena vjerojatnosti pogreške klasifikatora

Od skupa uzoraka za učenje  
zahtijeva se (za svaki uzorak):

- dovoljnost informacije
- postojanost značajki
- geometrijska postojanost

(mala udaljenost među uzorcima u  
prostoru značajki znači i malu  
razliku u svojstvima objekta)

$N$ ?

Idealno  $N \rightarrow \infty$

Preporuka za  $N$

- barem 3 do 5 puta više uzoraka  
za učenje po razredu od  
broja značajki (dimensionalnost  
vektora značajki)

Primjer: sustav za autorizaciju  
osoba na temelju lica

580 korisnika ( $M = 580$ )

110 - komponentni vektor značajki

$$N \doteq 5 * 110 * 580 = 319\,000 !!!$$

slika lica  $\uparrow$

Primjer: Klasifikacija brojčano-slovnih znakova

$$M = 30 + 10 = 40$$

$$\omega_1, \omega_2, \dots, \omega_{40}$$

Dimenzionalnost vektora značajki

$$n = 18.$$

$$N = 5 * 18 * 40 = 3600$$

↑  
slika brojčano-slovnih znakova