


# SVM - Support Vector Machines

## Strojevi s potpornim vektorima

(Vapnik, 1992)

- Izvorno SVM je linearni stroj
- Osnovna zamisao SVM : konstrukcija hiperravnine kao dezižijske plohe ali tako da je margina odvajanja između "pozitivne" i "negativne" skupine uzoraka (za učenje) maksima-

Lna.



$x \in \omega_1$

$o \in \omega_2$

$\rho$  - margina  
separacije  
(odvajanja)

$\rho_1 < \rho_2$

Imamo skup uzoraka za učenje :

$$\{(\vec{x}_i, d_i)\}_{i=1}^N, \text{ gdje je}$$

$\vec{x}_i$ ;  $i=1, 2, \dots, N$  ulazni vektor  
uzoraka za  $i$ -ti primjer

$d_i$  - željeni odgovor klasifikatora

$$\begin{aligned} \omega_1 &\rightarrow d_i = +1 \\ \omega_2 &\rightarrow d_i = -1 \end{aligned} \quad \left. \vphantom{\begin{aligned} \omega_1 &\rightarrow d_i = +1 \\ \omega_2 &\rightarrow d_i = -1 \end{aligned}} \right\} \text{označeni uzorci}$$

Pretpostavka : razredi  $\omega_1$  i  $\omega_2$   
su linearno separabilni

Jednadžba dezižijske ravnine :

$$\vec{w}^T \vec{x} + b = 0$$

$\vec{x}$  - ulazni vektor

$\vec{w}$  - vektor težinskih koeficijenata

$b$  - pomaknuće ( $w_0$ )


Vrijedi :

$$\vec{w}^T \vec{x} + b \geq 0 \quad \text{za} \quad d_i = +1$$

$$\vec{w}^T \vec{x} + b < 0 \quad \text{za} \quad d_i = -1$$

**Margina:** Za zadani vektor težinskih koeficijenata  $\bar{W}$  i pomaknuće  $b$  udaljenost između hiperravnine i najbliže točke (uzorka) u  $n$ -dimenzionalnom prostoru naziva se MARGINA ODVAJANJA (engl. margin of separation) i označit ćemo je s  $\rho$ .

**Cilj:** Naći posebnu hiperravninu za koju je margina odvajanja  $\rho$  maksimalna. Takva hiperravnina naziva se OPTIMALNA RAVNINA.





Optimalna hiperravnina:  $\{\vec{w}_0, b_0\}$


$$\vec{w}_0^T \vec{x} + b_0 = 0$$

optimalne  
vrijednosti

Decizijska funkcija:

$$g(\vec{x}) = \vec{w}_0^T \vec{x} + b_0$$


↗ daje mjeru udaljenosti  $\vec{x}$ -a  
od optimalne hiperravnine



$$\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|}$$

$$r = \frac{g(\vec{x})}{\|\vec{w}_0\|}$$

Primjer:



$$g(\vec{x}) = \vec{w}_0^T \vec{x} + b_0$$

$$g(\vec{x}) = \begin{bmatrix} -2 \\ 3 \end{bmatrix}^T \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - 4$$

$$\vec{x}_1 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

$$g(\vec{x}_1) = -2 \leftarrow \text{NORMIRATI } r(\vec{x}_1) \doteq 0.54$$

$$\vec{x}_2 = \begin{bmatrix} 1.5 \\ 5 \end{bmatrix}$$

$$g(\vec{x}_2) = 8 \leftarrow \text{NORMIRATI } r(\vec{x}_2) \doteq 2.65 \quad \|\vec{w}_0\| = \sqrt{w_1^2 + w_2^2}$$

Par  $(\vec{w}_0, b_0)$  mora zadovoljiti sljedeća <sup>SVM 5</sup> ograničenja

$$\vec{w}_0^T \vec{x}_i + b_0 \geq 1 \quad \text{za } d_i = +1 \quad (1)$$

$$\vec{w}_0^T \vec{x}_i + b_0 \leq -1 \quad \text{za } d_i = -1 \quad (2)$$

$$\vec{x}_i \in \{(\vec{x}_i, d_i)\}_{i=1}^N$$

Naravno ovo vrijedi ako su uzorci linearno odvojivi.

Uvijek možemo skalirati  $\vec{w}_0$  i  $b_0$  tako da nejednadžbe (1) i (2) vrijede!

$$r = \frac{|g(\vec{x})|}{\|\vec{w}_0\|}$$

možemo skalirati  $\vec{w}_0$  i  $b_0$  tako da

za najbliže

uzorke iz  $\omega_1$  i  $\omega_2$

bude

$$g(\vec{x}) = 1 \quad \text{za } \omega_1$$

$$g(\vec{x}) = -1 \quad \text{za } \omega_2$$

hiperravnini  $g(\vec{x})$ !

za uzorke (točke u  $n$ -dimensional. prostoru) iz skupa za učenje i to za one koje vrijedi

$$\vec{w}_0^T \vec{x} + b_0 = 1 \quad \text{za } d_i = +1$$

$$\vec{w}_0^T \vec{x} + b_0 = -1 \quad \text{za } d_i = -1$$

kažemo da su potporni vektori.  
(support vectors)

Potporni vektori su one točke koje leže najbliže odlučujućoj hiperravnini i zato se najteže klasificiraju. Zbog toga oni imaju izravan utjecaj na optimalni položaj odlučujuće hiperravnine.

Potporni vektor  $\vec{x}^{(s)}$ :

$$g(\vec{x}^{(s)}) = \vec{w}_0^T \vec{x}^{(s)} + b_0 = \mp 1 \quad \text{za} \\ d^{(s)} = \mp 1$$

(!/Algebarska udaljenost potpornog vektora  $\vec{x}^{(s)}$  od optimalne hiperravnine je  $r = \frac{g(\vec{x}^{(s)})}{\|\vec{w}_0\|}$ )

$$r = \begin{cases} \frac{1}{\|\vec{w}_0\|} & \text{ako je } d^{(s)} = +1 \\ -\frac{1}{\|\vec{w}_0\|} & \text{ako je } d^{(s)} = -1 \end{cases}$$

gdje znak + označava da  $\vec{x}^{(s)}$  leži na pozitivnoj strani optimalne hiperravnine a - predznak pokazuje da je  $\vec{x}^{(s)}$  na negativnoj strani optimalne ravnine.

$\rho$  - optimalna vrijednost  
MARGINE ODVAJANJA  
između dva razreda  
koji definiraju skup uzoraka  
za učenje

$$\rho = 2r$$

$$\rho = \frac{2}{\|\vec{w}_0\|}$$

$$\rho = \frac{2}{\|\vec{w}_0\|}$$

slijedi da maksimiziranje margine odvajanja temelji na minimizaciji norme vektora težinskih koeficijenata  $\vec{w}_0$ .

Optimalna hiperravnina :

$$\vec{w}_0^T \vec{x} + b_0 = 0$$

je jedinstvena u tom smislu da vektor  $\vec{w}_0$  daje maksimalnu separaciju između pozitivnih i negativnih uzoraka iz skupa za učenje.

Cilj: Razvoj djelotvorne procedure (uporabom skupa uzoraka za učenje) tako da nađemo optimalnu hiperravninu uz zadovoljenje ograničenja :

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad \text{za} \\ i = 1, 2, \dots, N$$



## Formalno postavljén problem:

- Zadan je skup uzoraka za učenje  $\{(\vec{x}_i, d_i)\}_{i=1}^N$
- Nađi optimalnu vrijednost vektora težinskih koeficijenata  $\vec{W}$  i pomaknuće  $b$  tako da su zadovoljena ograničenja

$$d_i \cdot (\vec{W}^T \vec{x}_i + b) \geq 1 \quad \text{za} \\ i = 1, 2, \dots, N$$

a pri tomu vektor težinskih koeficijenata  $\vec{W}$  minimizira kriterijsku funkciju:

$$J(\vec{W}) = \frac{1}{2} \vec{W}^T \vec{W}$$

$$\vec{W}^T \vec{W} = \|\vec{W}\|^2$$

- 
- nelinearni optimizacijski zadatak sa skupom linearnih nejednadžbi

Optimizacijski problem riješiti  
metodom Lagrangeovih multiplika-  
-tora

prvotni problem

Primjer :

Određivanje vezanih ekstrema funkcije  $z = f(x, y)$  uz uvjet

$\varphi(x, y) = 0$  svodi se na računanje slobodnih ekstrema Lagrangeove funkcije :

$$F = f(x, y) + \lambda \varphi(x, y)$$

Lagrangeov multiplikator

$$\frac{\partial F}{\partial x} = 0 \quad ; \quad \frac{\partial F}{\partial y} = 0 \quad \varphi(x, y) = 0$$

Iz tog se sustava jednačbi određuju vrijednosti za  $x, y$  i Lagrangeov multiplikator  $\lambda$ .

- Ako je  $d^2 F < 0$  u izračunatoj točki, funkcija  $z = f(x, y)$  ima maksimum

- Ako je  $d^2 F > 0$  funkcija  $z = f(x, y)$  ima minimum

Tražimo ekstrem funkcije:

$$z = x + 2y$$

uz uvjet  $x^2 + y^2 = 5$ .

- Lagrangeova funkcija:

$$F = x + 2y + \lambda(x^2 + y^2 - 5)$$

- Računamo:

$$F_x = \frac{\partial F}{\partial x} = 1 + 2x\lambda$$

$$F_y = \frac{\partial F}{\partial y} = 2 + 2y\lambda$$

- Iz sustava jednačini:

$$1 + 2\lambda x = 0$$

$$2 + 2\lambda y = 0$$

$$x^2 + y^2 = 5$$

slijedi:  $x = -\frac{1}{2\lambda}$  ;  $y = -\frac{1}{\lambda}$

uvršćavamo u 3. jednačinu:

$$\frac{1}{4\lambda^2} + \frac{1}{\lambda^2} = 5 / 4\lambda^2$$

$$5(1 - 4\lambda^2) = 0$$

$$\lambda_{1,2} = \pm \sqrt{\frac{1}{4}}$$

$$\lambda_1 = +\frac{1}{2} ; \quad \lambda_2 = -\frac{1}{2}$$

za  $\lambda_1 = \frac{1}{2}$  dobivamo:

$$x_1 = -1 \quad y_1 = -2$$

za  $\lambda_2 = -\frac{1}{2}$

$$x_2 = 1 \quad y_2 = 2$$

Računamo:

$$d^2F = \frac{\partial^2 F}{\partial x^2} dx^2 + 2 \frac{\partial^2 F}{\partial x \partial y} dx dy + \frac{\partial^2 F}{\partial y^2} dy^2$$

$$F_{xx} = 2\lambda \quad ; \quad F_{yy} = 2\lambda \quad ; \quad F_{xy} = 0$$

$$d^2F = 2\lambda dx^2 + 2\lambda dy^2 = 2\lambda (dx^2 + dy^2)$$

za  $(\lambda_1 = \frac{1}{2}) \quad d^2F > 0 \quad \text{minimum}$

za  $(\lambda_2 = -\frac{1}{2}) \quad d^2F < 0 \quad \text{maksimum}$

funkcije  
 $f(x, y)$ .



$$J(\vec{w}) = \frac{1}{2} \vec{w}^T \cdot \vec{w}$$

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1 \quad \forall i = 1, 2, \dots, N$$

1. Lagrangeova funkcija:

$$J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i [d_i \cdot (\vec{w}^T \vec{x}_i + b) - 1]$$

$\lambda_i$  - Lagrangeovi multiplikatori

$$a) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \vec{0}$$

$$b) \quad \frac{\partial J(\vec{w}, b, \lambda)}{\partial b} = 0$$

$$c) \quad \lambda_i [d_i \cdot (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i = 1, 2, \dots, N$$

$$d) \quad \lambda_i \geq 0 \quad i = 1, 2, \dots, N$$

$$\frac{\partial J(\vec{w}, b, \lambda)}{\partial \vec{w}} = \vec{w} - \sum_{i=1}^N \lambda_i d_i \vec{x}_i = \vec{0}$$

$$\boxed{\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i}$$

u skladu s Karush-Kuhn-Tucker /  
uvjetima (KKT conditions) /  
S. Theodoridis, K. Koutroumbas, 2006 /

$$\frac{\partial J(\vec{w}, b, \lambda)}{\partial b} = - \sum_{i=1}^N \lambda_i d_i = 0$$

$$\boxed{\sum_{i=1}^N \lambda_i d_i = 0}$$

- Traženi vektor  $\vec{w}$  određen je s  $N_s \leq N$  vektora uzoraka

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \cdot \vec{x}_i$$

$$\lambda_i \neq 0$$

Vektor  $\vec{w}$  je optimalno rješenje!

- Budući da je skup ograničenja

$$\lambda_i [d_i \cdot (\vec{w}^T \vec{x}_i + b) - 1] = 0$$

$$i = 1, 2, \dots, N$$

potporni vektori leže u dvije hiperravnine:

$$\vec{w}^T \vec{x} + b = \pm 1$$

Potporni (support) vektori su oni vektori koji leže tako da su NAJBLIŽI hiperravnini linearnog klasifikatora i određuju kritične elemente skupa za učenje.

- Vektori  $\vec{x}_i$  za koje je  $\lambda_i = 0$  mogu ležati izvan pojasa odvajanja ali mogu ležati, također, na jednoj od hiperravnina.
- Rezultirajuća (optimalna) hiperravnina je neosjetljiva na broj i položaj takvih vektora
- $\vec{w}$  je eksplicitno određena,  $b$  se može dobiti iz jednog od uvjeta

(\*)  $\lambda_i [d_i (\vec{w}^T \vec{x}_i + b) - 1] = 0 \quad i=1, 2, \dots, N$   
za  $\lambda_i \neq 0$ .

U praksi,  $b$  se obično računa kao srednja vrijednost dobivena uporabom svih uvjeta tog tipa (\*)

Optimalna hiperravnina linearnog klasifikatora je jedinstvena.

- $J(\vec{w})$  je konveksna (strogo)
- Nejednadžbe su linearne

\* Lokalni minimum je ujedno i globalni! \*

Konveksna funkcija  $f(\vec{\theta})$


$$f: S \subseteq \mathbb{R}^L \rightarrow \mathbb{R}$$

je konveksna u  $S$  ako za svaki


$\vec{\theta} : \vec{\theta}' \in S$  vrijedi: NJE Lagrangeov  
multiplikator!

$$f(\lambda \vec{\theta} + (1-\lambda) \vec{\theta}') \leq \lambda f(\vec{\theta}) + (1-\lambda) f(\vec{\theta}')$$

za svaki  $\lambda \in [0, 1]$



konveksna  
funkcija



konkavna  
funkcija



# Lagrangov dualni problem

- Optimizacijski zadatak

minimiziraj  $J(\vec{w})$

uz ograničenje

$$\varphi_i(\vec{w}) \geq 0 \quad i = 1, 2, \dots, N$$

Lagrangova funkcija

$$J(\vec{w}, \vec{\lambda}) = J(\vec{w}) - \sum_{i=1}^N \lambda_i \varphi_i(\vec{w})$$

Neka je  $J^*(\vec{w}, \vec{\lambda}) = \max_{\vec{\lambda}} (J(\vec{w}, \vec{\lambda}))$

Budući da je  $\vec{\lambda} \geq \vec{0}$  i  $\varphi_i(\vec{w}) \geq 0$

- Maksimalna vrijednost Lagrangove funkcije onda kad je

$$\lambda_i \geq 0; \quad i = 1, 2, \dots, N \quad \text{ili}$$

kada je  $\varphi_i(\vec{w}) = 0$  (ili oboje)

u tom slučaju je

$$J^*(\vec{w}, \vec{\lambda}) = J(\vec{w})$$

Originalni problem je ekvivalentan sa:

$$\min_{\vec{w}} J(\vec{w}) = \min_{\vec{w}} \max_{\vec{\lambda}} J(\vec{w}, \vec{\lambda})$$

Dualni problem :

$$\max_{\vec{\lambda} \geq \vec{0}} \min_{\vec{w}} J(\vec{w}, \vec{\lambda})$$

↓ rješenje ovog dijela

$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

## Detekcija živosti ruke

85 slika IR

29 živih ruku

56 neživih (umjetnih) ruku  
(2 tipa)

} skup  
za  
ispitivanje

## SVM


45 slika za učenje

40 slika za ispitivanje

žive ruke  $\notin$  skupu za učenje

umjetne ruke ne pripadaju skupu za učenje

SVM s linearnim jezgrom 5% pogreške



$$(1) J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i \cdot d_i \vec{w}^T \vec{x}_i - b \sum_{i=1}^N \lambda_i d_i + \sum_{i=1}^N \lambda_i$$

$$\vec{w}^T \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{w}^T \vec{x}_i = \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \cdot \vec{x}_j$$

$$J(\vec{w}, b, \lambda) = Q(\lambda)$$

$$Q(\lambda) = \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j d_i d_j \vec{x}_i^T \cdot \vec{x}_j$$

uz ograničenjima:

$$(1) \sum_{i=1}^N \lambda_i d_i = 0$$

$$(2) \lambda_i \geq 0 \text{ za } i=1, 2, \dots, N$$

maksimiziraj  $Q(\lambda)$ !



# Dualni problem -

svm 16

- Lagrangeova dualnost  
(Wolfe dual representation)

a) Ako prvotni problem ima optimalno rješenje tada dualni problem ima također optimalno rješenje i odgovarajuća optimalna rješenja su jednaka.

Maksimiziraj  $J(\vec{w}, b, \lambda)$

gdje 
$$\vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$\sum_{i=1}^N \lambda_i d_i = 0$$

$$\lambda_i \geq 0 \quad i=1,2,\dots,N$$

VEKTORI  
| UZORAKA

ograničujuća  
jednadžbe  
ne  
nejednadžbe !!!

Dualni problem

- Naiznimo Lagrangeove  
multiplikatore koji daju  
optimalno rješenje!

Nekle značajke dualnog pristupa:

- Kriterijska funkcija koja se treba maksimizirati zavisi samo od ulaznih uzoraka u obliku skupa skalarnog produkta

$$\{\vec{x}_i^T \vec{x}_j\}_{(i,j)=1}^N$$

Optimalno rješenje  $\vec{w} = \vec{w}_0$

$$\vec{w}_0 = \sum_{i=1}^N \lambda_{0,i} d_i \vec{x}_i$$

gdje je  $\lambda_{0,i}$  optimalni

L. multiplikator

$$b_0 = 1 - \vec{w}_0^T \vec{x}^{(1)} \text{ za } d^{(1)} = 1$$

$$(1) \quad J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \vec{w} - \sum_{i=1}^N \lambda_i [d_i (\vec{w}^T \vec{x}_i + b) - 1] \quad \text{sum 17}$$

$$(2) \quad \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

$$(3) \quad \sum_{i=1}^N \lambda_i d_i = 0 \quad i=1, 2, \dots, N$$

$$\lambda_i \geq 0$$

zamjenom (2) i (3) u (1) i  
nakon uređivanja dobiva se:

$$(**) \quad \max_{\lambda} \left( \sum_{i=1}^N \lambda_i - \frac{1}{2} \sum_{i,j} \lambda_i \lambda_j d_i d_j \vec{x}_i^T \vec{x}_j \right)$$

uz uvjet

$$\sum_{i=1}^N \lambda_i d_i = 0$$


$$\lambda_i \geq 0$$

Optimalni Lagrangeovi multiplikatori  
se računaju optimiziranjem  
(MAKSIMIZIRANJE) izraza **(\*\*)**  
a optimalna se hiperravnina

$$\text{dobiva} \quad \vec{w} = \sum_{i=1}^N \lambda_i d_i \vec{x}_i$$

↑ optimalni Lagrangeovi multiplikatori.

# PRIMJER:



$$w_1: [1, 1]^T$$

$$[1, -1]^T$$

$$w_2: [-1, 1]^T$$

$$[-1, -1]^T$$

vizualno:  
optimalna ravni

$$je: w_1 = 1$$

$$w_2 = 0$$

$$b = 0$$

$$g(\vec{x}) = \vec{w}^T \vec{x} + b = 0$$

$$g(\vec{x}) = x_1$$

$$w_1 \cdot x_1 + w_2 \cdot x_2 + b = 0$$

Ograničenja (linearne nejednadžbe):

$$w_1 + w_2 + b - 1 \geq 0$$

$$w_1 - w_2 + b - 1 \geq 0$$

$$+ w_1 - w_2 - b - 1 \geq 0$$

$$+ w_1 + w_2 - b - 1 \geq 0$$

$$d_i \cdot (\vec{w}^T \vec{x}_i + b) \geq 1$$

$$(-1) \cdot (-1 \cdot w_1 + 1 \cdot w_2 + b) - 1 \geq 0$$

$$za w_2 \quad d_i = -1$$



$$J(\vec{w}, b, \lambda) = \frac{1}{2} \vec{w}^T \cdot \vec{w} - \sum_{i=1}^4 \lambda_i [d_i \cdot (\vec{w}^T \vec{x}_i + b) - 1] \quad \text{svm 20}$$

$$J(\vec{w}, b, \lambda) = \frac{w_1^2 + w_2^2}{2} - \lambda_1 (w_1 + w_2 + b - 1) \\ - \lambda_2 (w_1 - w_2 + b - 1) \\ - \lambda_3 (w_1 - w_2 - b - 1) \\ - \lambda_4 (w_1 + w_2 - b - 1)$$

KKT uvjeti su zadani sa:

$$\frac{\partial J}{\partial w_1} = 0 \Rightarrow w_1 = \lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 \quad (1)$$

$$\frac{\partial J}{\partial w_2} = 0 \Rightarrow w_2 = \lambda_1 + \lambda_4 - \lambda_2 - \lambda_3 \quad (2)$$

$$\frac{\partial J}{\partial b} = 0 \Rightarrow \lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0 \quad (3)$$

$$\lambda_1 (w_1 + w_2 + b - 1) = 0 \quad (4)$$

$$\lambda_2 (w_1 - w_2 + b - 1) = 0 \quad (5)$$


$$\lambda_3 (w_1 - w_2 - b - 1) = 0 \quad (6)$$

$$\lambda_4 (w_1 + w_2 - b - 1) = 0 \quad (7)$$

$$\lambda_1, \lambda_2, \lambda_3, \lambda_4 \geq 0$$

7 jednačbi  $\rightarrow$  7 nepoznanica

Znamo rješenje s maksimalnom marginom (za ovaj jednostavan slučaj):  $w_1 = 1$   $w_2 = 0$   $b = 0$



$$g(\vec{x}) = x_1 = 0$$

maksimalna margina razdvajanja

Uvrstimo  $w_1 = 1$  ;  $w_2 = 0$  i  $b = 0$  u jednačinu:

- ①  $\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1$
- ②  $\lambda_1 + \lambda_4 - \lambda_2 - \lambda_3 = 0$
- ③  $\lambda_1 + \lambda_2 - \lambda_3 - \lambda_4 = 0$

Sustav linearnih jednačina: 3 jednačine i 4 nepoznanice!

Očito  $\rightarrow$  više od jednog rješenja!

Medutim, svako od rješenja vodi do JEDINSTVENOG  
(OPTIMALNE) LINIJE  
ODVAJANJA!

SVIM 22

Na primjer:

$$\textcircled{1} + \textcircled{3} \quad 2\lambda_1 + 2\lambda_2 = 1 \Rightarrow \lambda_1 = \frac{1 - 2\lambda_2}{2}$$

$$\textcircled{1} + \textcircled{2} \quad 2\lambda_1 + 2\lambda_4 = 1$$

$$\textcircled{2} + \textcircled{3} \quad 2\lambda_1 - 2\lambda_3 = 0 \Rightarrow \lambda_1 = \lambda_3$$

uzmimo  $\lambda_1 = \frac{1}{8} \Rightarrow \lambda_3 = \frac{1}{8}$

$$\lambda_2 = \frac{1 - 2\lambda_1}{2} = \frac{1 - 2 \cdot \frac{1}{8}}{2} = \frac{\frac{3}{4}}{\frac{2}{1}} = \frac{3}{8}$$

$$\lambda_4 = \frac{1 - 2\lambda_1}{2} = \frac{3}{8}$$

$$\vec{W} = \sum_{i=1}^{N=4} \lambda_i d_i \vec{x}_i = \lambda_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ -1 \end{bmatrix} + \lambda_3 \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \lambda_4 \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\vec{W} = \frac{1}{8} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{3}{8} \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \frac{1}{8} \begin{bmatrix} -1 \\ 1 \end{bmatrix} - \frac{3}{8} \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\vec{W} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

---

$$\lambda_1 = \frac{1}{4} \quad \lambda_3 = \frac{1}{4} \quad \lambda_4 = \frac{1}{4} \quad \lambda_2 = \frac{1}{4}$$

$$\vec{W} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$g(\vec{x}) = x_1 = 0$$

# SVM za $M > 2$ razreda?

Podsjetimo se:

- za svaki od razreda tražimo optimalnu decizijsku funkciju

$$g_i(\vec{x}) \quad i=1, 2, \dots, M$$

tako da

$$g_i(\vec{x}) > g_j(\vec{x}) \quad \forall j \neq i$$

ako je  $\vec{x} \in \omega_i$

za SVM tražimo

decizijsku funkciju  $g_i(\vec{x}) = 0$

takva da bude optimalna hiperravnina koja odvaja razred  $\omega_i$  od svih ostalih

$$g_i(\vec{x}) > 0 \quad \text{za } \vec{x} \in \omega_i$$

$$g_i(\vec{x}) < 0 \quad \text{inače}$$

Klasifikacijsko pravilo

dodijeli  $\vec{x}$  u  $\omega_i$

ako

$$i = \arg \max_k \{g_k(\vec{x})\}.$$